DATA SCIENCE PROJECT

WORKFLOW PARTE 1 DO PROJETO

NOME COMPLETO: ERICK FRANCISCO MACHADO

COLAB: Aqui

GITHUB: Aqui





Cenário Fictício:

Prezados(as) alunos(as),

É com entusiasmo que apresento a proposta do **Projeto de Conclusão de Curso (TCC)** para os estudantes do curso de Ciência de Dados da Universidade Vila Velha: o UWine – Clube de Vinhos da UVV.

A proposta do projeto consiste na análise de um Clube de Vinhos universitário fictício, com base em dados simulados, que será totalmente orientado por técnicas e práticas de Ciência de Dados.

Sendo assim, você foi designado como **Consultor em Ciência de Dados** (***Data Science Consultant***) para fazer uma análise completa dos dados dos clientes a partir de um conjunto de dados (Amostra) com mais de 1 milhão de notas fiscais (~ 350 Megabytes). Além disso, há uma entrada diária de aproximadamente umas 5000 novas notas fiscais no sistema.

O objetivo é permitir que cada consultor(a) percorra foco analíticos diferentes dentro do mesmo ecossistema de dados, aplicando modelos de machine learning supervisionado ou não supervisionado, análise preditiva, dashboards interativos, entre outros.

Para garantir organização, profundidade técnica e coerência metodológica no desenvolvimento do ***Projeto UWine***, adotaremos um workflow composto por cinco etapas principais, alinhadas às boas práticas da Ciência de Dados. Cada etapa representa um marco do processo analítico, permitindo que cada analista avance de forma estruturada do entendimento inicial dos dados até a entrega final dos insights.

BIBLIOTECAS E FUNÇÕES E CÓDIGOS

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount
("/content/drive", force_remount=True).
```

	NOTA FISCAL	REGIÃO	SEXO	ESTADO CIVIL	DEPENDENTES	RENDA BRUTO (R$)	OPINIÃO DO CLIENTE	NOTA DE SATISFAÇÃO (%)	
0	8280696	SUDESTE	MASCULINO	SOLTEIRO	1	16072.73	Entrega foi boa e rápida na UVVine	68.680	1
1	5608537	SUDESTE	MASCULINO	CASADO	0	3232.27	Experiência regular, não atendeu a política de...	68.680	1
2	2937609	SUDESTE	MASCULINO	SOLTEIRO	1	17275.53	Funcionou bem e me atendeu no prazo certo a UV...	68.680	1
3	5275399	SUL	MASCULINO	CASADO	3	7813.86	Foi indiferente minha experiência com a UVVine	68.680	1
4	1230503	SUDESTE	MASCULINO	CASADO	1	27885.50	Funcionou bem e me atendeu no prazo certo a UV...	76.659	1

5 rows × 23 columns

```
(1120000, 23)
```

	NOTA FISCAL	REGIÃO	SEXO	ESTADO CIVIL	DEPENDENTES	RENDA BRUTO (R$)	OPINIÃO DO CLIENTE	NOTA DE SATISFAÇÃO (%)	
0	8280696	SUDESTE	MASCULINO	SOLTEIRO	1	16072.73	Entrega foi boa e rápida na UVVine	68.680	1
1	5608537	SUDESTE	MASCULINO	CASADO	0	3232.27	Experiência regular, não atendeu a política de...	68.680	1
2	2937609	SUDESTE	MASCULINO	SOLTEIRO	1	17275.53	Funcionou bem e me atendeu no prazo certo a UV...	68.680	1
3	5275399	SUL	MASCULINO	CASADO	3	7813.86	Foi indiferente minha experiência com a UVVine	68.680	1
4	1230503	SUDESTE	MASCULINO	CASADO	1	27885.50	Funcionou bem e me atendeu no prazo certo a UV...	76.659	1

5 rows × 23 columns

```
Dimensão da base: 1,120,000 linhas e 23 colunas.
<class 'pandas.core.frame.DataFrame'>
Index: 1120000 entries, 0 to 1119999
Data columns (total 23 columns):
 #   Column                              Non-Null Count    Dtype
---  ------                              --------------    -----
 0   NOTA FISCAL                         1120000 non-null  int64
 1   REGIÃO                              1120000 non-null  object
 2   SEXO                                1120000 non-null  object
 3   ESTADO CIVIL                        1120000 non-null  object
 4   DEPENDENTES                         1120000 non-null  int64
 5   RENDA BRUTO (R$)                    1120000 non-null  float64
 6   OPINIÃO DO CLIENTE                  1120000 non-null  object
 7   NOTA DE SATISFAÇÃO (%)              1120000 non-null  float64
 8   MEAN: alcohol                       1120000 non-null  float64
 9   MEAN: malic_acid                    1120000 non-null  float64
 10  MEAN: ash                           1120000 non-null  float64
 11  MEAN: alcalinity_of_ash             1120000 non-null  float64
 12  MEAN: magnesium                     1120000 non-null  float64
 13  MEAN: total_phenols                 1120000 non-null  float64
 14  MEAN: flavanoids                    1120000 non-null  float64
 15  MEAN: nonflavanoid_phenols          1120000 non-null  float64
 16  MEAN: proanthocyanins               1120000 non-null  float64
 17  MEAN: color_intensity               1120000 non-null  float64
 18  MEAN: hue                           1120000 non-null  float64
 19  MEAN: od280/od315_of_diluted_wines  1120000 non-null  float64
 20  MEAN: proline                       1120000 non-null  float64
 21  TIPO DA CONTA                       1120000 non-null  object
 22  TOTAL (R$)                          1120000 non-null  float64
dtypes: float64(16), int64(2), object(5)
memory usage: 205.1+ MB
Não foram identificados valores ausentes na base de dados.
```

Workflow: Detalhamento das Atividades

Atividade A1: Estratificação amostral da população

O objetivo aqui é determinar o tamanho de amostra necessário para refletir com precisão a população, com base na margem de erro e no nível de confiança desejados. Em seguida, avaliamos o comportamento dos dados (checando outliers e rodando testes estatísticos) para dar suporte técnico às análises seguintes.

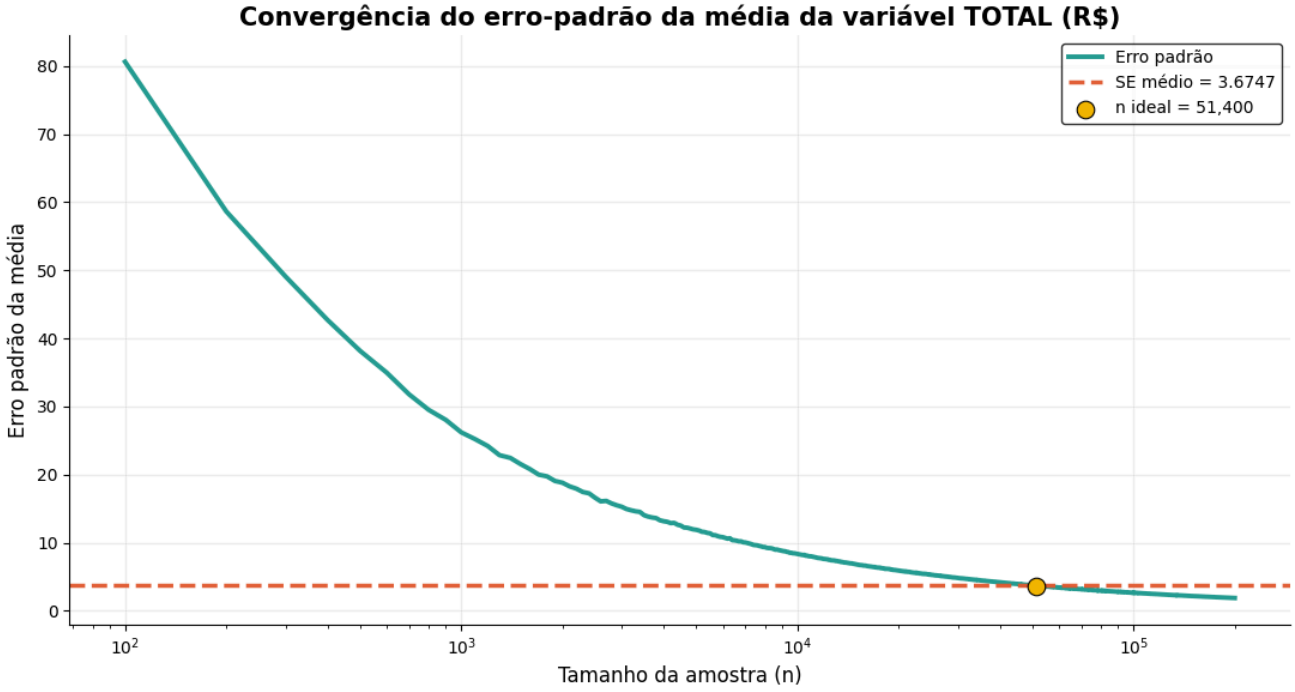
Atividade A1.1: Determinar o TAMANHO IDEAL da amostra

Para achar o tamanho ideal da amostra, analisamos a estabilização do erro-padrão da média para a variável TOTAL (R$). Fazemos isso simulando vários tamanhos de amostra e identificando o menor (n) que garanta um erro-padrão estimado menor ou igual ao erro-padrão médio.

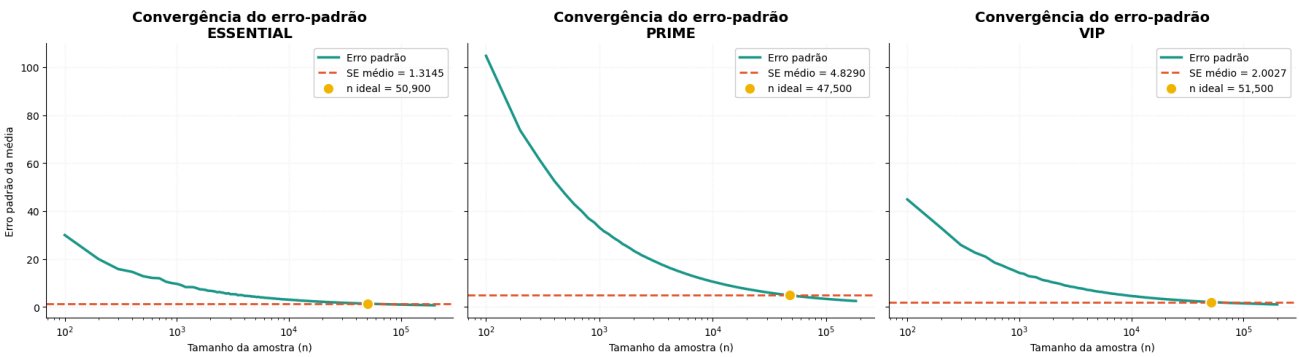
```
População disponível (N): 1,120,000
Média de TOTAL (R$): 810.27
Erro-padrão-médio: 3.674712
IC 95% da média: [803.07, 817.47]
Tamanho ideal da amostra: 51,400

Análise da amostragem por grupos concluída.
Grupos analisados: ESSENTIAL, PRIME, VIP
```

	Grupo	N_grupo	Média TOTAL (R$)	SE médio	IC95% inferior	IC95% superior	Tamanho ideal
0	ESSENTIAL	683501	403.8689	1.3145	401.2925	406.4454	50900
1	PRIME	183226	2192.3250	4.8290	2182.8602	2201.7899	47500
2	VIP	253273	907.1823	2.0027	903.2570	911.1077	51500



Os resultados mostram que o erro-padrão da média cai à medida que a amostra aumenta, estabilizando de forma progressiva ao longo das simulações. Aplicando o critério $SE(n) \leq SE$ médio, chegamos ao tamanho ideal de $n = 51.400$, que será o valor adotado nas próximas etapas do estudo.



Os gráficos por grupo mostram que o erro-padrão da média da variável `TOTAL (R$)` apresenta o mesmo comportamento de convergência observado na análise global em ESSENTIAL, PRIME e VIP. Em todos os segmentos, o erro-padrão cai de forma acentuada nas amostras menores, entre 100 e 1.000 observações, e se estabiliza a partir de aproximadamente 10.000, quando a curva passa a ficar próxima da linha do SE médio. O grupo PRIME apresentou a maior variabilidade inicial, com erro-padrão acima de 100 nas menores amostras e SE médio de 4,8290, o que indica maior dispersão dos valores de `TOTAL (R$)` nesse segmento. Já ESSENTIAL teve o menor SE médio (1,3145) e VIP ficou em posição intermediária (2,0027). O tamanho ideal da amostra ficou entre 47.500 e 51.500 observações (50.900 em ESSENTIAL, 47.500 em PRIME e 51.500 em VIP), faixa em que o ganho de precisão por observação adicional se torna marginal. Dessa forma, conclui-se que a estabilização do erro-padrão também ocorre de forma consistente dentro de cada segmento, sustentando a representatividade estatística da variável `TOTAL (R$)` tanto no nível global quanto no nível estratificado.

Atividade A1.2: Analisar os outliers

Nesta etapa, analisam-se as variáveis numéricas para identificar concentração excessiva de valores, extremos e problemas de qualidade dos dados. Em variáveis monetárias, valores altos podem representar clientes de maior valor e não devem ser tratados automaticamente como erro, enquanto valores negativos são incompatíveis com a natureza das variáveis e devem ser tratados como inconsistências. O foco é distinguir extremos plausíveis de negócio de registros inconsistentes, preservando a informação relevante para as análises estratificadas posteriores.

	Valor
count	1.120000e+06
mean	6.900971e+01
std	1.473340e+00
min	6.868000e+01
25%	6.868000e+01
50%	6.868000e+01
75%	6.868000e+01
max	9.261700e+01

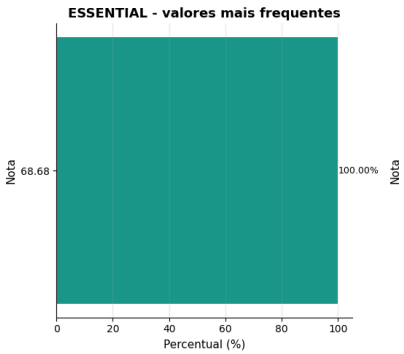
```
Quantidade de valores únicos: 212
```

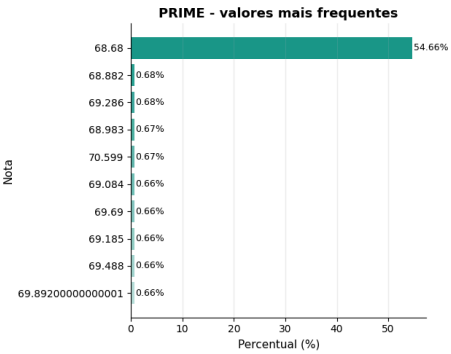
Frequência

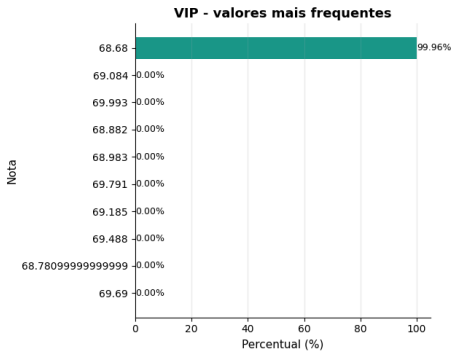
NOTA DE SATISFAÇÃO (%)	
68.680	1036840
68.882	1261
68.983	1241
69.286	1240
69.084	1224
70.599	1223
69.690	1220
69.185	1208
69.488	1207
69.892	1205

Percentual (%)

NOTA DE SATISFAÇÃO (%)	
68.680	92.575
68.882	0.113
68.983	0.111
69.286	0.111
69.084	0.109
70.599	0.109
69.690	0.109
69.185	0.108
69.488	0.108
69.892	0.108







```
=-=-=-=-Análise de outliers e qualidade dos dados=-=-=-=-.
Grupos analisados: ESSENTIAL, PRIME, VIP
Valores negativos foram tratados como problema de qualidade.
Valores extremos altos foram mantidos para preservar sinal de negócio.
```

	Grupo	Variável	N válidos	Negativos	% negativos	Q1	Q3	IQR	LI	
0	ESSENTIAL	RENDA BRUTO (R$)	683501	0	0.0	3197.49	3317.24	119.75	3017.86	3
1	ESSENTIAL	NOTA DE SATISFAÇÃO (%)	683501	0	0.0	68.68	68.68	0.00	68.68	
2	ESSENTIAL	TOTAL (R$)	683501	0	0.0	237.65	494.90	257.25	-148.22	
3	PRIME	RENDA BRUTO (R$)	183226	0	0.0	18749.63	23024.47	4274.83	12337.39	29
4	PRIME	NOTA DE SATISFAÇÃO (%)	183226	0	0.0	68.68	72.01	3.33	63.68	
5	PRIME	TOTAL (R$)	183226	0	0.0	1313.85	3017.84	1703.99	-1242.13	5
6	VIP	RENDA BRUTO (R$)	253273	0	0.0	7555.21	8002.71	447.50	6883.96	8
7	VIP	NOTA DE SATISFAÇÃO (%)	253273	0	0.0	68.68	68.68	0.00	68.68	
8	VIP	TOTAL (R$)	253273	0	0.0	559.82	1176.74	616.92	-365.56	2

	TIPO DA CONTA	n	n_unicos	media	dp	minimo	q1	mediana	q3	maximo	percen
0	ESSENTIAL	683501	1	68.6800	0.0000	68.68	68.68	68.68	68.680	68.680	
1	PRIME	183226	212	70.6944	3.1419	68.68	68.68	68.68	72.013	92.617	
2	VIP	253273	42	68.6807	0.0525	68.68	68.68	68.68	68.680	76.558	

```
Grupo: ESSENTIAL | Registros válidos: 683.501
```

Nota	Contagem	Percentual (%)	Acumulado (%)
68.680000	683,501	100.00	100.00

```
Grupo: PRIME | Registros válidos: 183.226
```

Nota	Contagem	Percentual (%)	Acumulado (%)
68.680000	100,160	54.66	54.66
68.882000	1,255	0.68	55.35
69.286000	1,239	0.68	56.03
68.983000	1,236	0.67	56.70
70.599000	1,221	0.67	57.37
69.690000	1,217	0.66	58.03
69.084000	1,217	0.66	58.70
69.185000	1,204	0.66	59.35
69.488000	1,203	0.66	60.01
69.892000	1,202	0.66	60.66

Grupo: VIP | Registros válidos: 253.273

Nota	Contagem	Percentual (%)	Acumulado (%)
68.680000	253,179	99.96	99.96
69.993000	7	0.00	99.97
69.084000	7	0.00	99.97
68.882000	6	0.00	99.97
68.983000	5	0.00	99.97
69.488000	4	0.00	99.97
68.781000	4	0.00	99.98
69.185000	4	0.00	99.98
69.791000	4	0.00	99.98
69.690000	3	0.00	99.98

Grupo: ESSENTIAL

OPINIÃO DO CLIENTE	Registros	Notas_validas	Media	Mediana	Desvio_padrao	Minimo	Maximo	N
Entrega foi boa e rápida na UVVine	105,579	105,579	68.68	68.68	0.00	68.68	68.68	
Funcionou bem e me atendeu no prazo certo a UVVine	105,452	105,452	68.68	68.68	0.00	68.68	68.68	
Fiquei satisfeito com o serviço da UVVine	105,288	105,288	68.68	68.68	0.00	68.68	68.68	
Serviço eficiente, recomendo o clube: UVVine	104,858	104,858	68.68	68.68	0.00	68.68	68.68	
Gostei do atendimento prestado pela UVVine	104,822	104,822	68.68	68.68	0.00	68.68	68.68	
Nada digno de nota com a UVVine	20,751	20,751	68.68	68.68	0.00	68.68	68.68	
Foi indiferente minha experiência com a UVVine	20,639	20,639	68.68	68.68	0.00	68.68	68.68	
Não tenho muito a dizer sobre a UVVine	20,570	20,570	68.68	68.68	0.00	68.68	68.68	
Compro exponenciamente, opinião neutra sobre UVVine	20,491	20,491	68.68	68.68	0.00	68.68	68.68	
Sem opinião formada sobre a UVVine	20,431	20,431	68.68	68.68	0.00	68.68	68.68	

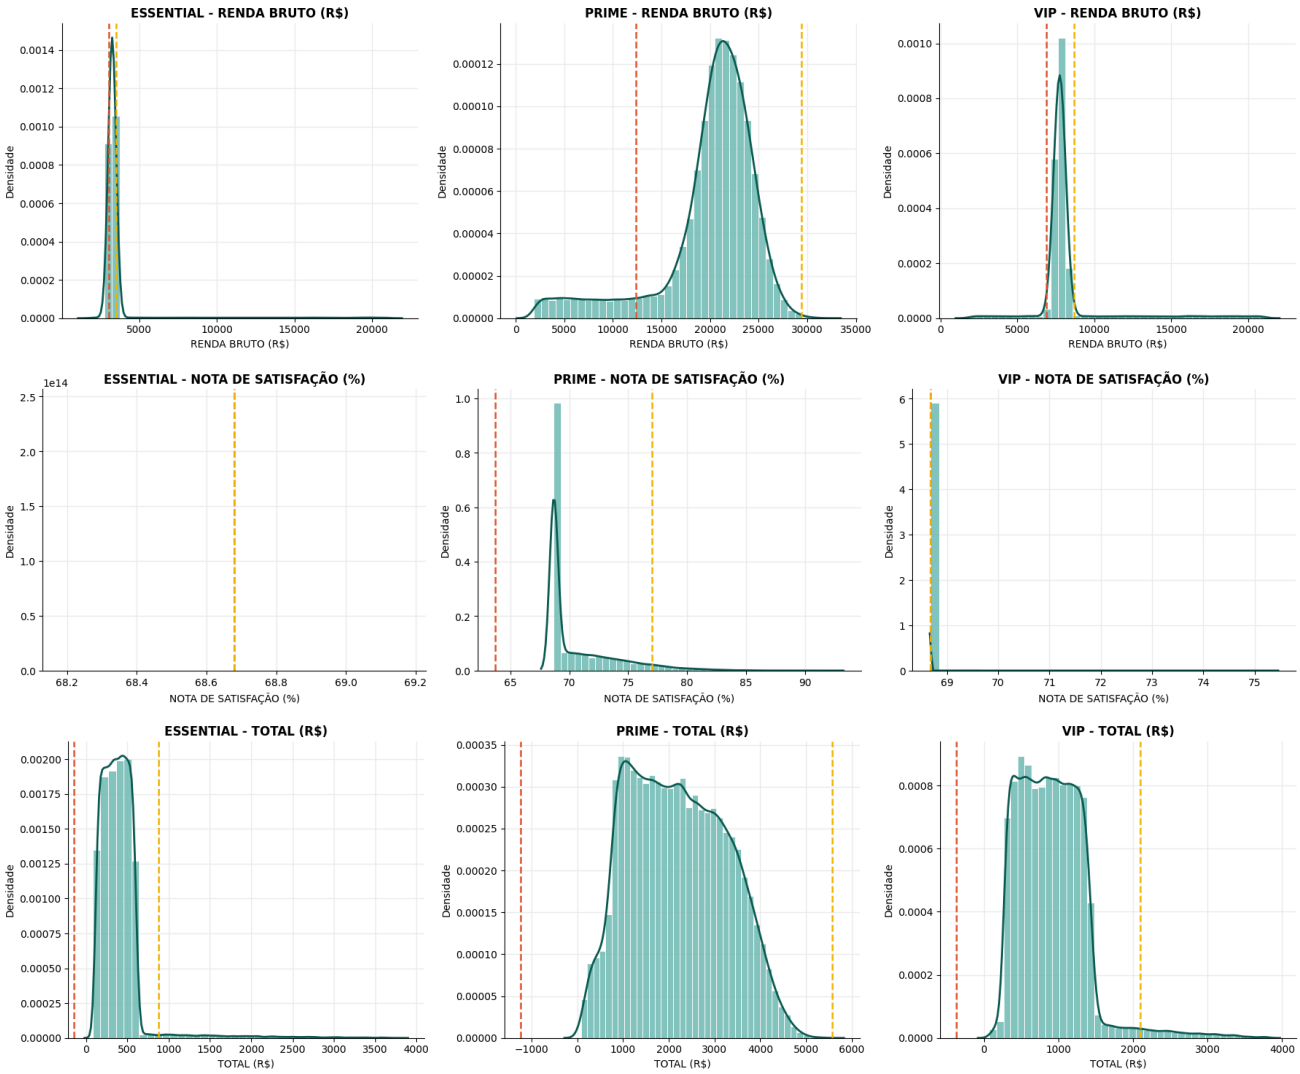
Grupo: PRIME

OPINIÃO DO CLIENTE	Registros	Notas_validas	Media	Mediana	Desvio_padrao	Minimo	Maximo	N
Gostei do atendimento prestado pela UVVine	28,484	28,484	70.73	68.68	3.18	68.68	92.21	
Fiquei satisfeito com o serviço da UVVine	28,390	28,390	70.70	68.68	3.16	68.68	91.10	
Serviço eficiente, recomendo o clube: UVVine	28,219	28,219	70.66	68.68	3.09	68.68	89.99	
Entrega foi boa e rápida na UVVine	28,165	28,165	70.70	68.68	3.14	68.68	89.49	
Funcionou bem e me atendeu no prazo certo a UVVine	28,147	28,147	70.69	68.68	3.15	68.68	89.28	
Nada digno de nota com a UVVine	5,531	5,531	70.71	68.68	3.14	68.68	87.06	
Foi indiferente minha experiência com a UVVine	5,487	5,487	70.64	68.68	3.09	68.68	87.97	
Sem opinião formada sobre a UVVine	5,485	5,485	70.71	68.68	3.14	68.68	88.98	
Compro exponenciamente, opinião neutra sobre UVVine	5,410	5,410	70.75	68.68	3.24	68.68	87.87	
Não tenho muito a dizer sobre a UVVine	5,376	5,376	70.65	68.68	3.13	68.68	87.06	

Grupo: VIP

OPINIÃO DO CLIENTE	Registros	Notas_validas	Media	Mediana	Desvio_padrao	Minimo	Maximo	N
Serviço eficiente, recomendo o clube: UVVine	39,161	39,161	68.68	68.68	0.06	68.68	75.45	
Entrega foi boa e rápida na UVVine	39,074	39,074	68.68	68.68	0.04	68.68	73.22	
Funcionou bem e me atendeu no prazo certo a UVVine	39,040	39,040	68.68	68.68	0.07	68.68	75.95	
Gostei do atendimento prestado pela UVVine	38,876	38,876	68.68	68.68	0.05	68.68	75.35	
Fiquei satisfeito com o serviço da UVVine	38,845	38,845	68.68	68.68	0.05	68.68	75.95	
Não tenho muito a dizer sobre a UVVine	7,603	7,603	68.68	68.68	0.00	68.68	68.78	
Nada digno de nota com a UVVine	7,577	7,577	68.68	68.68	0.05	68.68	71.61	
Sem opinião formada sobre a UVVine	7,567	7,567	68.68	68.68	0.09	68.68	76.56	
Foi indiferente minha experiência com a UVVine	7,547	7,547	68.68	68.68	0.05	68.68	72.72	
Compro exponenciamente, opinião neutra sobre UVVine	7,535	7,535	68.68	68.68	0.04	68.68	71.91	

	Variável	Qtd negativos	% negativos
0	RENDA BRUTO (R$)	0	0.0
1	NOTA DE SATISFAÇÃO (%)	0	0.0
2	TOTAL (R$)	0	0.0



A análise das variáveis monetárias mostrou perfis distintos entre os grupos. Em `RENDA BRUTO (R$)`, ESSENTIAL se concentra entre cerca de 3.000 e 3.500, com cauda direita muito rala que chega a cerca de 22.000, e tem 31.416 extremos altos (4,60%) e 3.847 baixos (0,56%). Em VIP, a concentração fica entre 7.500 e 8.000, com 21.532 extremos altos (8,50%) e 8.987 baixos (3,55%). PRIME é o grupo mais disperso: os limites do critério do IQR ficam em 12.337,39 e 29.436,72 e predominam os extremos baixos (17.795, ou 9,71%, contra apenas 166 altos), reflexo da cauda à esquerda observada no gráfico.

Em `TOTAL (R$)`, ESSENTIAL e VIP concentram a maior parte dos valores em faixas curtas (cerca de 100 a 600 e de 300 a 1.500) e têm cauda direita longa, que chega a cerca de 4.000, enquanto PRIME se distribui de forma ampla, até cerca de 5.800. Como os limites inferiores são negativos nos três grupos, não há extremos baixos. Os extremos altos aparecem em ESSENTIAL (19.740, ou 2,89%) e em VIP (5.761, ou 2,27%), e PRIME não tem extremos. Como esses valores podem representar clientes de maior valor, foram mantidos na base, e não houve valores negativos em nenhuma das três variáveis.

A NOTA DE SATISFAÇÃO (%) apresentou forte concentração em 68,68, valor presente em 92,575% dos registros da base. Em ESSENTIAL, todos os registros têm essa nota, e em VIP ela responde por 99,96% das observações (desvio padrão de 0,0525, com apenas 94 extremos altos). Apenas PRIME apresenta variação relevante, com média de 70,6944, desvio padrão de 3,1419 e 11.036 extremos altos (6,02%). Como o IQR é zero em ESSENTIAL e em VIP, os limites LI e LS coincidem com 68,68 e o critério perde o sentido nesses grupos.

Contudo, a nota não acompanha a opinião registrada. Entre as dez opiniões mais frequentes, ESSENTIAL tem a mesma nota (68,68) em todas, VIP varia no máximo de 68,68 a 76,56, e em PRIME as médias ficam entre 70,64 e 70,75 independentemente de a opinião ser positiva ou neutra. Dessa forma, a variável tem pouca utilidade como medida contínua de satisfação, e as análises seguintes usarão OPINIÃO DO CLIENTE.

Atividade A1.3: Testes de Hipóteses (Link)

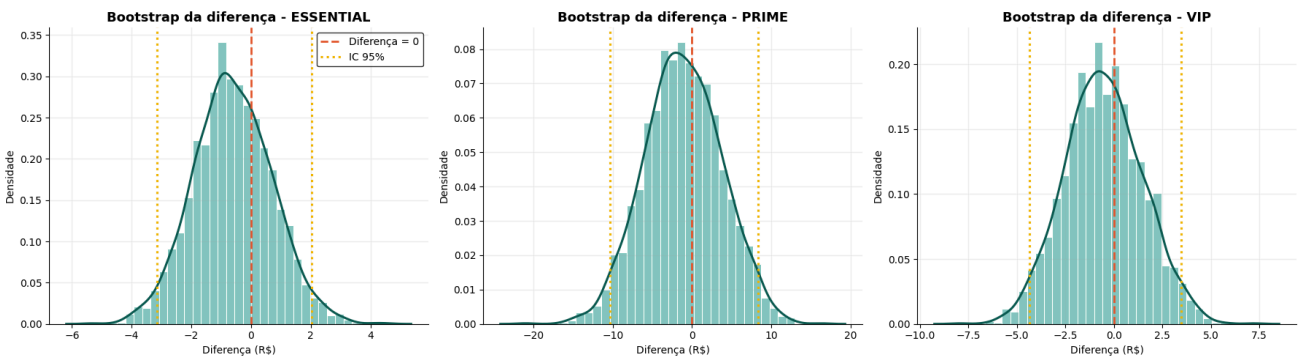
Na parte de hipóteses, aplicam-se testes para analisar o comportamento estatístico da variável TOTAL (R$) e confirmar a estabilidade da amostragem estratificada nos grupos ESSENTIAL, PRIME e VIP.

A validação é feita separadamente em cada grupo, usando o tamanho ideal de amostra definido na Atividade A1.1. Em cada segmento, o processo gera reamostragens sucessivas, divide cada uma em train, validation e test, e aceita somente as rodadas em que as três partições ficam dentro do intervalo de confiança de referência da média do grupo.

Como complemento, o teste de Shapiro-Wilk é aplicado a amostras controladas para verificar a normalidade, e o bootstrap é usado para medir a estabilidade da diferença entre a média amostral e a média populacional de cada grupo. Assim, a etapa busca confirmar se a amostragem escolhida se mantém estatisticamente consistente quando o procedimento é repetido várias vezes.

```
Análise de hipóteses estratificada concluída.
ESSENTIAL: 20/20 rodadas válidas (taxa de aceite = 39.22%)
PRIME: 20/20 rodadas válidas (taxa de aceite = 57.14%)
VIP: 20/20 rodadas válidas (taxa de aceite = 29.85%)
```

	Grupo	N	n ideal	Shapiro W	Shapiro p-valor	Decisão normalidade	Rodadas válidas	Tentativas	Taxa de aceite (%)	IC infer
0	ESSENTIAL	683501	50900	0.5631	0.0	Rejeita normalidade	20	51	39.2157	401.2(
1	PRIME	183226	47500	0.9802	0.0	Rejeita normalidade	20	35	57.1429	2182.8
2	VIP	253273	51500	0.8992	0.0	Rejeita normalidade	20	67	29.8507	903.2



Grupo: ESSENTIAL

	rodada	media_amostra	media_train	media_validation	media_test	diff_obs	ci_boot_diff_inf	c
0	1	403.2656	403.7510	402.8905	402.1842	-0.6034	-3.1417	
1	2	405.0540	404.2499	406.4663	406.0538	1.1851	-1.3508	
2	3	404.5820	404.2738	405.5251	404.5632	0.7130	-1.8396	
3	4	403.1235	402.8176	404.2304	402.9346	-0.7454	-3.3438	
4	5	402.8676	402.7423	403.8028	402.3083	-1.0013	-3.5309	
5	6	404.6619	404.5657	404.9670	404.6457	0.7930	-1.8122	
6	7	404.4904	404.3478	403.1325	406.2759	0.6214	-2.0048	
7	8	403.9091	404.9390	402.7641	401.9645	0.0402	-2.4368	
8	9	403.1658	402.4797	405.1443	403.2454	-0.7031	-3.2444	
9	10	404.2594	403.9278	403.4474	406.0659	0.3904	-2.1882	
10	11	404.2028	405.1640	402.6249	402.8973	0.3339	-2.4130	
11	12	401.6958	401.3381	402.3999	402.0648	-2.1732	-4.5412	
12	13	404.8795	405.5706	402.4168	405.2687	1.0105	-1.6534	
13	14	404.6439	406.3603	401.4808	402.6579	0.7750	-1.8345	
14	15	403.1137	402.5300	405.3694	402.6090	-0.7552	-3.3560	
15	16	403.6354	402.9647	405.7891	403.4936	-0.2336	-2.9022	
16	17	405.0410	405.0705	405.5460	404.4476	1.1721	-1.4217	
17	18	403.5154	404.4743	401.5740	402.5800	-0.3536	-2.9495	
18	19	403.6708	403.1613	404.4981	404.3721	-0.1981	-2.7655	
19	20	403.5439	402.2337	404.9622	406.0564	-0.3250	-3.0599	

Grupo: PRIME

	rodada	media_amostra	media_train	media_validation	media_test	diff_obs	ci_boot_diff_inf	c
0	1	2191.1819	2192.1508	2188.8325	2190.6247	-1.1431	-10.3250	
1	2	2191.2504	2191.1533	2189.5115	2193.2808	-1.0746	-10.3566	
2	3	2190.2394	2191.2229	2191.4472	2186.0812	-2.0856	-11.1376	
3	4	2189.1868	2188.6207	2195.9661	2184.1060	-3.1382	-12.9257	
4	5	2189.7576	2184.7581	2193.0941	2201.4194	-2.5675	-11.7961	
5	6	2194.6881	2195.2380	2188.5033	2199.2235	2.3631	-7.0520	
6	7	2194.2620	2191.8550	2199.9204	2195.8246	1.9370	-7.2250	
7	8	2195.8887	2196.1527	2201.1352	2189.8499	3.5636	-5.8851	
8	9	2193.3938	2198.5792	2187.5192	2183.7125	1.0688	-8.3169	
9	10	2198.4515	2197.7727	2197.5827	2201.3565	6.1264	-3.1295	
10	11	2186.3986	2183.0942	2191.1943	2191.5162	-5.9264	-15.1896	
11	12	2190.8623	2189.7084	2197.6452	2187.5409	-1.4628	-10.9169	
12	13	2192.9760	2188.5285	2200.6332	2198.6615	0.6510	-9.0480	
13	14	2194.8229	2197.7111	2186.7680	2194.2134	2.4979	-7.0829	
14	15	2190.1666	2192.7646	2185.4793	2187.0601	-2.1584	-11.2929	
15	16	2190.3399	2188.3099	2195.2467	2191.5230	-1.9852	-11.0603	
16	17	2195.1484	2198.0023	2192.4473	2189.2878	2.8234	-6.9409	
17	18	2192.2688	2190.0795	2196.8588	2194.2469	-0.0562	-9.4308	
18	19	2187.2043	2187.6571	2184.5543	2188.4958	-5.1207	-14.4064	
19	20	2193.6779	2192.8047	2201.0203	2188.9552	1.3529	-8.3372	

Grupo: VIP

	rodada	media_amostra	media_train	media_validation	media_test	diff_obs	ci_boot_diff_inf	c
0	1	906.6898	906.3039	907.5724	906.9648	-0.4926	-4.3377	
1	2	906.5872	905.3705	908.1548	908.6699	-0.5951	-4.5561	
2	3	907.3504	906.6772	905.6305	911.0897	0.1680	-3.7497	
3	4	906.8480	907.3331	907.5523	904.6881	-0.3344	-4.3348	
4	5	906.3428	907.5977	903.6892	905.2318	-0.8395	-4.7675	
5	6	906.9958	906.6091	905.1839	909.9674	-0.1866	-3.9854	
6	7	906.3478	906.9727	903.5174	907.3037	-0.8345	-4.6742	
7	8	905.7473	904.9664	905.3795	908.4581	-1.4350	-5.3472	
8	9	907.2492	906.2329	909.9706	907.5767	0.0669	-3.8040	
9	10	907.3552	907.5024	905.7720	908.4970	0.1729	-3.7023	
10	11	906.2492	906.9500	905.9525	904.4435	-0.9331	-4.7348	
11	12	906.3522	905.4157	905.3512	910.1629	-0.8301	-4.8083	
12	13	908.3110	908.9259	905.2207	909.5567	1.1287	-2.7034	
13	14	908.2251	907.7672	908.8182	909.0055	1.0427	-2.7723	
14	15	905.1795	904.7539	906.0006	905.6353	-2.0028	-6.0665	
15	16	906.8252	906.2704	910.1451	905.1696	-0.3572	-4.2212	
16	17	907.7657	908.9099	906.7977	905.3013	0.5834	-3.2615	
17	18	909.9555	910.6188	908.6201	909.3009	2.7731	-1.0847	
18	19	907.3620	907.5446	909.6030	904.5732	0.1796	-3.6160	
19	20	907.2307	906.6109	907.5893	908.7314	0.0483	-3.8718	

O teste de Levene foi usado para verificar, em cada grupo (ESSENTIAL, PRIME e VIP), se as partições TRAIN, VALIDATION e TEST têm variâncias equivalentes na variável TOTAL (R$) nas rodadas válidas da amostragem estratificada.

A leitura é feita grupo a grupo. Um p-valor acima de 0,05 não rejeita a hipótese nula de homogeneidade de variâncias, o que indica que a dispersão das partições é estatisticamente semelhante. Um p-valor abaixo de 0,05 rejeita essa hipótese e aponta diferença de variabilidade entre pelo menos duas partições.

As estatísticas descritivas de cada partição (média, mediana e intervalo interquartil) complementam o teste, ao mostrar como TRAIN, VALIDATION e TEST se comportam dentro de cada segmento. Assim, a análise confirma se a estabilidade da amostragem estratificada também se mantém na dispersão dos dados, o que reforça a consistência da validação por grupos.

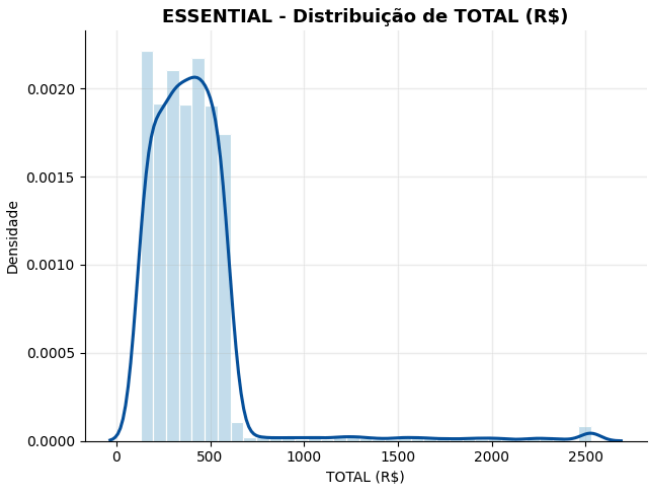
A1.3.1: Teste de Normalidade

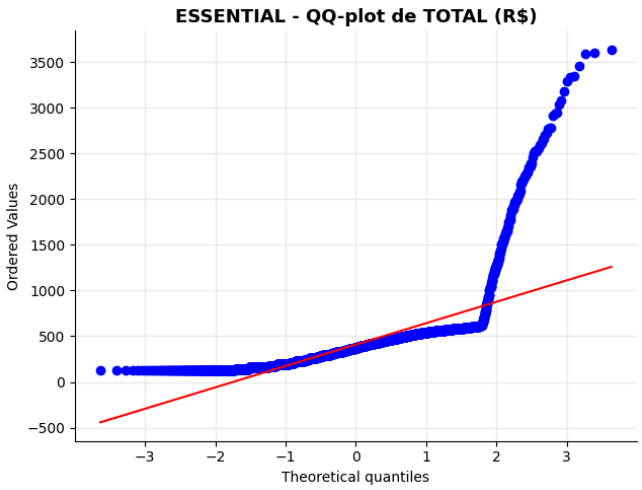
Nesta etapa, verifica-se se a variável TOTAL (R$) tem comportamento compatível com a distribuição normal em cada um dos grupos ESSENTIAL, PRIME e VIP. Para isso, aplica-se o teste de Shapiro-Wilk a amostras controladas de cada grupo, com apoio de histogramas e QQ-plots.

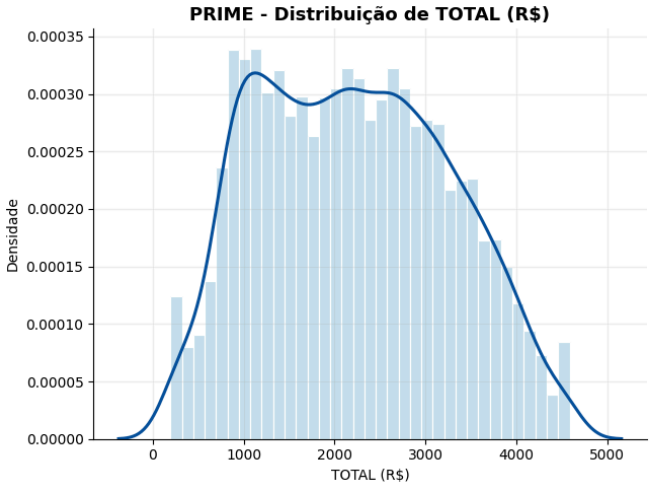
A análise é feita no nível estratificado porque a base completa mistura grupos com distribuições bem diferentes, o que dificultaria o diagnóstico. Por isso, a normalidade é avaliada separadamente em cada segmento, em linha com a validação amostral realizada na Atividade A1.3.

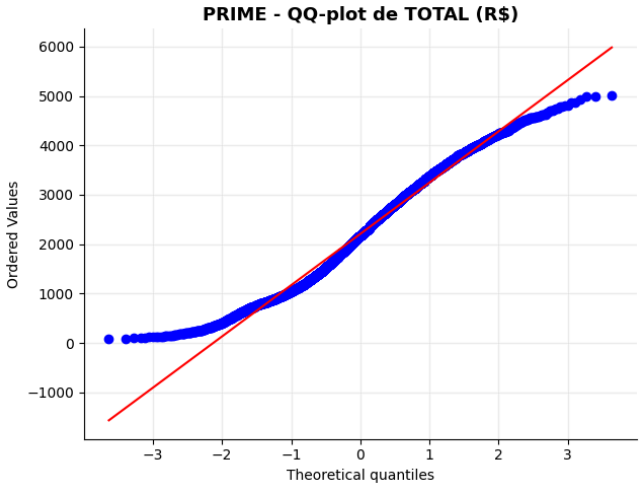
```
Teste de normalidade por grupos concluído.
Variável analisada: TOTAL (R$)
Grupos analisados: 3
```

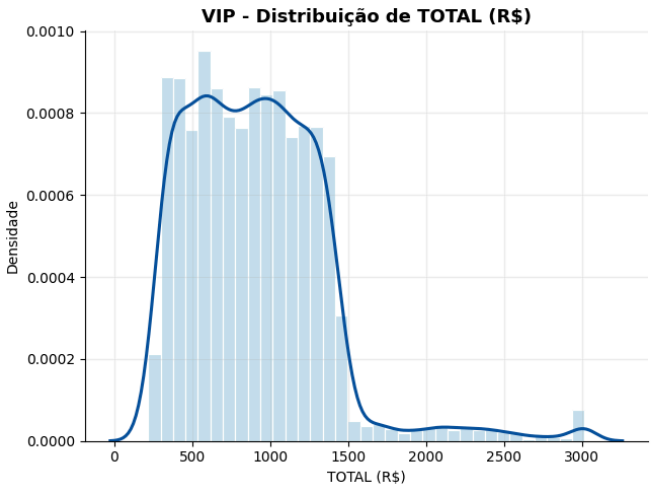
	Grupo	N população	n amostra	Shapiro W	Shapiro p-valor	Decisão normalidade	Média amostra	DP amostra	Assimetri
0	ESSENTIAL	683501	5000	0.5631	0.0	Rejeita normalidade	409.0829	311.8388	4.984
1	PRIME	183226	5000	0.9802	0.0	Rejeita normalidade	2209.1934	1047.3862	0.176
2	VIP	253273	5000	0.8992	0.0	Rejeita normalidade	903.7862	451.3063	1.487

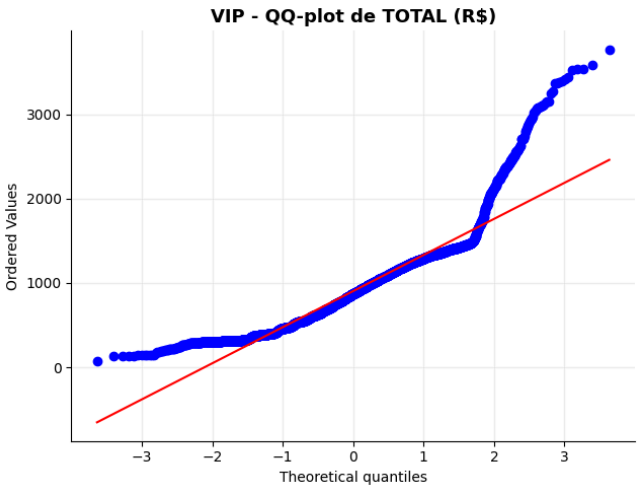


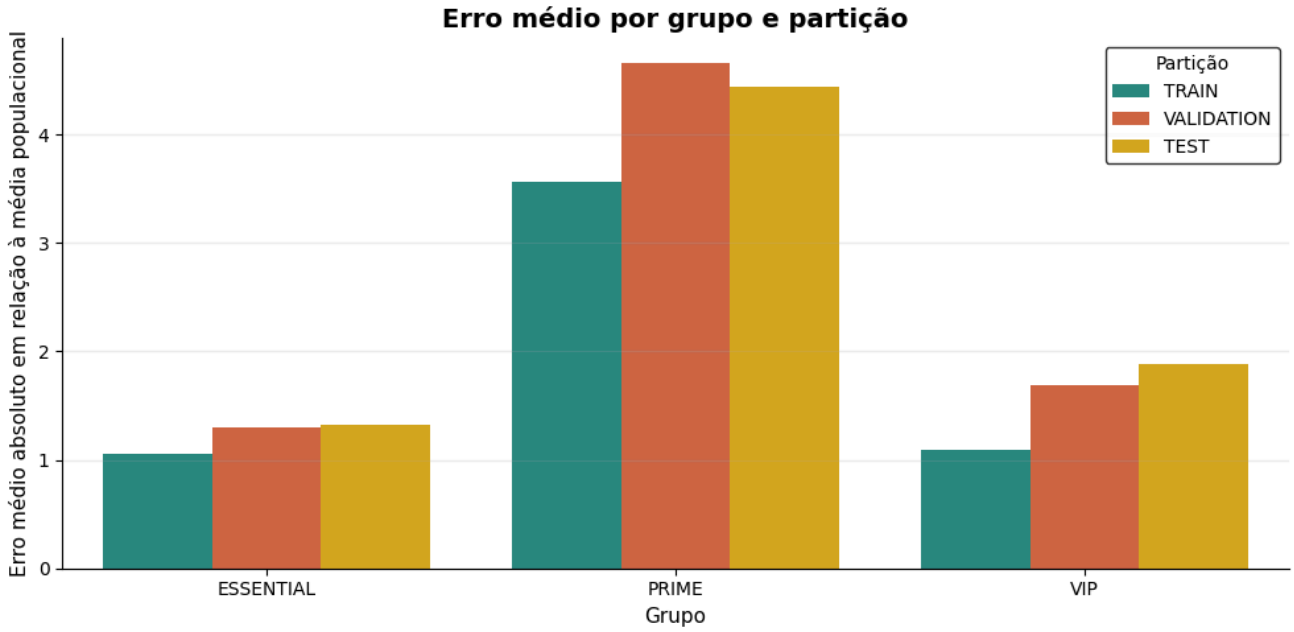












	Grupo	Variável	N	Valores únicos	% únicos	Moda	% moda	Top 5 %
0	ESSENTIAL	RENDA BRUTO (R$)	683501	75707	11.0764	3239.27	0.0082	0.0379
1	ESSENTIAL	TOTAL (R$)	683501	71459	10.4548	132.81	0.0101	0.0493
2	PRIME	RENDA BRUTO (R$)	183226	163609	89.2936	17334.83	0.0038	0.0175
3	PRIME	TOTAL (R$)	183226	145418	79.3654	791.32	0.0038	0.0169
4	VIP	RENDA BRUTO (R$)	253273	141141	55.7268	7739.83	0.0043	0.0205
5	VIP	TOTAL (R$)	253273	112470	44.4066	313.16	0.0055	0.0265

	Grupo	Variável	P1	P5	P25	P50	P75	P95	P99
0	ESSENTIAL	RENDA BRUTO (R$)	3047.00	3113.10	3197.49	3256.07	3317.24	3462.78	17165.86
1	ESSENTIAL	TOTAL (R$)	128.60	134.70	237.65	367.45	494.90	599.32	1952.05
2	PRIME	RENDA BRUTO (R$)	2949.32	7179.14	18749.63	21066.16	23024.47	25612.93	27349.16
3	PRIME	TOTAL (R$)	257.26	649.91	1313.85	2130.85	3017.84	3948.15	4427.23
4	VIP	RENDA BRUTO (R$)	3274.93	7146.19	7555.21	7770.99	8002.71	13821.61	19718.64
5	VIP	TOTAL (R$)	286.50	316.66	559.82	869.24	1176.74	1469.09	2681.15

Os resultados da A1.3.1 rejeitaram a hipótese de normalidade da variável `TOTAL (R$)` nos grupos ESSENTIAL, PRIME e VIP, pois os p-valores do teste de Shapiro-Wilk ficaram abaixo de 0,05 nos três casos (W de 0,5631 em ESSENTIAL, 0,8992 em VIP e 0,9802 em PRIME). Os histogramas e os QQ-plots confirmaram o diagnóstico, com desvios claros em relação ao comportamento esperado sob normalidade.

Em ESSENTIAL, a distribuição apresentou assimetria positiva acentuada (4,9840) e curtose elevada (33,9362), o que indica forte concentração em valores baixos e uma cauda superior longa. Em VIP, o comportamento também foi assimétrico à direita, com assimetria de 1,4875 e curtose de 4,8874, mostrando concentração central acompanhada de valores extremos superiores. PRIME foi o grupo mais próximo de um formato regular, com assimetria baixa (0,1769) e curtose negativa (-0,8457), embora sem aderência à normalidade segundo o teste formal.

A análise complementar mostrou que essa não normalidade não decorre de travamento artificial dos valores monetários: `TOTAL (R$)` tem 71.459 valores únicos em ESSENTIAL, 145.418 em PRIME e 112.470 em VIP, e a moda representa no máximo 0,0101% dos registros. Os percentis reforçaram a presença de caudas superiores relevantes em ESSENTIAL e VIP: em ESSENTIAL, a mediana é de 367,45 e o percentil 99 chega a 1.952,05, e em VIP, a mediana é de 869,24 e o percentil 99 chega a 2.681,15.

O gráfico de erro médio por grupo e partição mostrou que as amostras validadas ficaram próximas da média populacional de cada segmento. ESSENTIAL teve os menores erros médios absolutos, entre 1,0594 (TRAIN) e 1,3274 (TEST). VIP teve erros intermediários, entre 1,0898 e 1,8791. PRIME concentrou os maiores desvios, sobretudo na partição VALIDATION (4,6545), indicando maior variabilidade interna mesmo após o critério de aceitação das amostras. Em todos os grupos, o erro ficou bem abaixo de 1% da média populacional.

Conclui-se então que a variável `TOTAL (R$)` não segue distribuição normal mesmo no nível estratificado, mas a validação por grupos produziu partições com erro médio controlado em relação à média populacional. Assim, a estratificação melhora a consistência da amostragem, ainda que não elimine a assimetria e as caudas longas características da variável.

A1.3.2: Teste de Independência

Nesta etapa, verifica-se, em cada grupo (`ESSENTIAL` , `PRIME` e `VIP`), se o fato de uma partição (`TRAIN` , `VALIDATION` ou `TEST`) ficar dentro do intervalo de confiança depende de qual partição se trata. Para isso, aplica-se o teste Qui-Quadrado de independência, com apoio do tamanho de efeito, das frequências esperadas e dos resíduos padronizados.

A finalidade é identificar se alguma partição se comporta de modo sistematicamente diferente das outras na validação das reamostragens, o que seria um sinal de instabilidade do procedimento de amostragem dentro dos grupos.

```
Teste de independência por grupos concluído.
Grupos analisados: 3
```

	Grupo	N válidos	Qui-quadrado	gl	p-valor	Decisão	Cramér's V	Interpretação	% esperado < 5
0	ESSENTIAL	153	15.6923	2	0.0004	Rejeita H0	0.3203	Efeito forte	0.0
1	PRIME	105	9.4382	2	0.0089	Rejeita H0	0.2998	Efeito moderado	0.0
2	VIP	201	19.1200	2	0.0001	Rejeita H0	0.3084	Efeito forte	0.0

```
Grupo: ESSENTIAL
```

Status IC	Dentro do IC	Fora do IC
Partição		
TEST	32	19
TRAIN	48	3
VALIDATION	34	17

	Partição	Status IC	|Resíduo padronizado|
0	TRAIN	Fora do IC	2.773501
1	TEST	Fora do IC	1.664101
2	TRAIN	Dentro do IC	1.622214
3	VALIDATION	Fora do IC	1.109400
4	TEST	Dentro do IC	0.973329
5	VALIDATION	Dentro do IC	0.648886

```
Grupo: PRIME
```

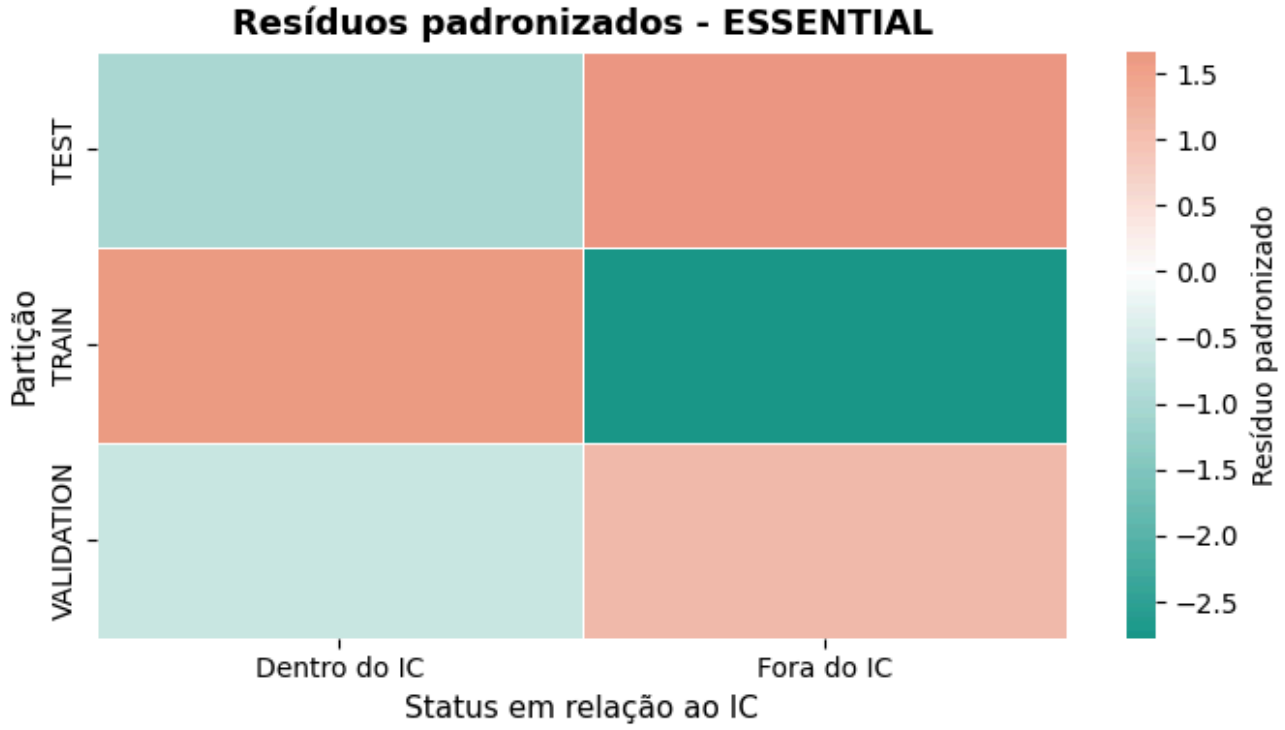
Status IC	Dentro do IC	Fora do IC
Partição		
TEST	27	8
TRAIN	35	0
VALIDATION	27	8

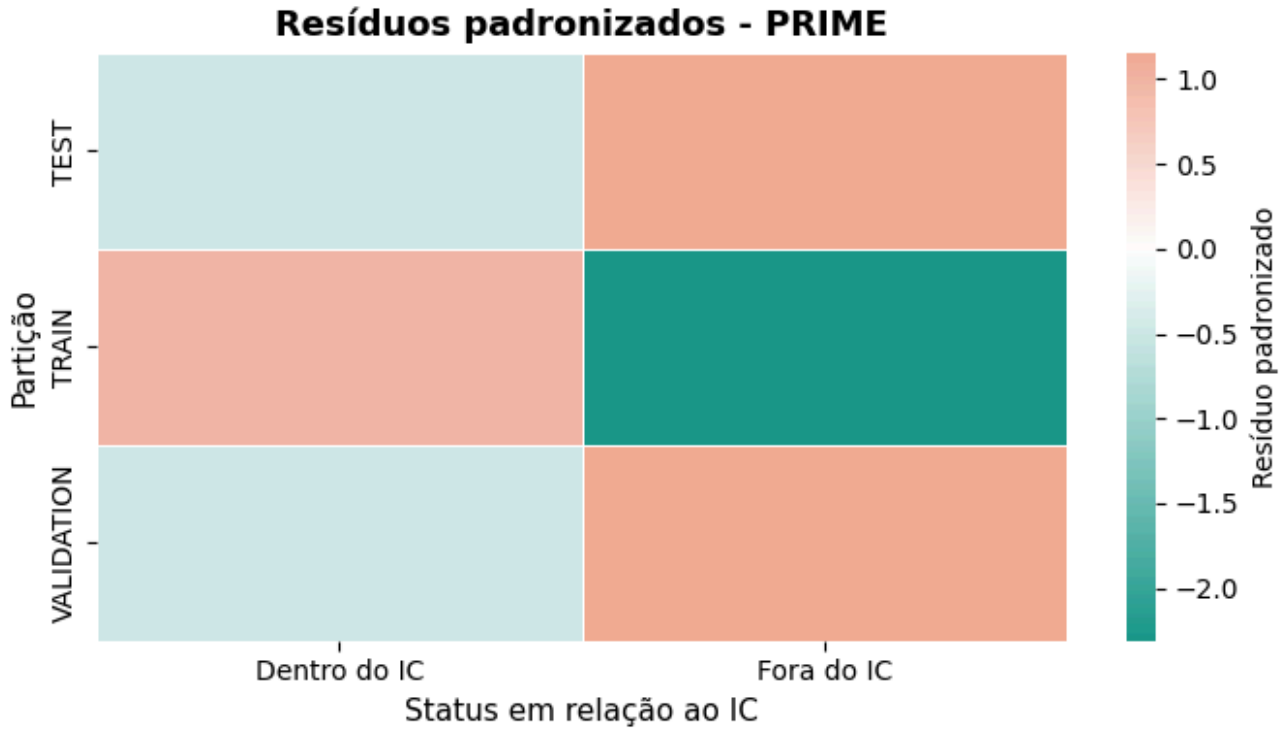
	Partição	Status IC	|Resíduo padronizado|
0	TRAIN	Fora do IC	2.309401
1	TEST	Fora do IC	1.154701
2	VALIDATION	Fora do IC	1.154701
3	TRAIN	Dentro do IC	0.979184
4	TEST	Dentro do IC	0.489592
5	VALIDATION	Dentro do IC	0.489592

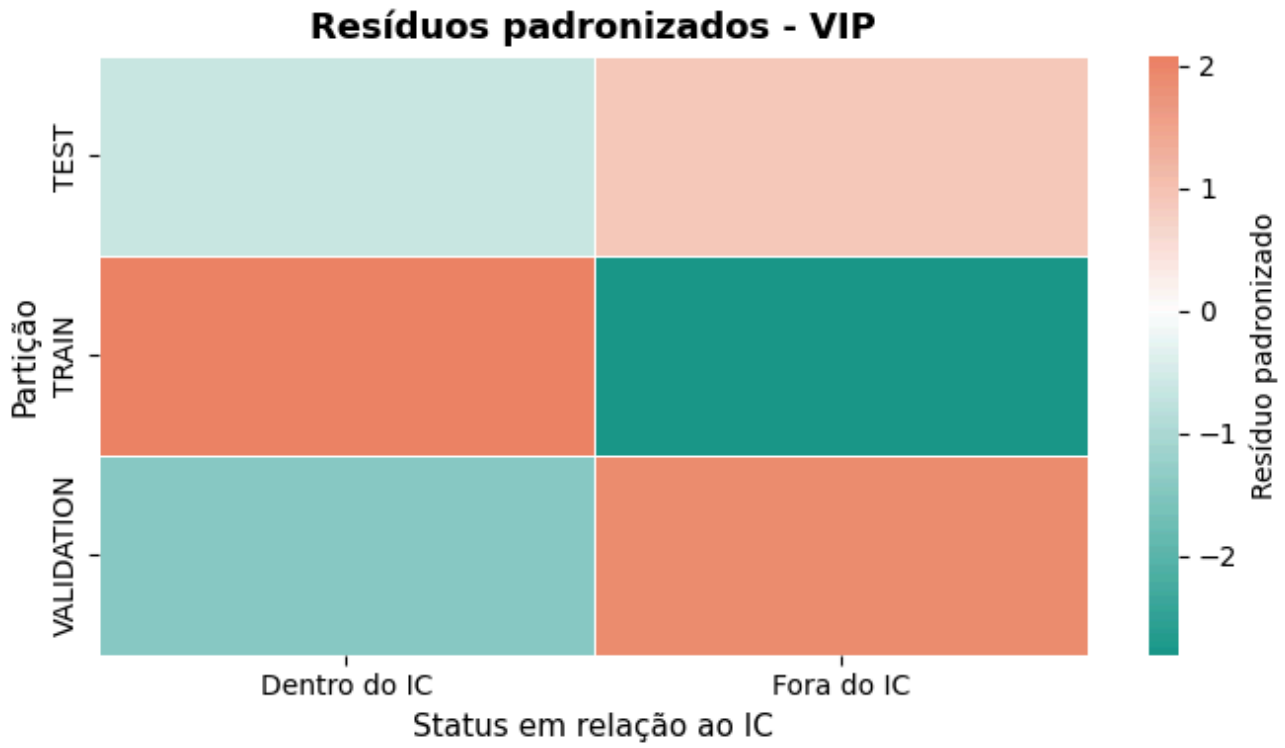
```
Grupo: VIP
```

Status IC	Dentro do IC	Fora do IC
Partição		
TEST	39	28
TRAIN	57	10
VALIDATION	34	33

	Partição	Status IC	|Resíduo padronizado|
0	TRAIN	Fora do IC	2.809274
1	TRAIN	Dentro do IC	2.076116
2	VALIDATION	Fora do IC	1.918528
3	VALIDATION	Dentro do IC	1.417835
4	TEST	Fora do IC	0.890745
5	TEST	Dentro do IC	0.658281


Resíduos padronizados - ESSENTIAL
Partição
TEST
TRAIN
VALIDATION
Dentro do IC
Fora do IC
Status em relação ao IC
Resíduo padronizado
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
−2.0
−2.5


Resíduos padronizados - PRIME
Partição
TEST
TRAIN
VALIDATION
Dentro do IC
Fora do IC
Status em relação ao IC
Resíduo padronizado
1.0
0.5
0.0
−0.5
−1.0
−1.5
−2.0



Grupo: ESSENTIAL - percentuais por partição

Status IC	Dentro do IC	Fora do IC
Partição		
TEST	62.75	37.25
TRAIN	94.12	5.88
VALIDATION	66.67	33.33

Grupo: PRIME - percentuais por partição

Status IC	Dentro do IC	Fora do IC
Partição		
TEST	77.14	22.86
TRAIN	100.00	0.00
VALIDATION	77.14	22.86

Grupo: VIP - percentuais por partição

Status IC	Dentro do IC	Fora do IC
Partição		
TEST	58.21	41.79
TRAIN	85.07	14.93
VALIDATION	50.75	49.25

O teste Qui-Quadrado mostrou associação estatisticamente significativa entre a partição (TRAIN, VALIDATION ou TEST) e o status em relação ao intervalo de confiança nos três grupos, com p =

0,0004 em ESSENTIAL, p = 0,0089 em PRIME e p = 0,0001 em VIP. Nenhuma frequência esperada ficou abaixo de 5, o que valida o uso do teste, e a hipótese nula de independência foi rejeitada em todos os casos.

O Cramér's V indicou efeito forte em ESSENTIAL (0,3203) e em VIP (0,3084) e efeito moderado em PRIME (0,2998, muito próximo do limite de 0,30). Portanto, as partições não se comportaram de forma equivalente: a chance de ficar dentro ou fora do intervalo de confiança mudou conforme a partição.

As tabelas de contingência e os resíduos padronizados mostram que TRAIN foi a partição mais estável. Em ESSENTIAL, TRAIN ficou dentro do intervalo em 94,12% das tentativas, contra 62,75% em TEST e 66,67% em VALIDATION. Em PRIME, os percentuais foram 100%, 77,14% e 77,14%, e em VIP, 85,07%, 58,21% e 50,75%, respectivamente. Os maiores resíduos padronizados em módulo (2,77 em ESSENTIAL, 2,31 em PRIME e 2,81 em VIP) correspondem a TRAIN fora do intervalo, que ocorreu menos vezes que o esperado. Em VIP, VALIDATION teve o pior desempenho, com cerca de metade das tentativas dentro do intervalo. Uma explicação possível é o tamanho das partições: TRAIN reúne 60% da amostra e as outras duas, 20% cada, e por isso a média de TRAIN tende a ser mais estável.

Conclui-se que, em cada grupo, a permanência dentro do intervalo de confiança depende da partição considerada. Embora a estratégia estratificada tenha gerado as rodadas válidas, as partições não têm o mesmo nível de estabilidade, com vantagem sistemática de TRAIN sobre TEST e VALIDATION.

A1.3.3: Teste de Distribuição

Nesta etapa, verifica-se, em cada grupo (`ESSENTIAL` , `PRIME` e `VIP`), se as partições `TRAIN` , `VALIDATION` e `TEST` possuem variâncias semelhantes em relação à variável `TOTAL (R$)` . Para essa análise, é aplicado o teste de Levene, utilizando a mediana como medida central, juntamente com estatísticas descritivas e gráficos que permitem observar a distribuição das médias entre as diferentes partições.

O propósito é identificar se a dispersão dos dados entre as partições é estatisticamente equivalente dentro de cada segmento, ajudando a avaliar a consistência e a estabilidade do processo de amostragem estratificada.

```
Teste de distribuição por grupos concluído.
Grupos analisados: 3
```

	Grupo	Estatística de Levene	p-valor	Decisão
0	ESSENTIAL	0.6668	0.5173	Não rejeita H0
1	PRIME	0.8656	0.4262	Não rejeita H0
2	VIP	3.0489	0.0552	Não rejeita H0

```
Grupo: ESSENTIAL
```

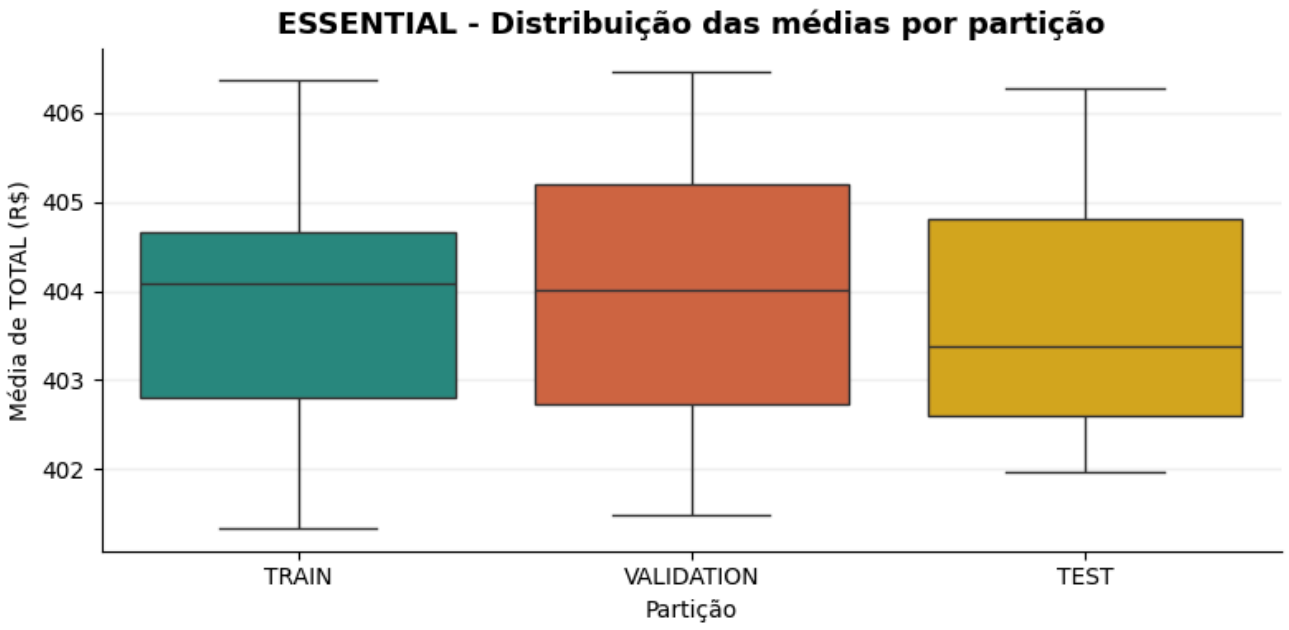
	Partição	n	media	dp	mediana	q1	q3	iqr
0	TRAIN	20	403.8481	1.2827	404.0889	402.7987	404.6590	1.8603
1	VALIDATION	20	403.9516	1.4929	404.0166	402.7293	405.2006	2.4713
2	TEST	20	403.8345	1.5045	403.3695	402.6018	404.8014	2.1996

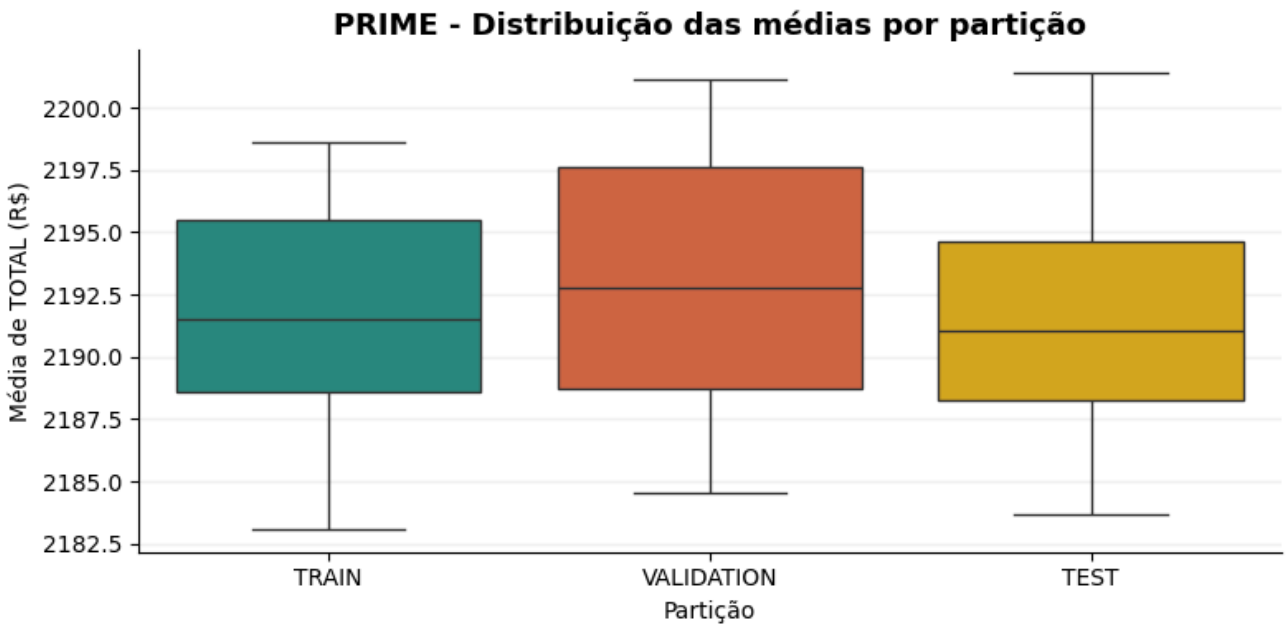
Grupo: PRIME

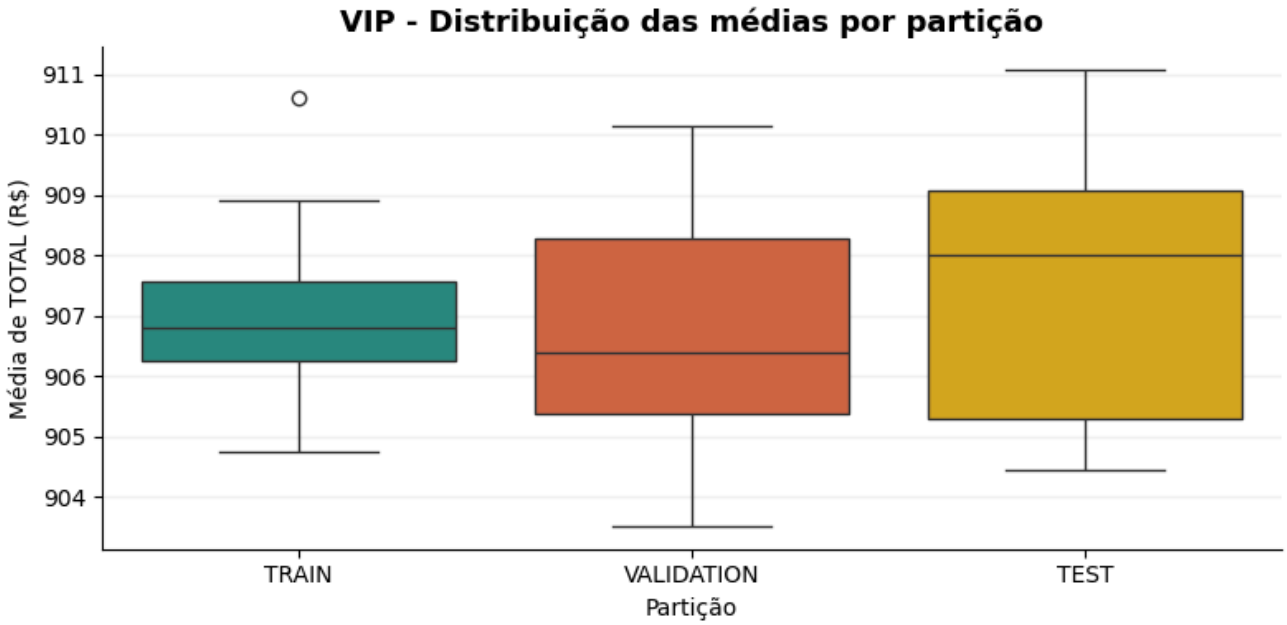
	Partição	n	media	dp	mediana	q1	q3	iqr
0	TRAIN	20	2191.8082	4.4218	2191.5389	2188.5977	2195.4667	6.8690
1	VALIDATION	20	2193.2680	5.4244	2192.7707	2188.7502	2197.5983	8.8481
2	TEST	20	2191.8490	5.3547	2191.0705	2188.2571	2194.6413	6.3842

Grupo: VIP

	Partição	n	media	dp	mediana	q1	q3	iqr
0	TRAIN	20	906.9667	1.4216	906.8136	906.2610	907.5579	1.2969
1	VALIDATION	20	906.8261	1.9675	906.3992	905.3724	908.2711	2.8987
2	TEST	20	907.5164	2.1229	908.0174	905.2839	909.0793	3.7954







O teste de Levene não rejeitou a hipótese nula de homogeneidade de variâncias em nenhum dos grupos: p = 0,5173 em ESSENTIAL, p = 0,4262 em PRIME e p = 0,0552 em VIP. Assim, a dispersão das médias de `TOTAL (R$)` pode ser considerada estatisticamente semelhante entre TRAIN, VALIDATION e TEST nos três segmentos, embora o valor de VIP tenha ficado apenas pouco acima do limite de 0,05.

As estatísticas descritivas por partição reforçam essa leitura. As médias ficaram muito próximas entre as partições e das médias populacionais: 403,83 a 403,95 em ESSENTIAL, 2.191,81 a 2.193,27 em PRIME e 906,83 a 907,52 em VIP. Os boxplots mostram caixas de alturas parecidas em ESSENTIAL e PRIME, e em VIP a caixa de TRAIN é a mais estreita, com um valor extremo isolado acima de 910.

Ainda assim, em todos os grupos TRAIN teve o menor desvio padrão (1,2827 em ESSENTIAL, 4,4218 em PRIME e 1,4216 em VIP) e o menor intervalo interquartil, enquanto VALIDATION e TEST variaram um pouco mais. A diferença é mais visível em VIP, onde o intervalo interquartil de TEST (3,7954) é quase o triplo do de TRAIN (1,2969), o que explica o p-valor próximo de 0,05 nesse grupo. Esse padrão é coerente com o fato de TRAIN ser a maior partição e, portanto, ter médias mais estáveis.

Dessa forma, conclui-se que a dispersão das médias é homogênea entre as partições nos três grupos, o que reforça a consistência da validação estratificada. A única ressalva é VIP, em que VALIDATION e TEST mostram tendência de maior variabilidade que TRAIN, ainda sem significância estatística.

A1.3.4: Teste das Médias Amostrais

Nesta etapa, são comparadas, para cada grupo (`ESSENTIAL` , `PRIME` e `VIP`), as médias de `TOTAL (R$)` das partições `TRAIN` , `VALIDATION` e `TEST` considerando as reamostragens que foram consideradas válidas. Como as três partições são analisadas simultaneamente em cada rodada, aplica-se o teste de Friedman. Quando necessário, são realizadas comparações entre pares com ajuste de Holm.

O objetivo é avaliar se as médias das partições aceitas permanecem estatisticamente semelhantes, contribuindo para confirmar a consistência do processo de validação estratificada.

```
Teste das médias amostrais por grupos concluído.
Grupos analisados: 3
```

	Grupo	Estatística de Friedman	p-valor	Decisão
0	ESSENTIAL	2.1	0.3499	Não rejeita H0
1	PRIME	0.3	0.8607	Não rejeita H0
2	VIP	1.9	0.3867	Não rejeita H0

```
Grupo: ESSENTIAL
```

	Partição	media	dp	mediana	q1	q3	iqr
0	TRAIN	403.8481	1.2827	404.0889	402.7987	404.6590	1.8603
1	VALIDATION	403.9516	1.4929	404.0166	402.7293	405.2006	2.4713
2	TEST	403.8345	1.5045	403.3695	402.6018	404.8014	2.1996

	grupo_1	grupo_2	estatistica	p_value	p_holm	diferença_significativa
0	TRAIN	VALIDATION	95.0	0.7285	1.0	False
1	TRAIN	TEST	99.0	0.8408	1.0	False
2	VALIDATION	TEST	89.0	0.5706	1.0	False

```
Grupo: PRIME
```

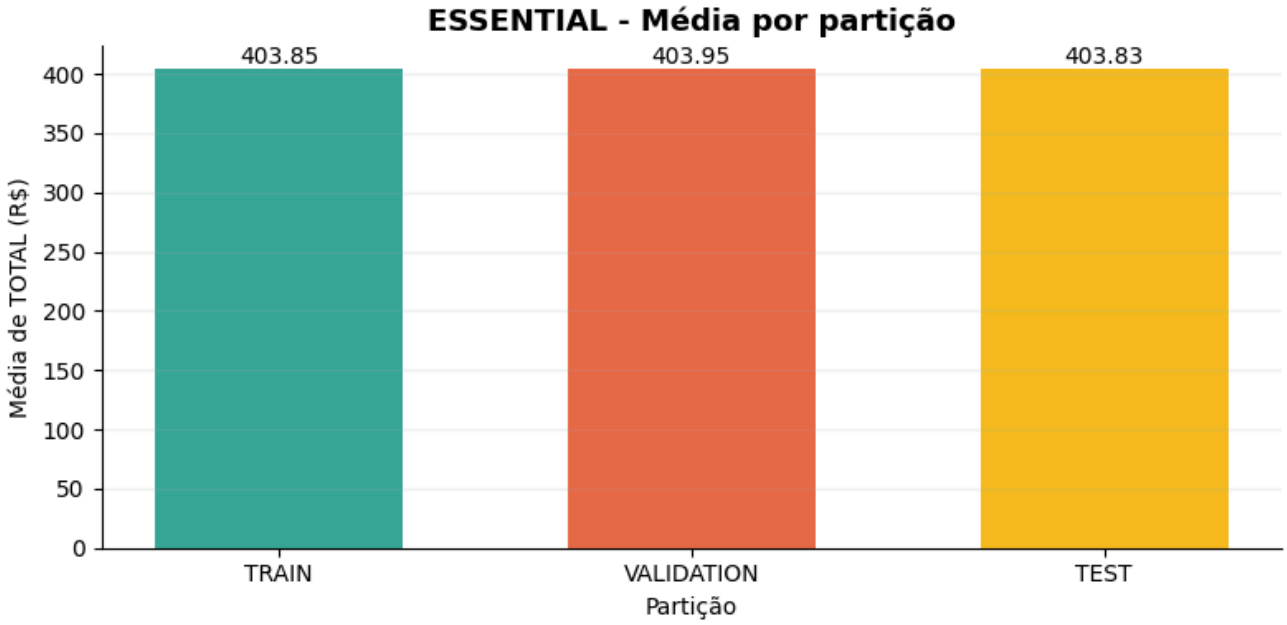
	Partição	media	dp	mediana	q1	q3	iqr
0	TRAIN	2191.8082	4.4218	2191.5389	2188.5977	2195.4667	6.8690
1	VALIDATION	2193.2680	5.4244	2192.7707	2188.7502	2197.5983	8.8481
2	TEST	2191.8490	5.3547	2191.0705	2188.2571	2194.6413	6.3842

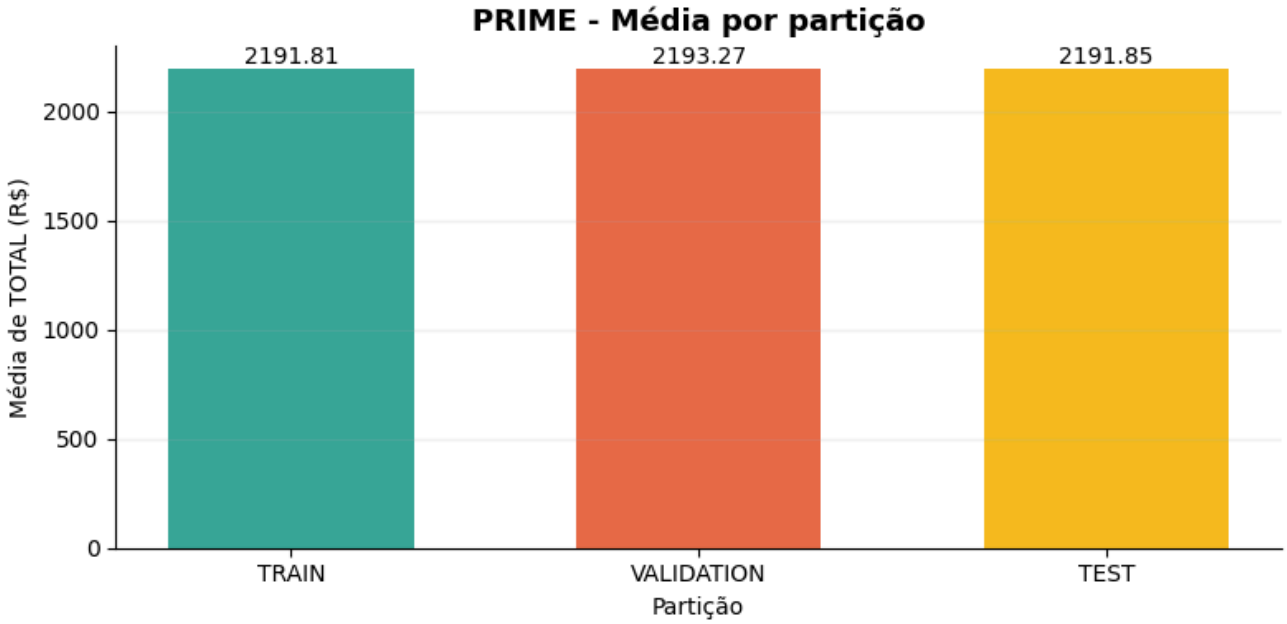
	grupo_1	grupo_2	estatistica	p_value	p_holm	diferença_significativa
0	TRAIN	VALIDATION	76.0	0.2943	0.8828	False
1	TRAIN	TEST	100.0	0.8695	0.8828	False
2	VALIDATION	TEST	80.0	0.3683	0.8828	False

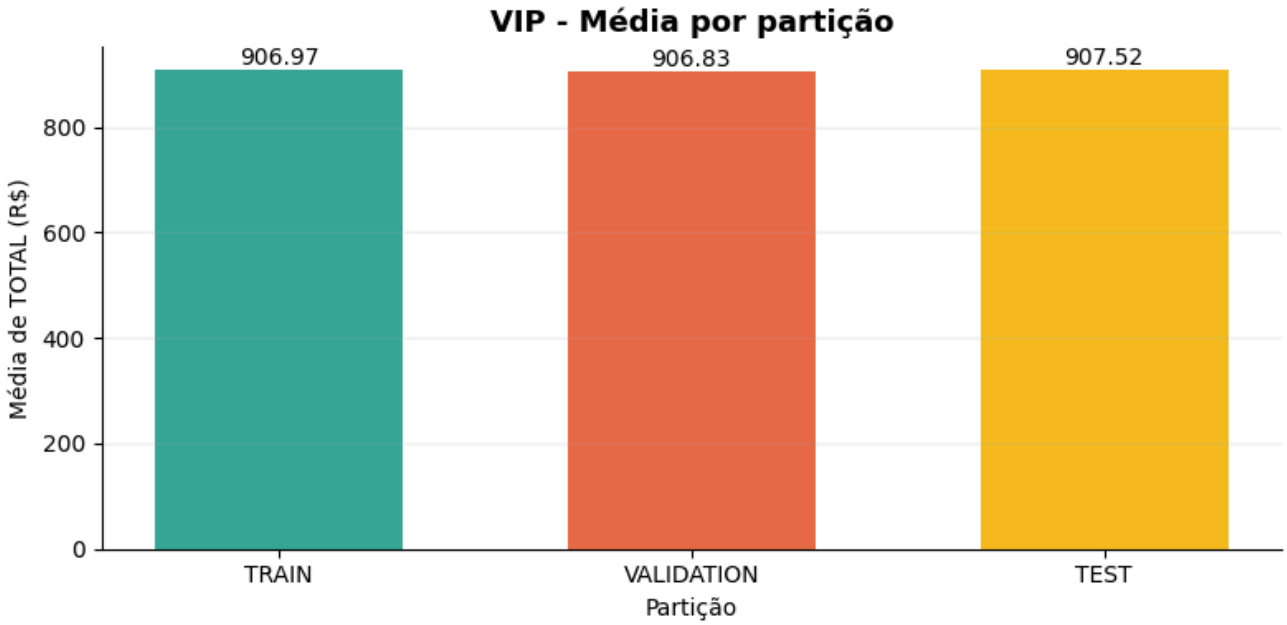
```
Grupo: VIP
```

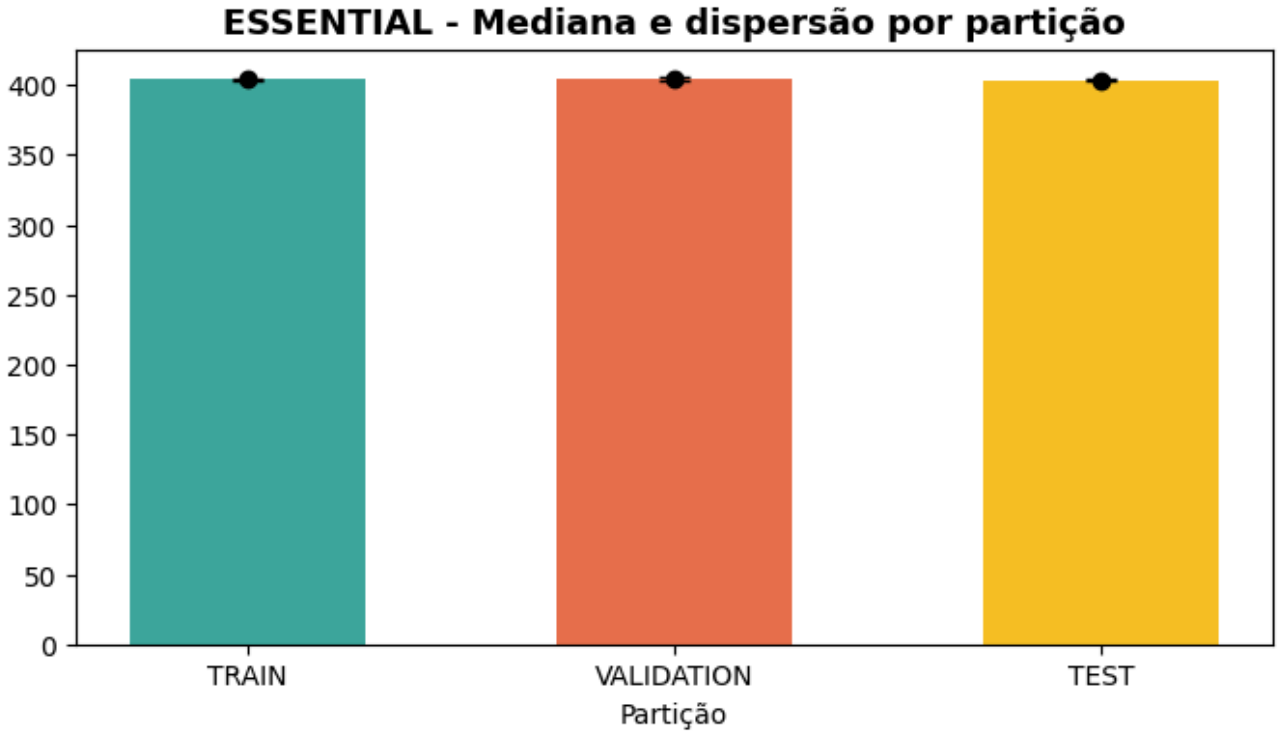
	Partição	media	dp	mediana	q1	q3	iqr
0	TRAIN	906.9667	1.4216	906.8136	906.2610	907.5579	1.2969
1	VALIDATION	906.8261	1.9675	906.3992	905.3724	908.2711	2.8987
2	TEST	907.5164	2.1229	908.0174	905.2839	909.0793	3.7954

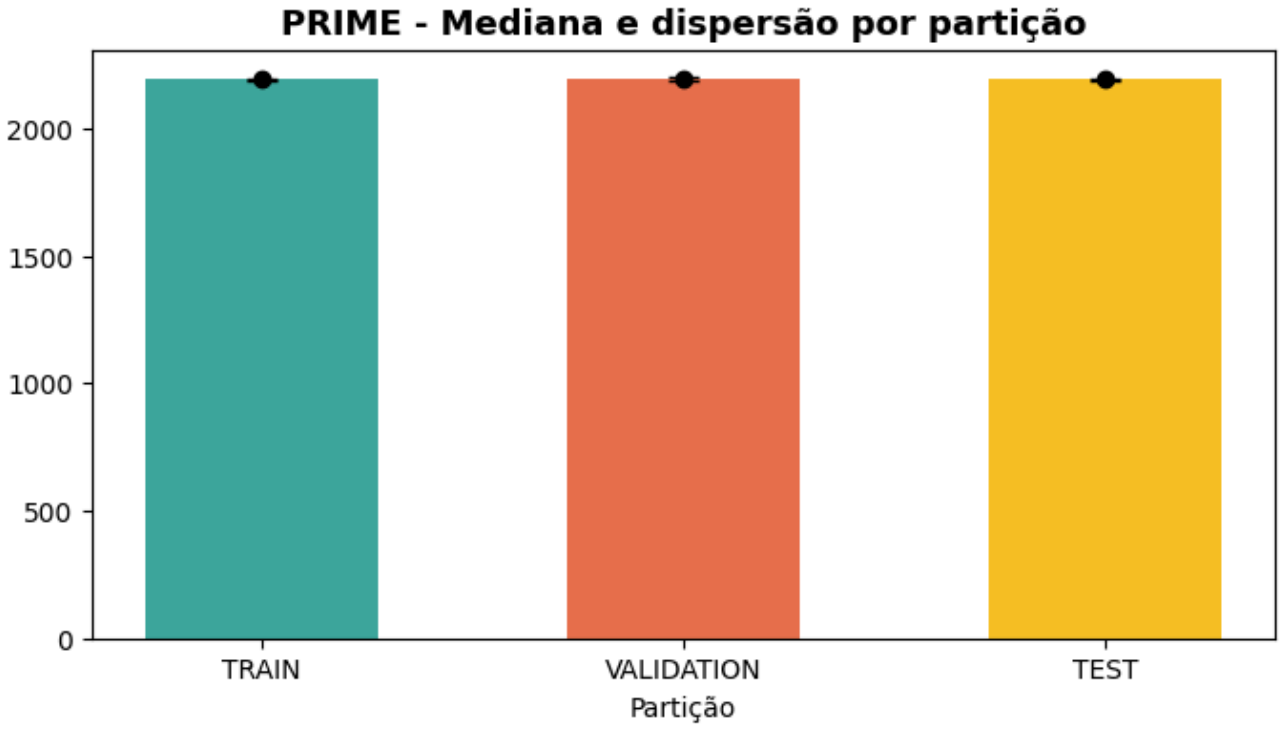
	grupo_1	grupo_2	estatistica	p_value	p_holm	diferença_significativa
0	TRAIN	VALIDATION	98.0	0.8124	1.0	False
1	TRAIN	TEST	82.0	0.4091	1.0	False
2	VALIDATION	TEST	80.0	0.3683	1.0	False

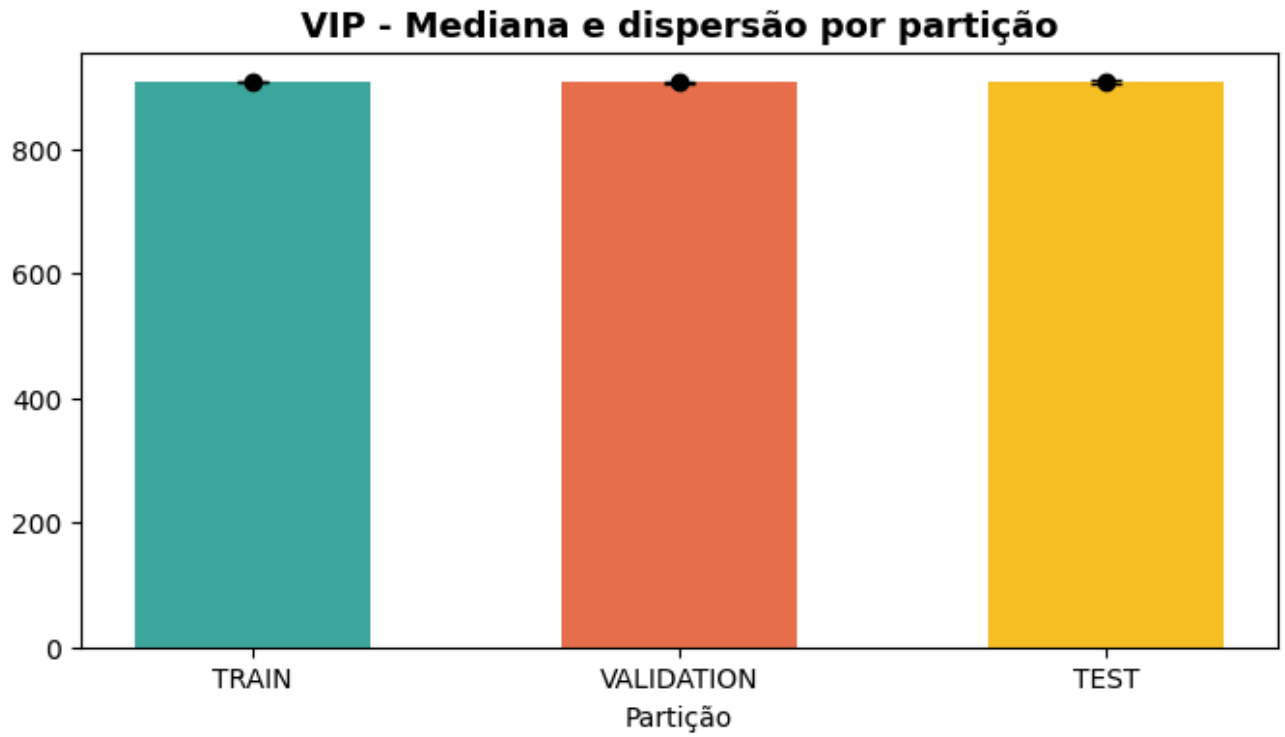



PRIME - Média por partição
2191.81
2193.27
2191.85
2000
1500
1000
500
0
Média de TOTAL (R$)
TRAIN
VALIDATION
TEST
Partição


VIP - Média por partição
906.97
906.83
907.52
800
600
400
200
0
Média de TOTAL (R$)
TRAIN
VALIDATION
TEST
Partição


ESSENTIAL - Mediana e dispersão por partição
400
350
300
250
200
150
100
50
0
TRAIN
VALIDATION
TEST
Partição


PRIME - Mediana e dispersão por partição
2000
1500
1000
500
0
TRAIN
VALIDATION
TEST
Partição



O teste de Friedman não encontrou diferença estatisticamente significativa entre as médias das partições TRAIN, VALIDATION e TEST em nenhum dos grupos: p = 0,3499 em ESSENTIAL, p = 0,8607 em PRIME e p = 0,3867 em VIP. Dessa forma, a hipótese nula de igualdade entre as partições não foi rejeitada nos três casos.

As estatísticas descritivas confirmam esse resultado. Em ESSENTIAL, as médias variaram apenas de 403,83 a 403,95, com medianas entre 403,37 e 404,09. Em PRIME, as médias ficaram entre 2.191,81 e 2.193,27, e em VIP, entre 906,83 e 907,52, valores muito próximos das médias populacionais de cada grupo (403,87, 2.192,33 e 907,18). Os intervalos interquartis foram pequenos em relação ao nível das médias, e os gráficos de média e de mediana por partição mostram barras praticamente do mesmo tamanho.

As comparações par a par com correção de Holm também não apontaram diferença significativa em nenhum par. Em ESSENTIAL e em VIP, todos os p ajustados foram iguais a 1,00, e em PRIME ficaram em 0,8828, sem qualquer evidência de que duas partições difiram entre si.

Conclui-se que, em cada grupo (ESSENTIAL, PRIME e VIP), as partições TRAIN, VALIDATION e TEST têm médias estatisticamente equivalentes para `TOTAL (R$)` nas rodadas aceitas. Isso reforça a consistência da amostragem estratificada validada na A1.3: mesmo que TRAIN tenha ficado mais vezes dentro do intervalo de confiança (A1.3.2), as rodadas aceitas não mostram distorção sistemática de média entre as partições.

Atividade A2 (Link): Estatística descritiva

Nesta etapa, são examinadas as variáveis quantitativas e qualitativas da base com o intuito de entender melhor sua composição dentro de cada estrato, observando padrões, níveis de dispersão e possíveis diferenças entre os grupos `ESSENTIAL`, `PRIME` e `VIP`.

Em vez de analisar os dados de forma geral, o foco está na comparação entre os segmentos, permitindo identificar como as características e comportamentos das variáveis se distribuem em cada grupo. Dessa forma, a análise contribui para a interpretação dos resultados obtidos nos testes estatísticos realizados anteriormente.

Atividade A2.1: Analisar as variáveis Quantitativas

Nesta etapa, são avaliadas as variáveis quantitativas da base para identificar suas principais características, como medidas de tendência central, nível de dispersão, formato das distribuições e ocorrência de possíveis valores extremos nos grupos `ESSENTIAL`, `PRIME` e `VIP`.

A análise é feita individualmente para cada grupo, evitando que uma avaliação conjunta oculte diferenças importantes entre as distribuições. Dessa forma, é possível obter uma visão mais clara e específica do comportamento das variáveis em cada segmento.

```
Análise das variáveis quantitativas por grupos concluída.
Grupos analisados: 3
Variáveis analisadas por grupo: 2
```

	grupo	variavel	n	media	mediana	dp	q1	q3	iq
0	ESSENTIAL	RENDA BRUTO (R$)	683501	3651.7831	3256.070	2158.2579	3197.4900	3317.2400	119.7500
1	ESSENTIAL	TOTAL (R$)	683501	403.8689	367.450	299.1983	237.6500	494.9000	257.2500
2	PRIME	RENDA BRUTO (R$)	183226	19912.5591	21066.165	5115.7511	18749.6350	23024.4675	4274.8325
3	PRIME	TOTAL (R$)	183226	2192.3250	2130.845	1051.2856	1313.8525	3017.8400	1703.9875
4	VIP	RENDA BRUTO (R$)	253273	8242.1429	7770.990	2405.2742	7555.2100	8002.7100	447.5000
5	VIP	TOTAL (R$)	253273	907.1823	869.240	455.2692	559.8200	1176.7400	616.9200

```
Grupo: ESSENTIAL
```

	variavel	coef_var
1	TOTAL (R$)	0.7408
0	RENDA BRUTO (R$)	0.5910

	variavel	outliers_%
0	RENDA BRUTO (R$)	5.1592
1	TOTAL (R$)	2.8881

	variavel	assimetria
0	RENDA BRUTO (R$)	5.8565
1	TOTAL (R$)	5.0153

```
Grupo: PRIME
```

	variavel	coef_var
3	TOTAL (R$)	0.4795
2	RENDA BRUTO (R$)	0.2569

	variavel	outliers_%
2	RENDA BRUTO (R$)	9.8026
3	TOTAL (R$)	0.0000

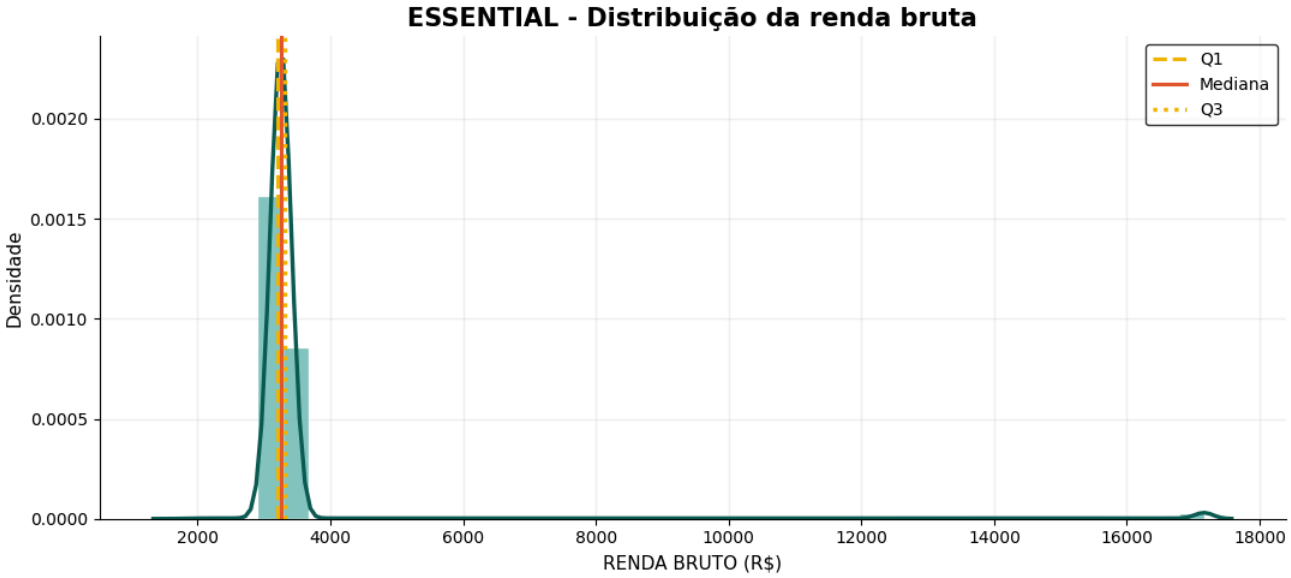
	variavel	assimetria
2	RENDA BRUTO (R$)	-1.6039
3	TOTAL (R$)	0.1935

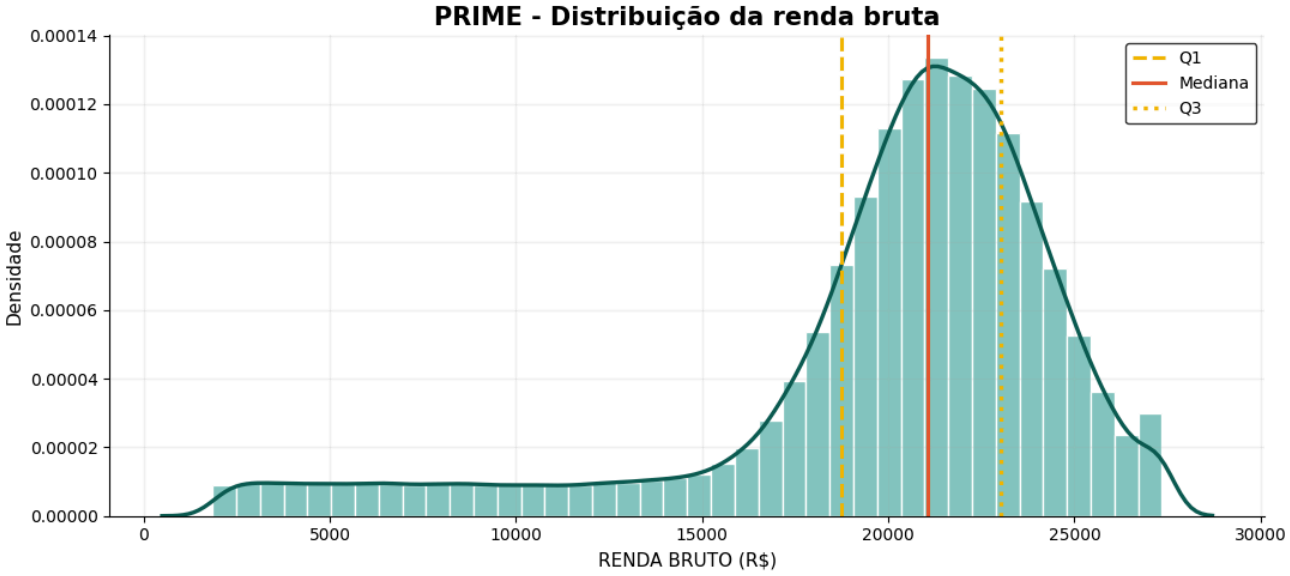
```
Grupo: VIP
```

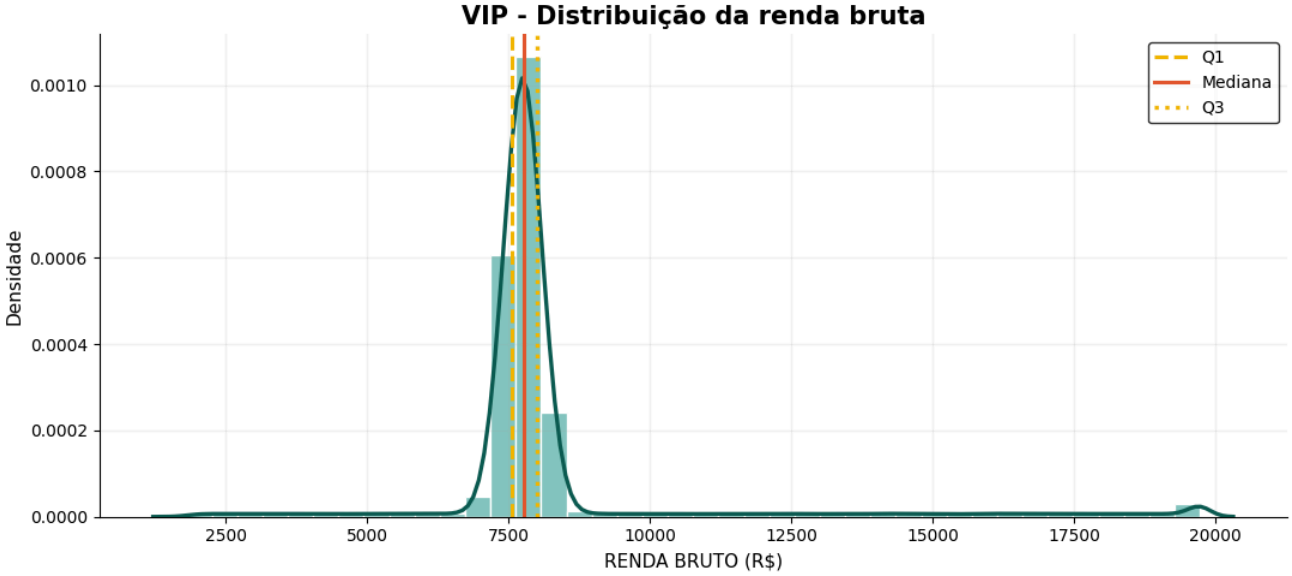
	variavel	coef_var
5	TOTAL (R$)	0.5018
4	RENDA BRUTO (R$)	0.2918

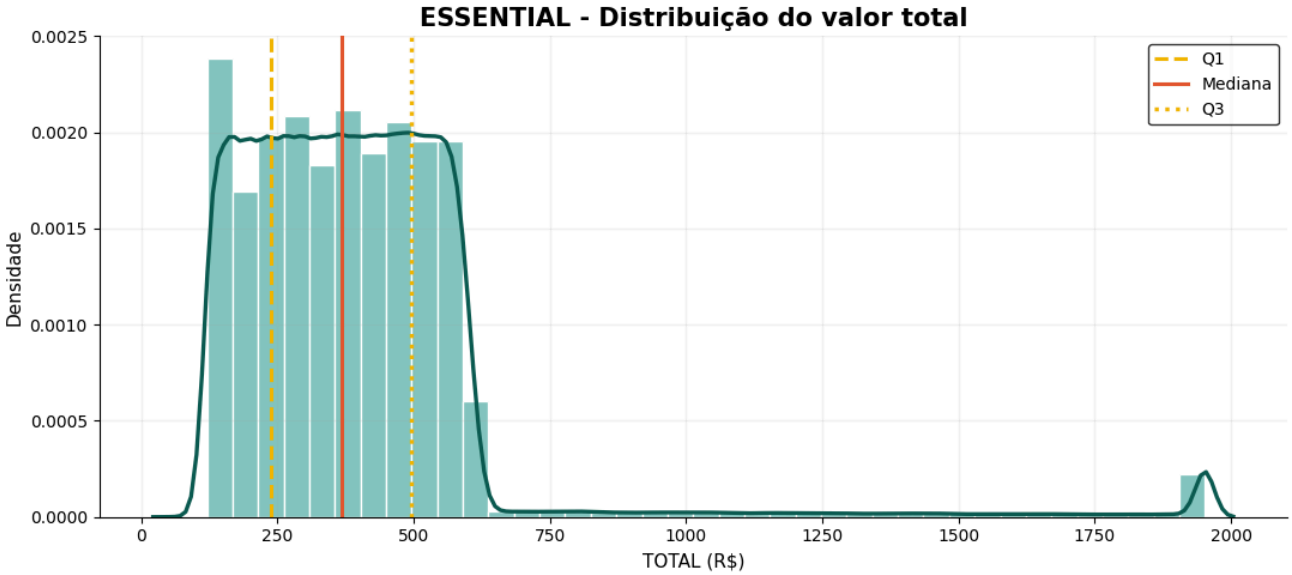
	variavel	outliers_%
4	RENDA BRUTO (R$)	12.0498
5	TOTAL (R$)	2.2746

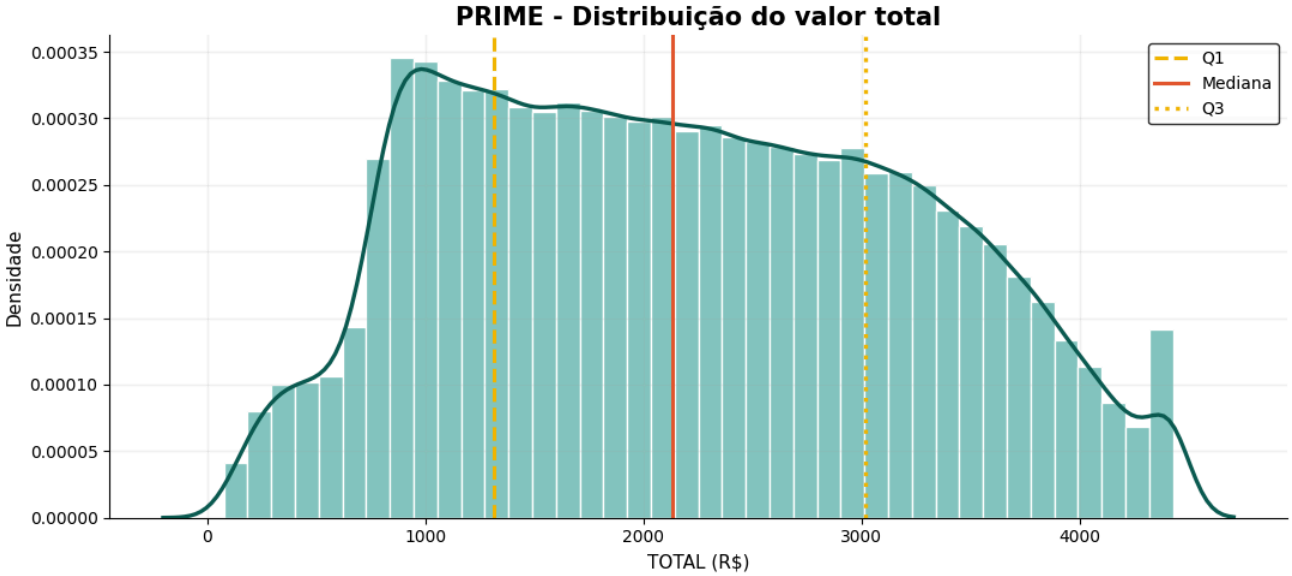
	variavel	assimetria
4	RENDA BRUTO (R$)	3.1997
5	TOTAL (R$)	1.5483

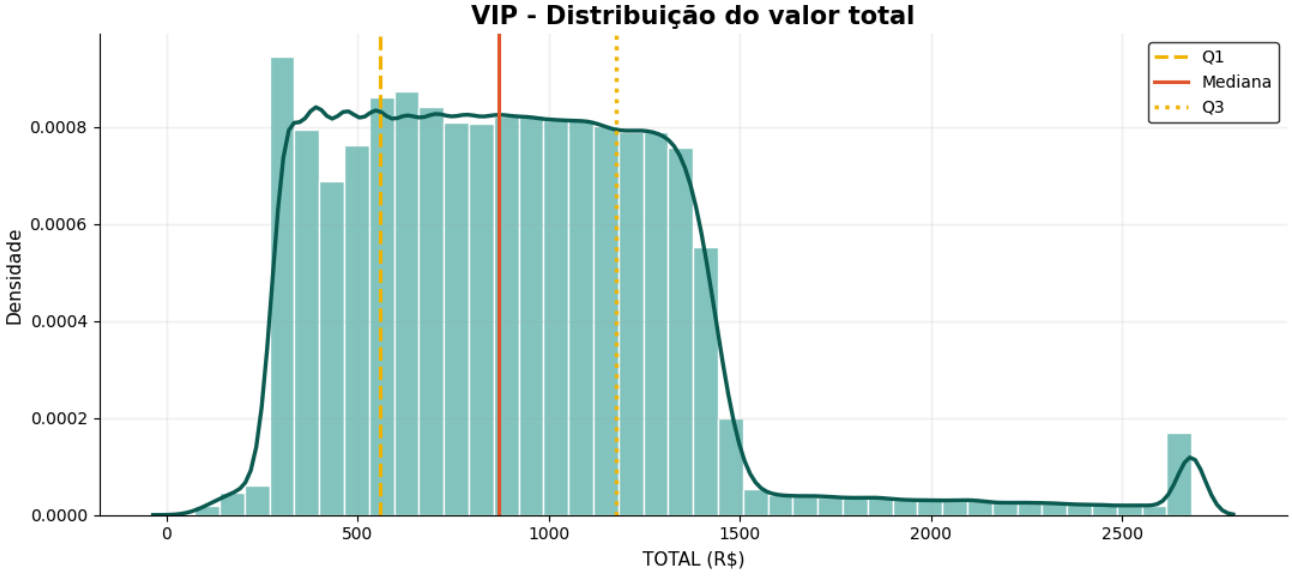

ESSENTIAL - Distribuição da renda bruta
Q1
Mediana
Q3
Densidade
0.0020
0.0015
0.0010
0.0005
0.0000
2000
4000
6000
8000
10000
12000
14000
16000
18000
RENDA BRUTO (R$)


PRIME - Distribuição da renda bruta
Q1
Mediana
Q3
Densidade
0.00014
0.00012
0.00010
0.00008
0.00006
0.00004
0.00002
0.00000
0
5000
10000
15000
20000
25000
30000
RENDA BRUTO (R$)


VIP - Distribuição da renda bruta
Q1
Mediana
Q3
Densidade
0.0010
0.0008
0.0006
0.0004
0.0002
0.0000
2500
5000
7500
10000
12500
15000
17500
20000
RENDA BRUTO (R$)


ESSENTIAL - Distribuição do valor total
Q1
Mediana
Q3
Densidade
TOTAL (R$)


PRIME - Distribuição do valor total
Q1
Mediana
Q3
Densidade
TOTAL (R$)


VIP - Distribuição do valor total
Q1
Mediana
Q3
Densidade
TOTAL (R$)

	grupo	variavel	p1	p5	q1	mediana	q3	p95	p99
0	ESSENTIAL	RENDA BRUTO (R$)	3047.00	3113.10	3197.49	3256.07	3317.24	3462.78	17165.86
1	ESSENTIAL	TOTAL (R$)	128.60	134.70	237.65	367.45	494.90	599.32	1952.05
2	PRIME	RENDA BRUTO (R$)	2949.32	7179.14	18749.63	21066.16	23024.47	25612.93	27349.16
3	PRIME	TOTAL (R$)	257.26	649.91	1313.85	2130.85	3017.84	3948.15	4427.23
4	VIP	RENDA BRUTO (R$)	3274.93	7146.19	7555.21	7770.99	8002.71	13821.61	19718.64
5	VIP	TOTAL (R$)	286.50	316.66	559.82	869.24	1176.74	1469.09	2681.15

A estatística descritiva por grupo mostrou que ESSENTIAL, PRIME e VIP têm perfis distintos em nível central, dispersão e forma da distribuição, tanto em `RENDA BRUTO (R$)` quanto em `TOTAL (R$)`.

ESSENTIAL tem o menor nível entre os grupos, com média de 3.651,78 em `RENDA BRUTO (R$)` e de 403,87 em `TOTAL (R$)`. Nas duas variáveis a média fica acima da mediana (3.256,07 e 367,45), efeito de uma cauda direita longa, confirmada pela assimetria positiva acentuada (5,86 e 5,02) e pela curtose muito elevada (35,03 e 35,64). O coeficiente de variação de `TOTAL (R$)` (0,7408) é o maior entre os grupos, e em `RENDA BRUTO (R$)` o intervalo interquartil é de apenas 119,75, o que deixa 5,16% dos valores fora dos limites do IQR.

PRIME apresenta os maiores níveis, com média de 19.912,56 em `RENDA BRUTO (R$)` e de 2.192,33 em `TOTAL (R$)`. Em `TOTAL (R$)`, a distribuição é a mais equilibrada: assimetria de 0,1935, curtose negativa (-0,8647) e nenhum valor fora dos limites do IQR. Em `RENDA BRUTO (R$)`, a mediana (21.066,16) supera a média e a assimetria é negativa (-1,6039), o que indica alongamento para valores baixos e explica os 9,80% de extremos, além de um coeficiente de variação de 0,2569, o menor do grupo.

VIP ocupa posição intermediária, com média de 8.242,14 em `RENDA BRUTO (R$)` e de 907,18 em `TOTAL (R$)`, mas é o grupo com mais extremos em `RENDA BRUTO (R$)`, 12,05% das observações. As duas variáveis têm assimetria positiva (3,1997 e 1,5483) e curtose acima de zero (12,1947 e 5,2435), o que aponta caudas à direita e heterogeneidade interna.

Os percentis confirmam as diferenças. As medianas seguem a ordem ESSENTIAL, VIP e PRIME, com 3.256,07, 7.770,99 e 21.066,16 em `RENDA BRUTO (R$)` e 367,45, 869,24 e 2.130,85 em `TOTAL (R$)`. As caudas também aparecem na distância entre os percentis 95 e 99: em `TOTAL (R$)`, de 599,32 para 1.952,05 em ESSENTIAL e de 1.469,09 para 2.681,15 em VIP, contra um aumento bem menor em PRIME (de 3.948,15 para 4.427,23).

Conclui-se que a análise por grupo revela diferenças relevantes de patamar monetário, dispersão relativa e formato das distribuições, que ficariam diluídas em uma leitura agregada. Esses resultados reforçam a adequação da abordagem estratificada adotada ao longo do trabalho.

Atividade A2.2: Analisar as variáveis Qualitativas

Nesta etapa, as variáveis qualitativas são examinadas com a finalidade de compreender como suas categorias se distribuem nos grupos `ESSENTIAL`, `PRIME` e `VIP`, considerando aspectos como frequência, concentração, quantidade de categorias e possíveis padrões de ocorrência.

A avaliação é feita individualmente para cada grupo, permitindo identificar características que poderiam passar despercebidas em uma análise conjunta da base. Dessa maneira, essa etapa complementa a análise das variáveis quantitativas e auxilia na construção de uma visão mais detalhada do perfil categórico dos registros.

```
Análise das variáveis qualitativas por grupos concluída.
Grupos analisados: 3
```

	grupo	variável	missing_%	categorias_unicas	moda	moda_%_validos	top1_%_
0	ESSENTIAL	REGIÃO	0.0	5	SUDESTE	67.03	
1	ESSENTIAL	SEXO	0.0	2	MASCULINO	86.97	
2	ESSENTIAL	ESTADO CIVIL	0.0	3	CASADO	55.04	
3	ESSENTIAL	OPINIÃO DO CLIENTE	0.0	25	Entrega foi boa e rápida na UVVine	15.45	
4	ESSENTIAL	DEPENDENTES	0.0	5	1	53.05	
5	PRIME	REGIÃO	0.0	5	SUDESTE	67.06	
6	PRIME	SEXO	0.0	2	MASCULINO	86.91	
7	PRIME	ESTADO CIVIL	0.0	3	CASADO	55.09	
8	PRIME	OPINIÃO DO CLIENTE	0.0	25	Gostei do atendimento prestado pela UVVine	15.55	
9	PRIME	DEPENDENTES	0.0	5	1	53.01	
10	VIP	REGIÃO	0.0	5	SUDESTE	67.02	
11	VIP	SEXO	0.0	2	MASCULINO	87.02	
12	VIP	ESTADO CIVIL	0.0	3	CASADO	55.05	
13	VIP	OPINIÃO DO CLIENTE	0.0	25	Serviço eficiente, recomendo o clube: UVVine	15.46	
14	VIP	DEPENDENTES	0.0	5	1	52.80	

```
Grupo: ESSENTIAL
```

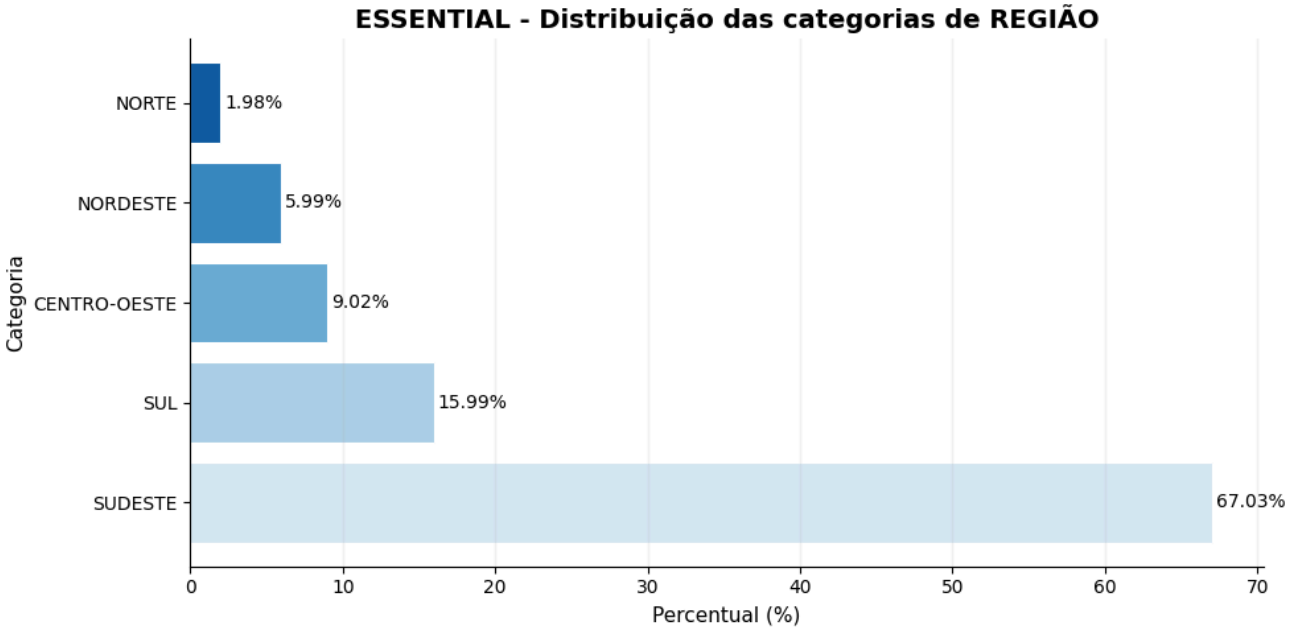
	variável	missing_%	categorias_unicas	moda	moda_%_validos	top1_%_validos	top3
0	REGIÃO	0.0	5	SUDESTE	67.03	67.03	
1	SEXO	0.0	2	MASCULINO	86.97	86.97	
2	ESTADO CIVIL	0.0	3	CASADO	55.04	55.04	
3	OPINIÃO DO CLIENTE	0.0	25	Entrega foi boa e rápida na UVVine	15.45	15.45	
4	DEPENDENTES	0.0	5	1	53.05	53.05	

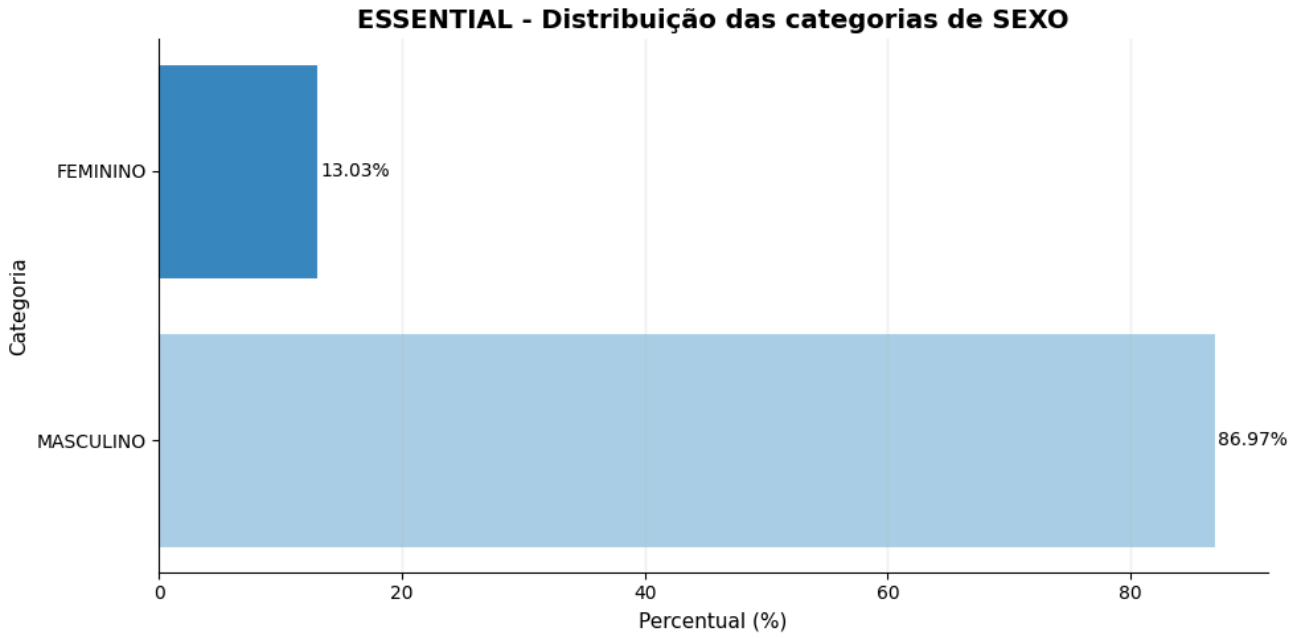
Grupo: PRIME

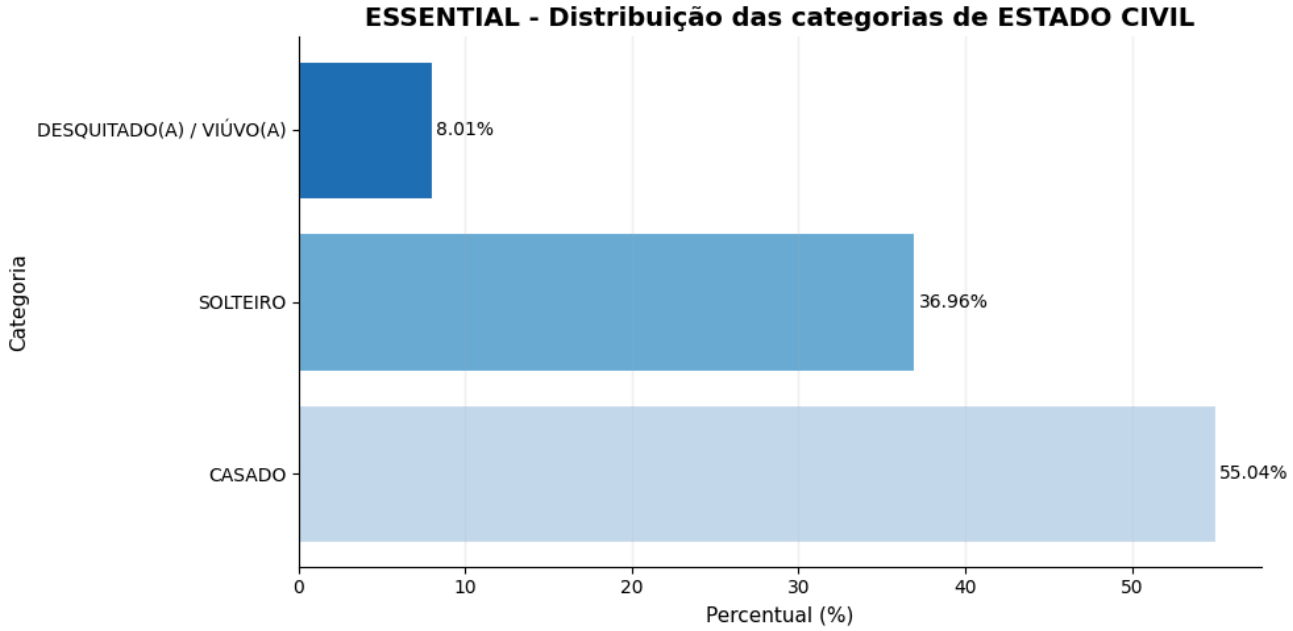
	variável	missing_%	categorias_unicas	moda	moda_%_validos	top1_%_validos	top3
5	REGIÃO	0.0	5	SUDESTE	67.06	67.06	
6	SEXO	0.0	2	MASCULINO	86.91	86.91	
7	ESTADO CIVIL	0.0	3	CASADO	55.09	55.09	
8	OPINIÃO DO CLIENTE	0.0	25	Gostei do atendimento prestado pela UVVine	15.55	15.55	
9	DEPENDENTES	0.0	5	1	53.01	53.01	

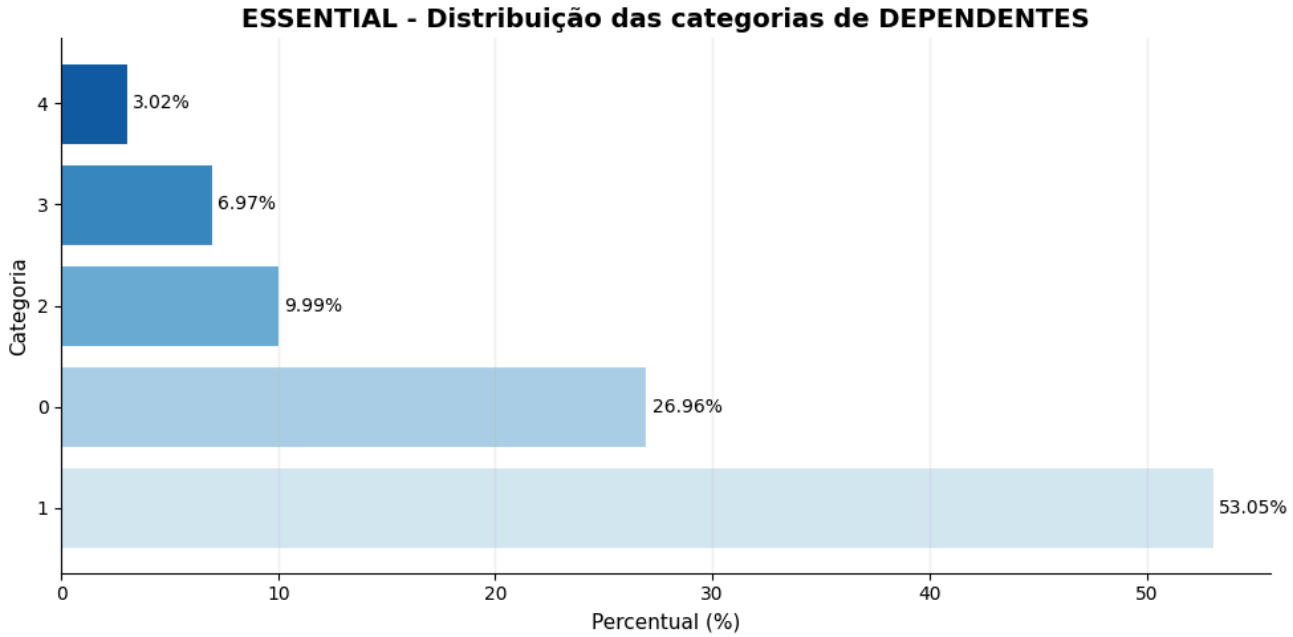
Grupo: VIP

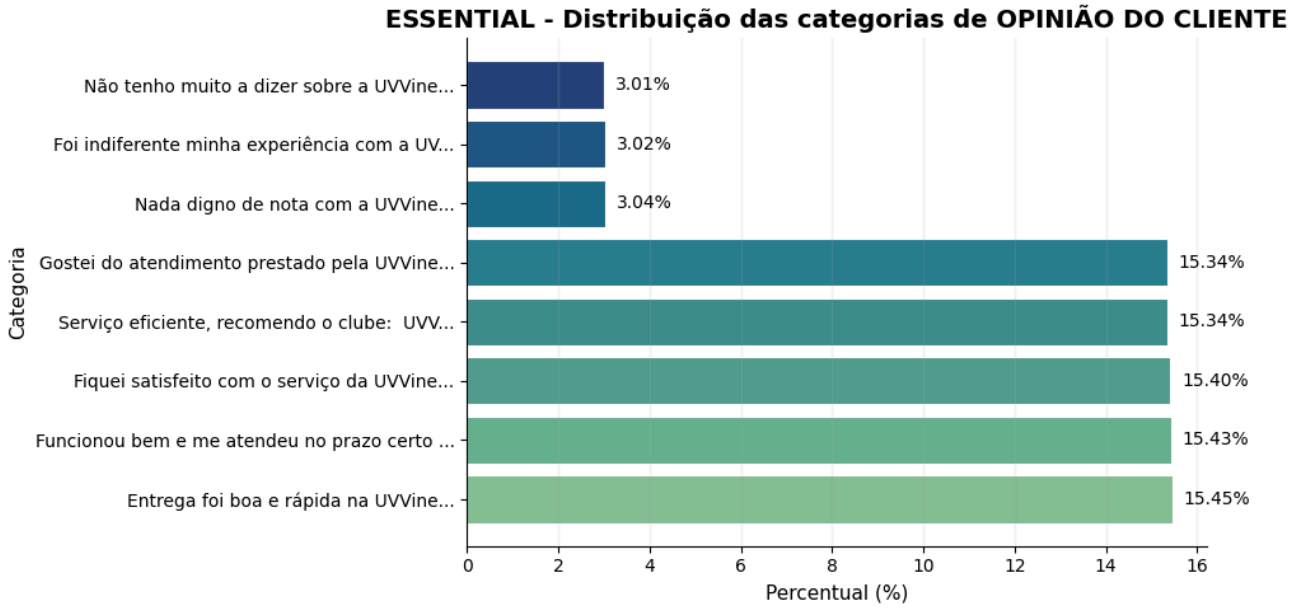
	variável	missing_%	categorias_unicas	moda	moda_%_validos	top1_%_validos	top
10	REGIÃO	0.0	5	SUDESTE	67.02	67.02	
11	SEXO	0.0	2	MASCULINO	87.02	87.02	
12	ESTADO CIVIL	0.0	3	CASADO	55.05	55.05	
13	OPINIÃO DO CLIENTE	0.0	25	Serviço eficiente, recomendo o clube: UVVine	15.46	15.46	
14	DEPENDENTES	0.0	5	1	52.80	52.80	

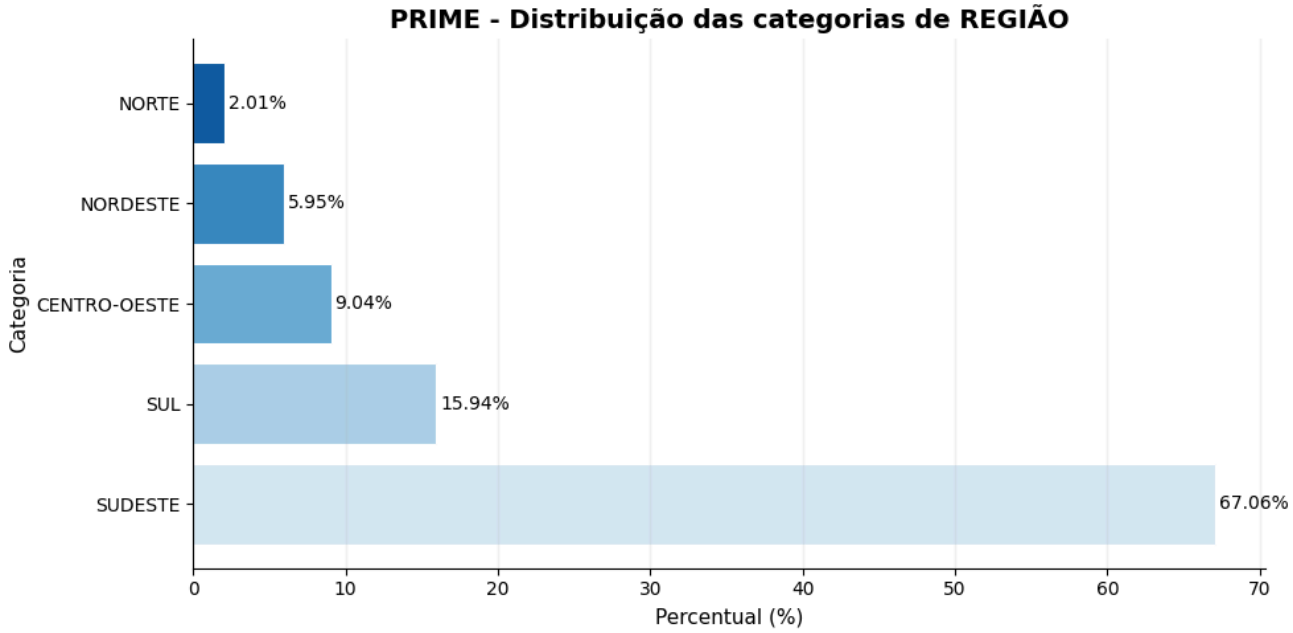


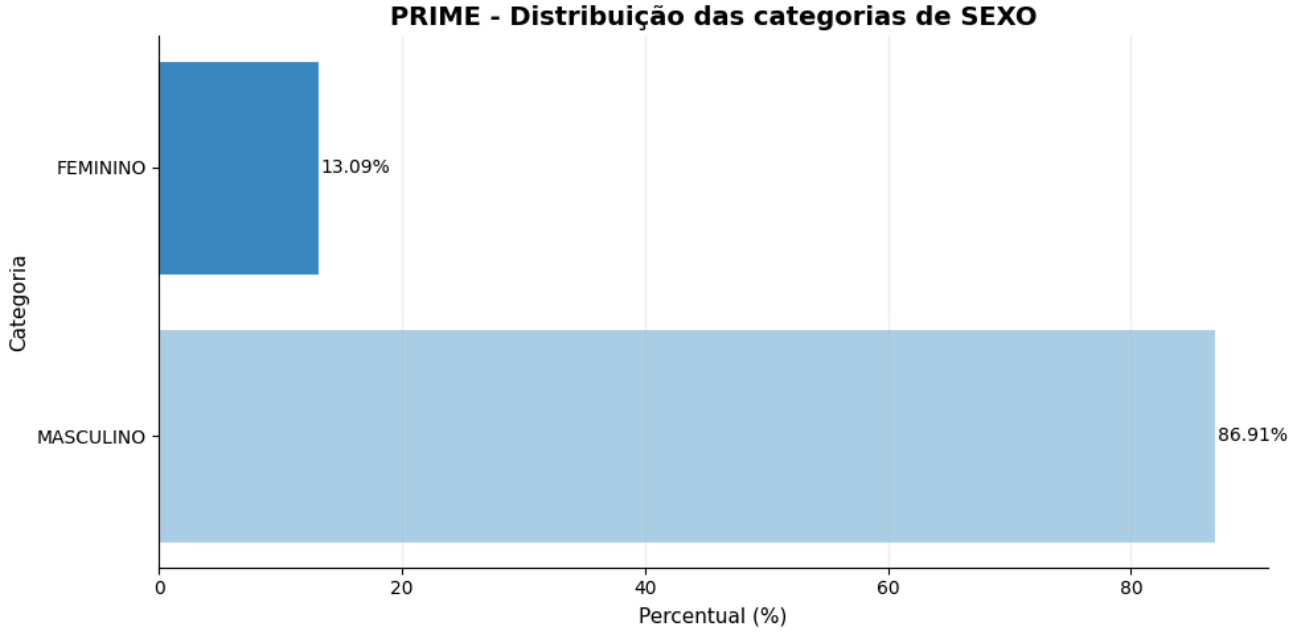

ESSENTIAL - Distribuição das categorias de SEXO
FEMININO
MASCULINO
13.03%
86.97%
Categoria
0
20
40
60
80
Percentual (%)

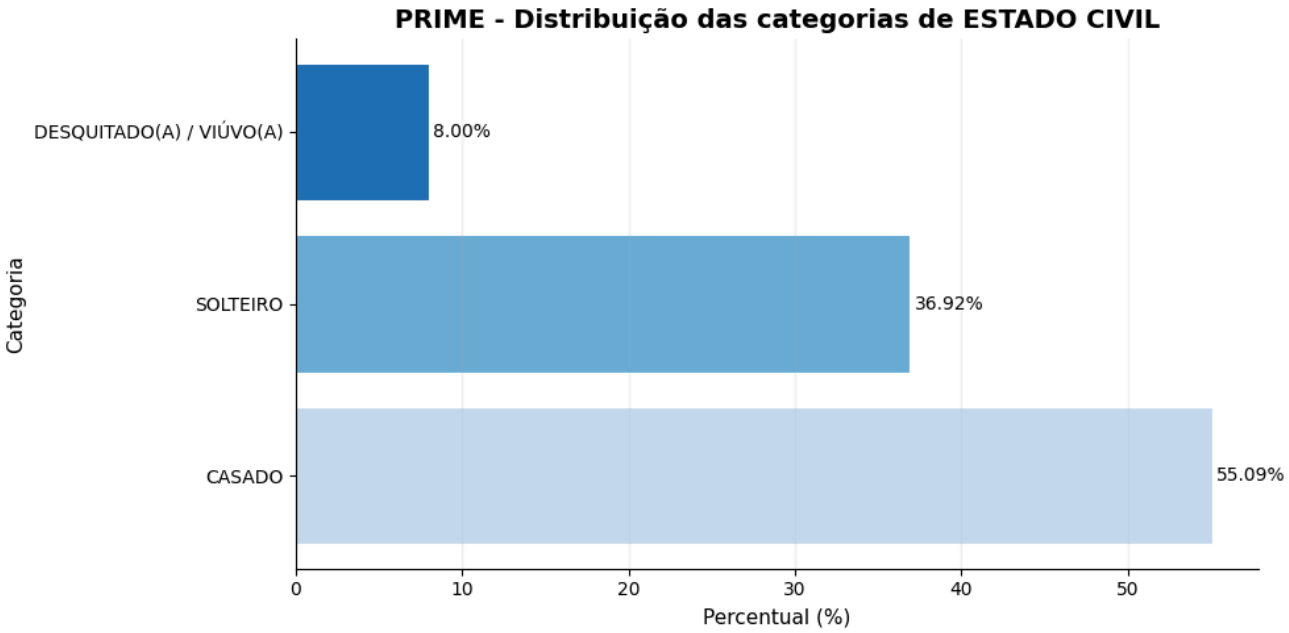

ESSENTIAL - Distribuição das categorias de ESTADO CIVIL
DESQUITADO(A) / VIÚVO(A)
SOLTEIRO
CASADO
8.01%
36.96%
55.04%
Categoria
0
10
20
30
40
50
Percentual (%)

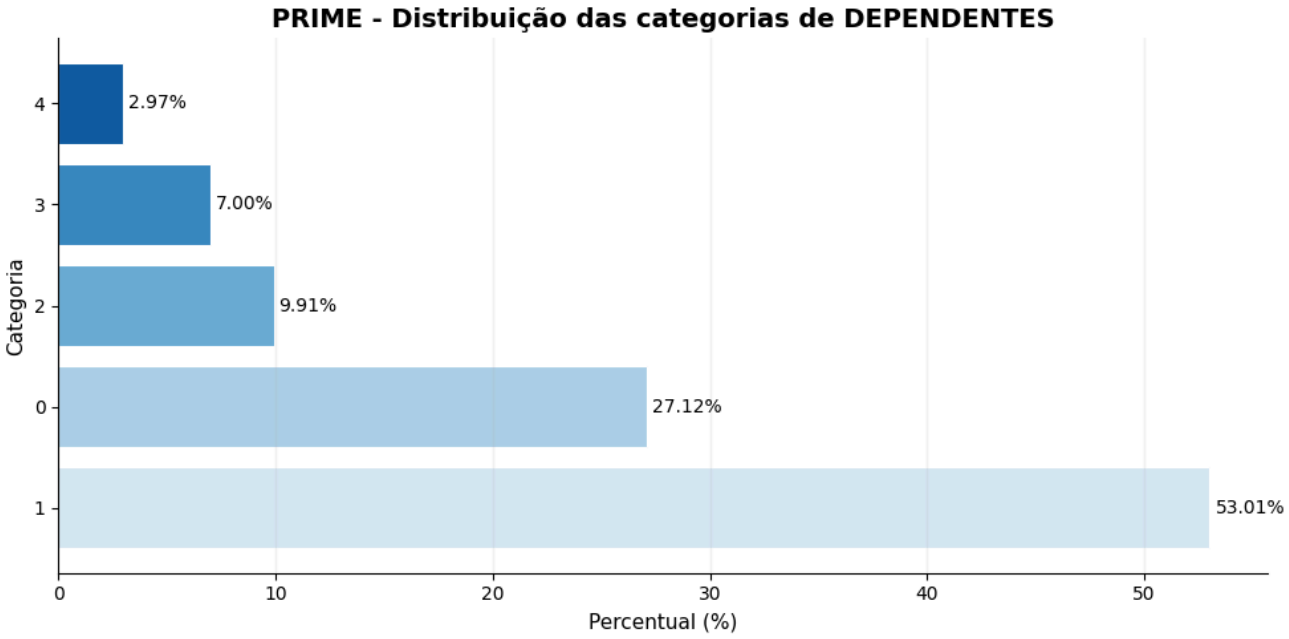

ESSENTIAL - Distribuição das categorias de DEPENDENTES
4
3
2
0
1
3.02%
6.97%
9.99%
26.96%
53.05%
Categoria
0
10
20
30
40
50
Percentual (%)

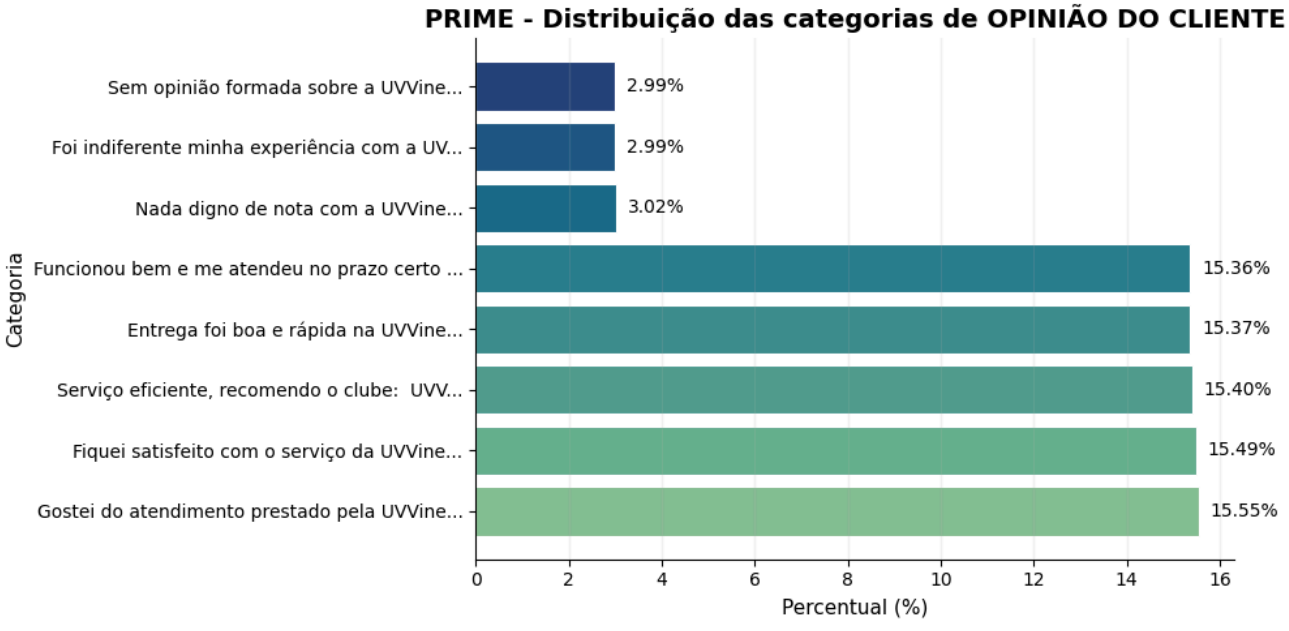

ESSENTIAL - Distribuição das categorias de OPINIÃO DO CLIENTE
Não tenho muito a dizer sobre a UVVine...
Foi indiferente minha experiência com a UV...
Nada digno de nota com a UVVine...
Gostei do atendimento prestado pela UVVine...
Serviço eficiente, recomendo o clube: UVV...
Fiquei satisfeito com o serviço da UVVine...
Funcionou bem e me atendeu no prazo certo ...
Entrega foi boa e rápida na UVVine...
3.01%
3.02%
3.04%
15.34%
15.34%
15.40%
15.43%
15.45%
Categoria
0
2
4
6
8
10
12
14
16
Percentual (%)

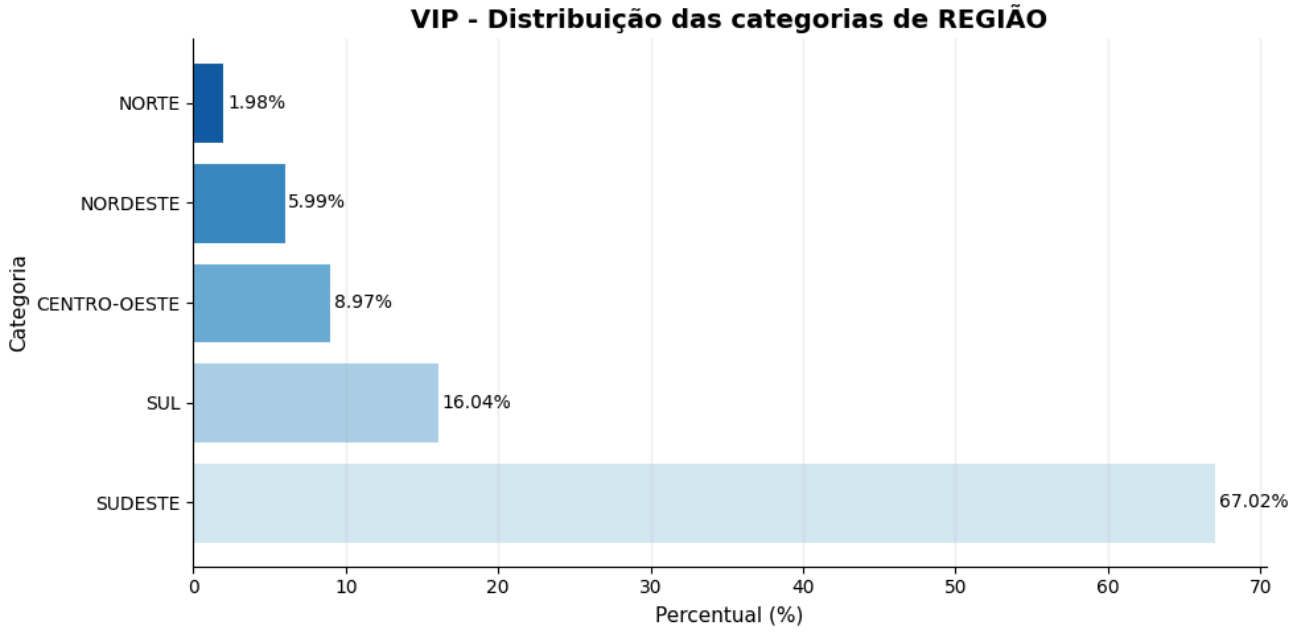

PRIME - Distribuição das categorias de REGIÃO
NORTE
NORDESTE
CENTRO-OESTE
SUL
SUDESTE
2.01%
5.95%
9.04%
15.94%
67.06%
Categoria
0
10
20
30
40
50
60
70
Percentual (%)

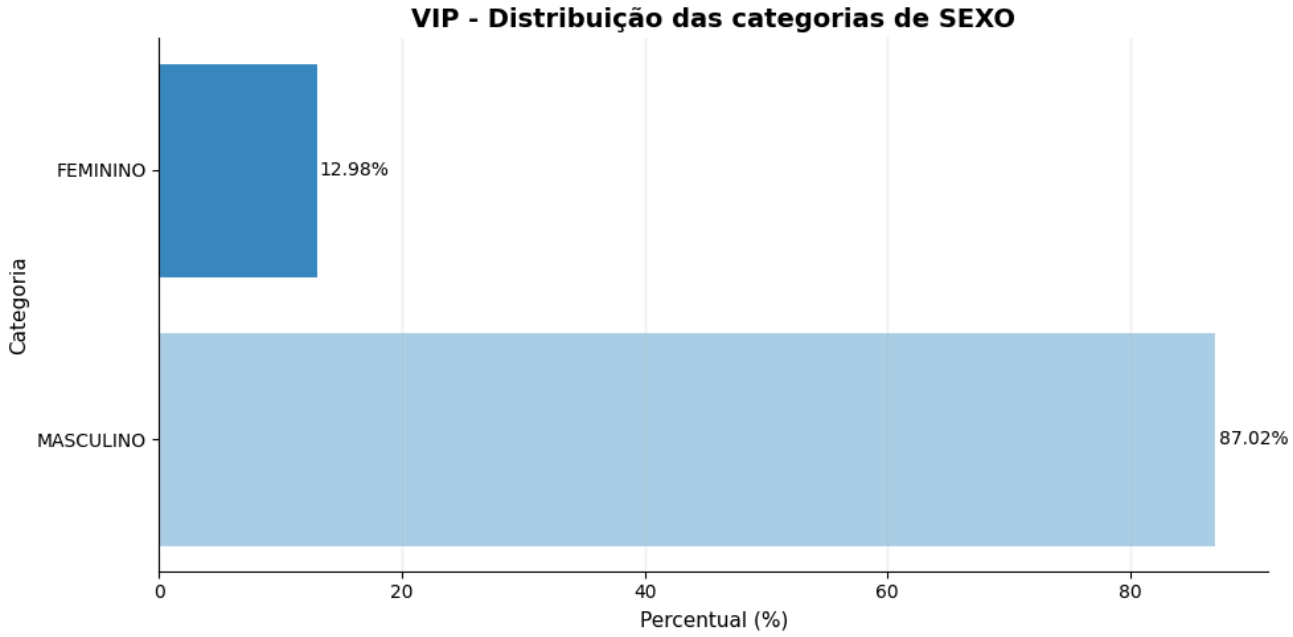

PRIME - Distribuição das categorias de SEXO
FEMININO
MASCULINO
13.09%
86.91%
Categoria
0
20
40
60
80
Percentual (%)

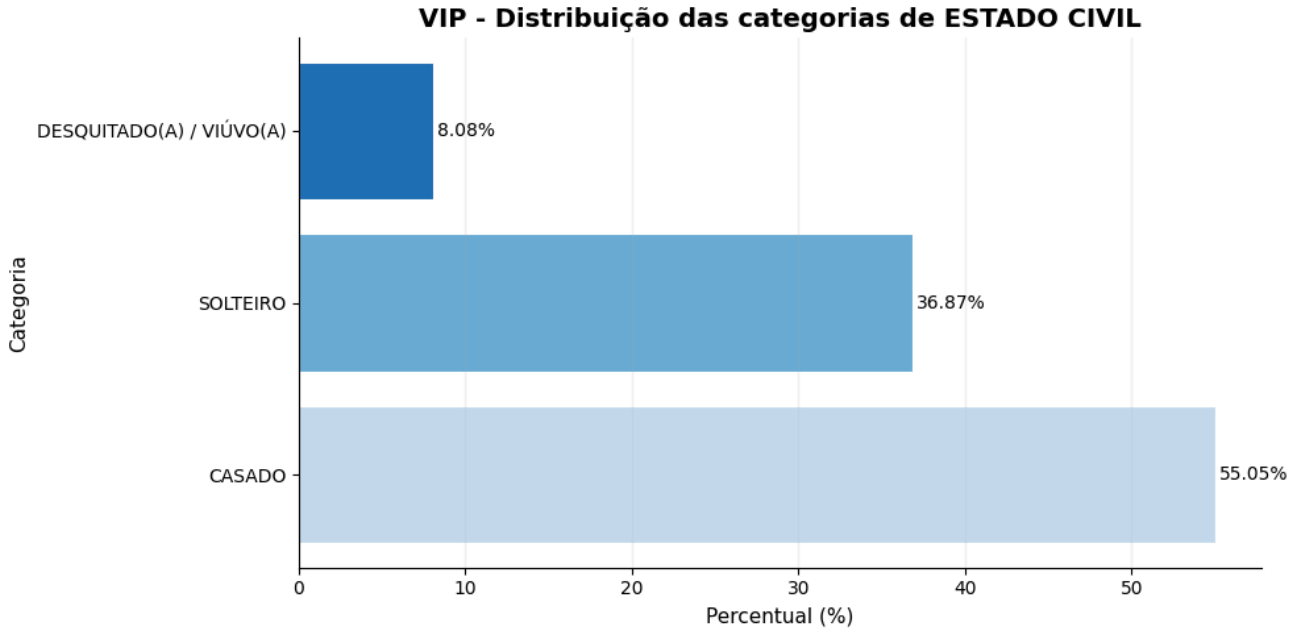

PRIME - Distribuição das categorias de ESTADO CIVIL
DESQUITADO(A) / VIÚVO(A)
SOLTEIRO
CASADO
8.00%
36.92%
55.09%
Categoria
0
10
20
30
40
50
Percentual (%)

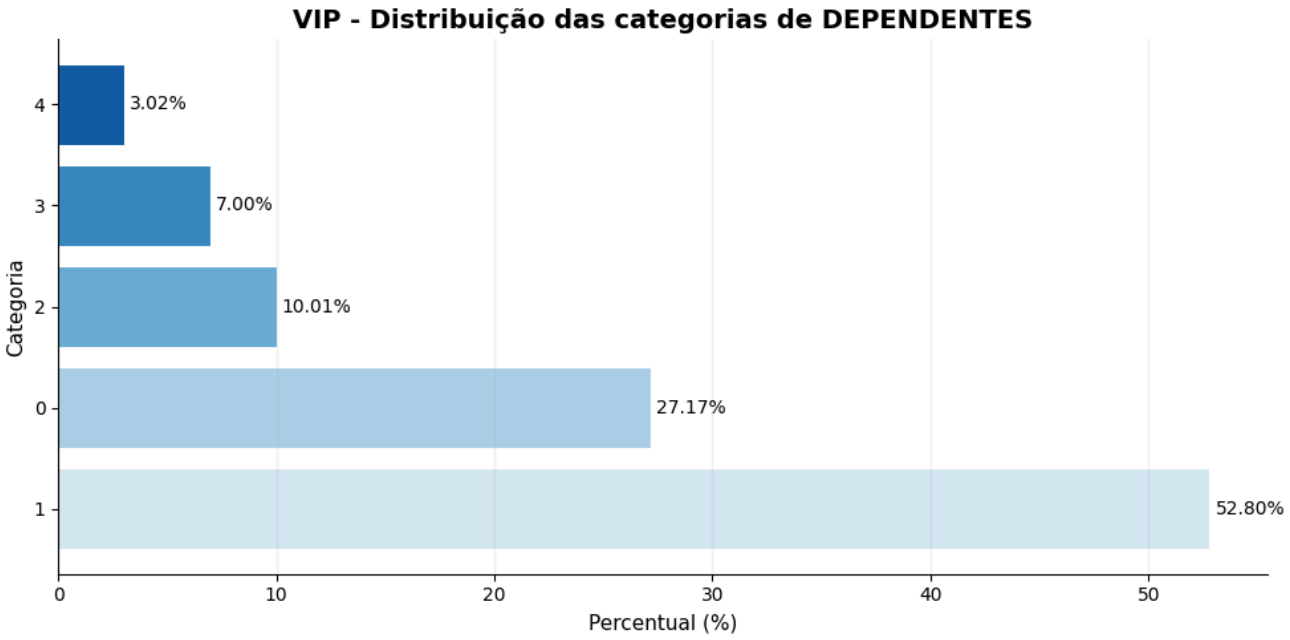

PRIME - Distribuição das categorias de DEPENDENTES
4
3
2
0
1
2.97%
7.00%
9.91%
27.12%
53.01%
Categoria
0
10
20
30
40
50
Percentual (%)

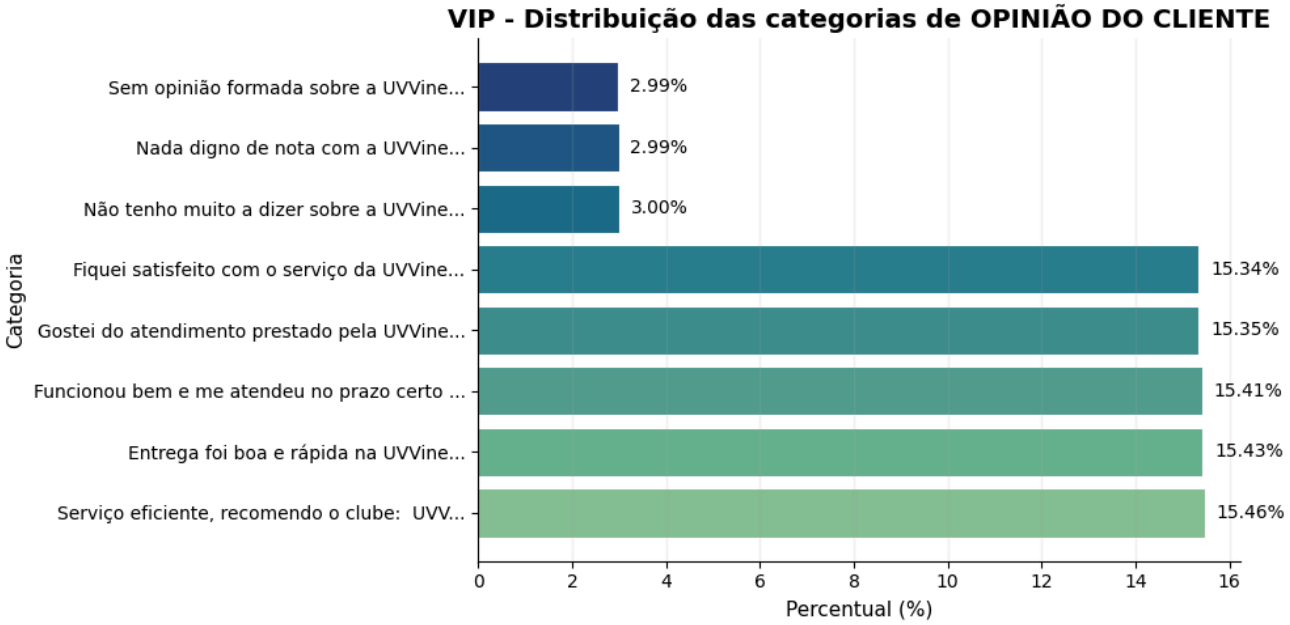

PRIME - Distribuição das categorias de OPINIÃO DO CLIENTE
Sem opinião formada sobre a UVVine...
Foi indiferente minha experiência com a UV...
Nada digno de nota com a UVVine...
Funcionou bem e me atendeu no prazo certo ...
Entrega foi boa e rápida na UVVine...
Serviço eficiente, recomendo o clube: UVV...
Fiquei satisfeito com o serviço da UVVine...
Gostei do atendimento prestado pela UVVine...
2.99%
2.99%
3.02%
15.36%
15.37%
15.40%
15.49%
15.55%
Categoria
0
2
4
6
8
10
12
14
16
Percentual (%)


VIP - Distribuição das categorias de REGIÃO
NORTE
NORDESTE
CENTRO-OESTE
SUL
SUDESTE
1.98%
5.99%
8.97%
16.04%
67.02%
Categoria
0
10
20
30
40
50
60
70
Percentual (%)


VIP - Distribuição das categorias de SEXO
FEMININO
MASCULINO
12.98%
87.02%
Categoria
0
20
40
60
80
Percentual (%)


VIP - Distribuição das categorias de ESTADO CIVIL
DESQUITADO(A) / VIÚVO(A)
SOLTEIRO
CASADO
8.08%
36.87%
55.05%
Categoria
0
10
20
30
40
50
Percentual (%)





A análise das variáveis qualitativas mostrou que ESSENTIAL, PRIME e VIP têm perfis categóricos muito parecidos, com os mesmos padrões de concentração e diferenças de décimos de ponto percentual entre os segmentos. Nenhuma das variáveis apresentou valores ausentes.

Em REGIÃO, o SUDESTE predomina nos três grupos, com cerca de 67% dos registros (67,03% em ESSENTIAL, 67,06% em PRIME e 67,02% em VIP), e as duas principais regiões já somam cerca de 92%. SEXO tem a maior concentração entre as variáveis, com MASCULINO em torno de 87% em todos os grupos. Em ESTADO CIVIL, a concentração é moderada: CASADO aparece em cerca de 55% dos registros, seguido por SOLTEIRO (36,87% a 36,96%) e por DESQUITADO(A) / VIÚVO(A) (cerca de 8%).

DEPENDENTES também tem concentração moderada, com a categoria 1 em torno de 53% (de 52,80% em VIP a 53,05% em ESSENTIAL), seguida por 0, com aproximadamente 27%. As três categorias mais frequentes somam cerca de 90% dos registros, e as categorias 3 e 4 ficam em torno de 7% e 3%. Isso indica um perfil familiar estável entre os segmentos.

OPINIÃO DO CLIENTE foi a variável mais diversa, com 25 categorias e distribuição mais equilibrada. A categoria mais frequente representa cerca de 15,5% dos registros em cada grupo (15,45% em

ESSENTIAL, 15,55% em PRIME e 15,46% em VIP), as três principais somam cerca de 46% e as cinco principais, cerca de 77%. A resposta mais comum muda entre os grupos, mas todas são positivas, e nenhuma domina a variável.

Conclui-se que as variáveis qualitativas têm estrutura estável entre ESSENTIAL, PRIME e VIP, com padrões de concentração praticamente iguais em REGIÃO, SEXO, ESTADO CIVIL e DEPENDENTES. OPINIÃO DO CLIENTE se destacou por manter maior diversidade de categorias em todos os grupos, o que reforça seu potencial informativo nas etapas seguintes.

Atividade A3: Resultado da Pesquisa de Satisfação

Em relaçao a este tópico, busca-se consolidar a percepção dos clientes por meio da classificação da variável qualitativa `OPINIÃO DO CLIENTE` em cinco níveis de satisfação: `Muito insatisfeito`, `Insatisfeito`, `Indiferente`, `Satisfeito` e `Muito satisfeito`.

A análise é realizada de forma individual nos grupos `ESSENTIAL`, `PRIME` e `VIP`, possibilitando observar e comparar a distribuição percentual dos diferentes níveis de satisfação entre os segmentos. Essa abordagem permite uma análise mais adequada à estrutura da base de dados, preservando as diferenças existentes entre os grupos e evitando que uma análise agregada oculte características específicas de cada segmento.

Fazer o resultado da Pesquisa de satisfação do cliente em porcentagem (%):

- Geral
- Por Sexo



Atividade A3.1: Discretizar a Variável Qualitativa (OPINIÃO DO CLIENTE)

A classificação é feita a partir do conteúdo textual das respostas, permitindo enquadrar cada registro em um dos níveis de satisfação definidos. Posteriormente, calcula-se a proporção percentual de cada categoria dentro dos grupos `ESSENTIAL`, `PRIME` e `VIP`. Para complementar a análise, aplica-se a técnica de bootstrap na estimação dos intervalos de confiança dos percentuais obtidos para cada nível de satisfação, proporcionando maior segurança na interpretação dos resultados.

```
Resultado da pesquisa de satisfação por grupos calculado.
Grupos analisados: 3
Categorias de satisfação: 5
Também foi calculada a distribuição por sexo dentro de cada grupo.
```

	Grupo	Categoria	N válidos	Freq. absoluta	Freq. (%)	IC 95% inferior	IC 95% superior
0	ESSENTIAL	Muito insatisfeito	683501	0	0.00	0.00	0.00
1	ESSENTIAL	Insatisfeito	683501	4093	0.60	0.58	0.62
2	ESSENTIAL	Indiferente	683501	127271	18.62	18.53	18.71
3	ESSENTIAL	Satisfeito	683501	110337	16.14	16.05	16.23
4	ESSENTIAL	Muito satisfeito	683501	441800	64.64	64.52	64.75
5	PRIME	Muito insatisfeito	183226	0	0.00	0.00	0.00
6	PRIME	Insatisfeito	183226	1101	0.60	0.57	0.64
7	PRIME	Indiferente	183226	33933	18.52	18.34	18.69
8	PRIME	Satisfeito	183226	29925	16.33	16.16	16.50
9	PRIME	Muito satisfeito	183226	118267	64.55	64.33	64.76
10	VIP	Muito insatisfeito	253273	0	0.00	0.00	0.00
11	VIP	Insatisfeito	253273	1540	0.61	0.58	0.64
12	VIP	Indiferente	253273	47044	18.57	18.42	18.72
13	VIP	Satisfeito	253273	40938	16.16	16.03	16.31
14	VIP	Muito satisfeito	253273	163751	64.65	64.47	64.83

```
Grupo: ESSENTIAL
```

	Categoria	N válidos	Freq. absoluta	Freq. (%)	IC 95% inferior	IC 95% superior
0	Muito insatisfeito	683501	0	0.00	0.00	0.00
1	Insatisfeito	683501	4093	0.60	0.58	0.62
2	Indiferente	683501	127271	18.62	18.53	18.71
3	Satisfeito	683501	110337	16.14	16.05	16.23
4	Muito satisfeito	683501	441800	64.64	64.52	64.75

```
Grupo: PRIME
```

	Categoria	N válidos	Freq. absoluta	Freq. (%)	IC 95% inferior	IC 95% superior
5	Muito insatisfeito	183226	0	0.00	0.00	0.00
6	Insatisfeito	183226	1101	0.60	0.57	0.64
7	Indiferente	183226	33933	18.52	18.34	18.69
8	Satisfeito	183226	29925	16.33	16.16	16.50
9	Muito satisfeito	183226	118267	64.55	64.33	64.76

Grupo: VIP

	Categoria	N válidos	Freq. absoluta	Freq. (%)	IC 95% inferior	IC 95% superior
10	Muito insatisfeito	253273	0	0.00	0.00	0.00
11	Insatisfeito	253273	1540	0.61	0.58	0.64
12	Indiferente	253273	47044	18.57	18.42	18.72
13	Satisfeito	253273	40938	16.16	16.03	16.31
14	Muito satisfeito	253273	163751	64.65	64.47	64.83

Grupo: ESSENTIAL - por sexo

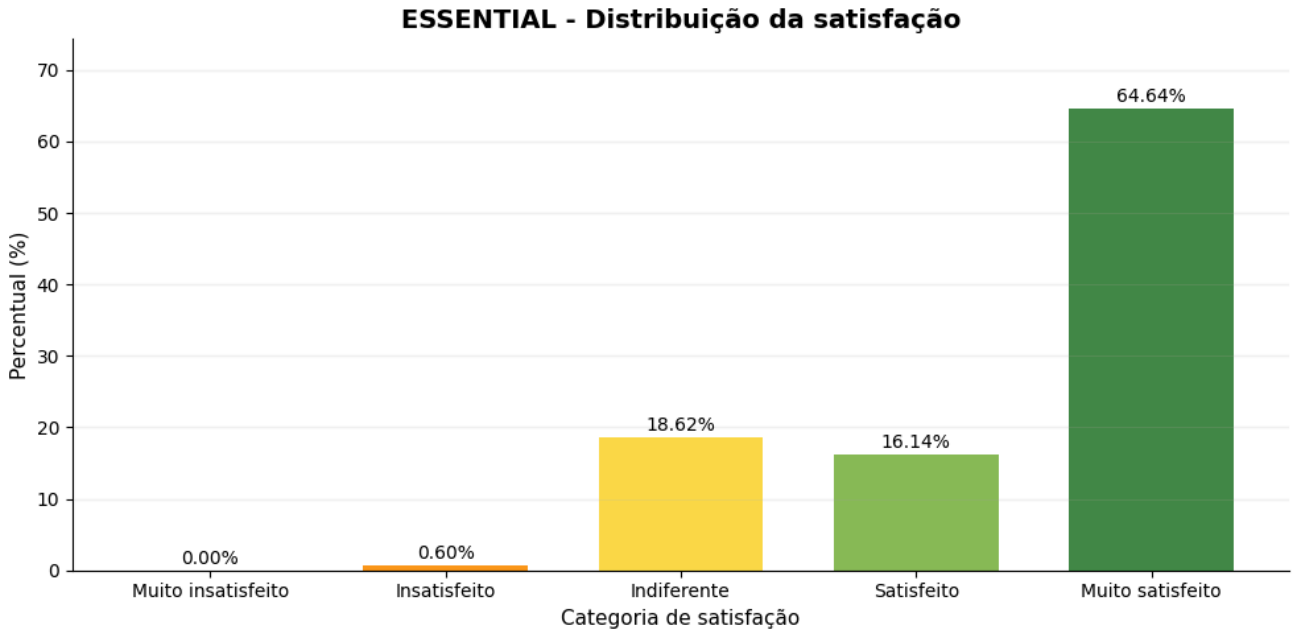
	Sexo	Categoria	N válidos	Freq. absoluta	Freq. (%)	IC 95% inferior	IC 95% superior
0	FEMININO	Muito insatisfeito	89094	0	0.00	0.00	0.00
1	FEMININO	Insatisfeito	89094	538	0.60	0.55	0.66
2	FEMININO	Indiferente	89094	16765	18.82	18.56	19.08
3	FEMININO	Satisfeito	89094	14278	16.03	15.78	16.27
4	FEMININO	Muito satisfeito	89094	57513	64.55	64.23	64.86
5	MASCULINO	Muito insatisfeito	594407	0	0.00	0.00	0.00
6	MASCULINO	Insatisfeito	594407	3555	0.60	0.58	0.62
7	MASCULINO	Indiferente	594407	110506	18.59	18.49	18.69
8	MASCULINO	Satisfeito	594407	96059	16.16	16.07	16.25
9	MASCULINO	Muito satisfeito	594407	384287	64.65	64.53	64.77

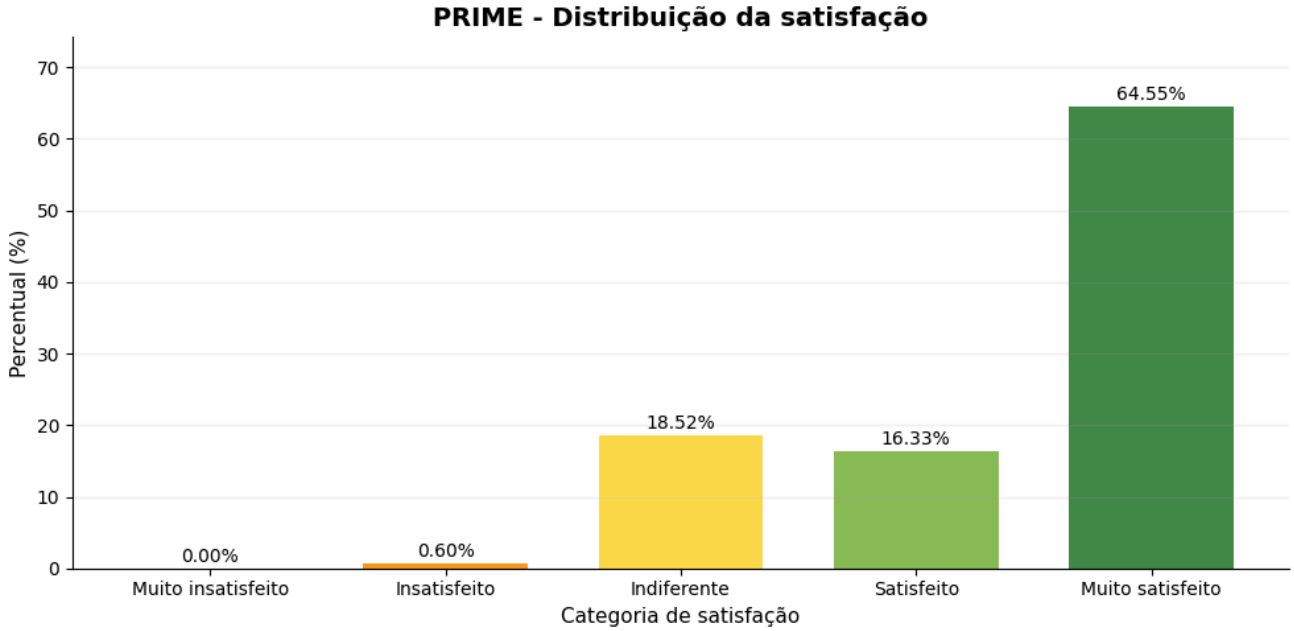
Grupo: PRIME - por sexo

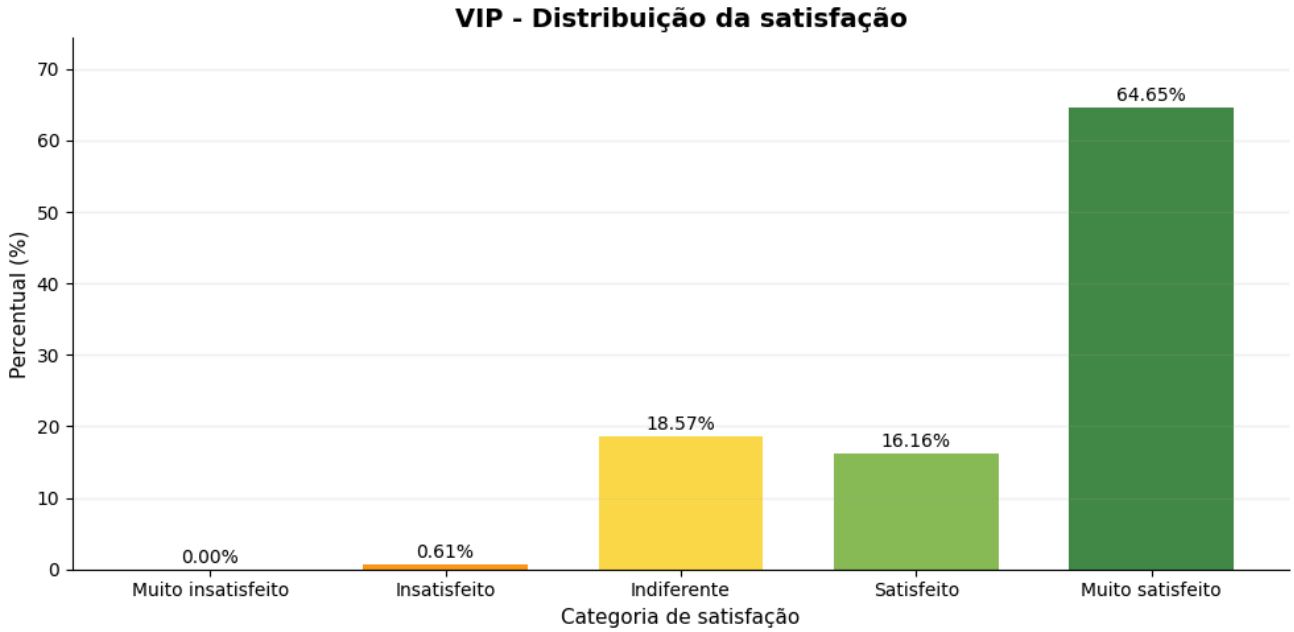
	Sexo	Categoria	N válidos	Freq. absoluta	Freq. (%)	IC 95% inferior	IC 95% superior
10	FEMININO	Muito insatisfeito	23980	0	0.00	0.00	0.00
11	FEMININO	Insatisfeito	23980	135	0.56	0.47	0.66
12	FEMININO	Indiferente	23980	4432	18.48	18.00	18.97
13	FEMININO	Satisfeito	23980	3939	16.43	15.95	16.90
14	FEMININO	Muito satisfeito	23980	15474	64.53	63.93	65.15
15	MASCULINO	Muito insatisfeito	159246	0	0.00	0.00	0.00
16	MASCULINO	Insatisfeito	159246	966	0.61	0.57	0.64
17	MASCULINO	Indiferente	159246	29501	18.53	18.34	18.72
18	MASCULINO	Satisfeito	159246	25986	16.32	16.13	16.50
19	MASCULINO	Muito satisfeito	159246	102793	64.55	64.32	64.79

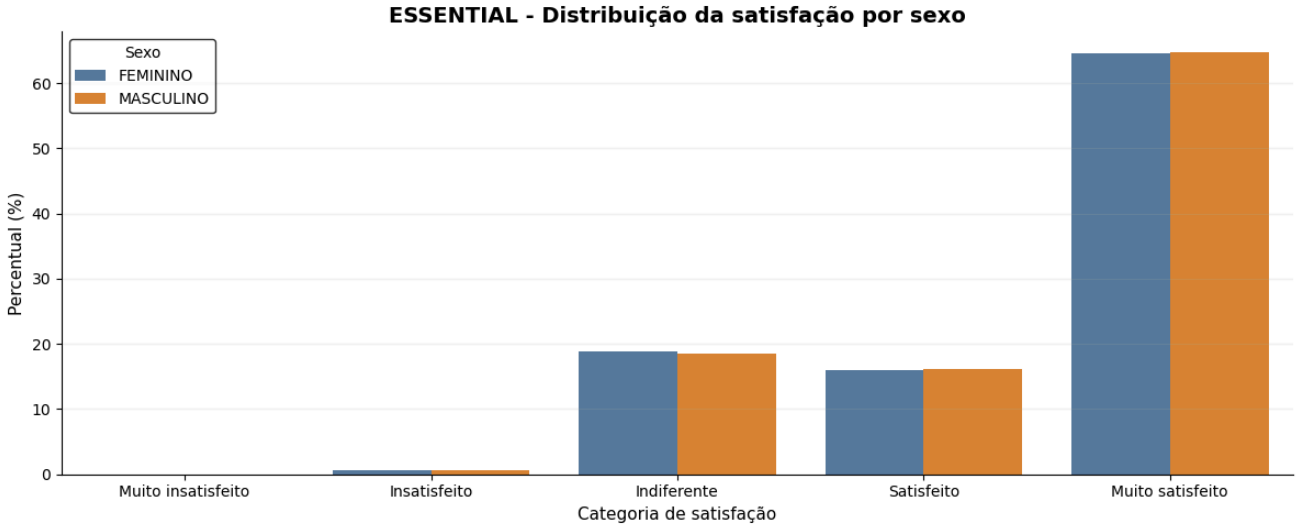
Grupo: VIP - por sexo

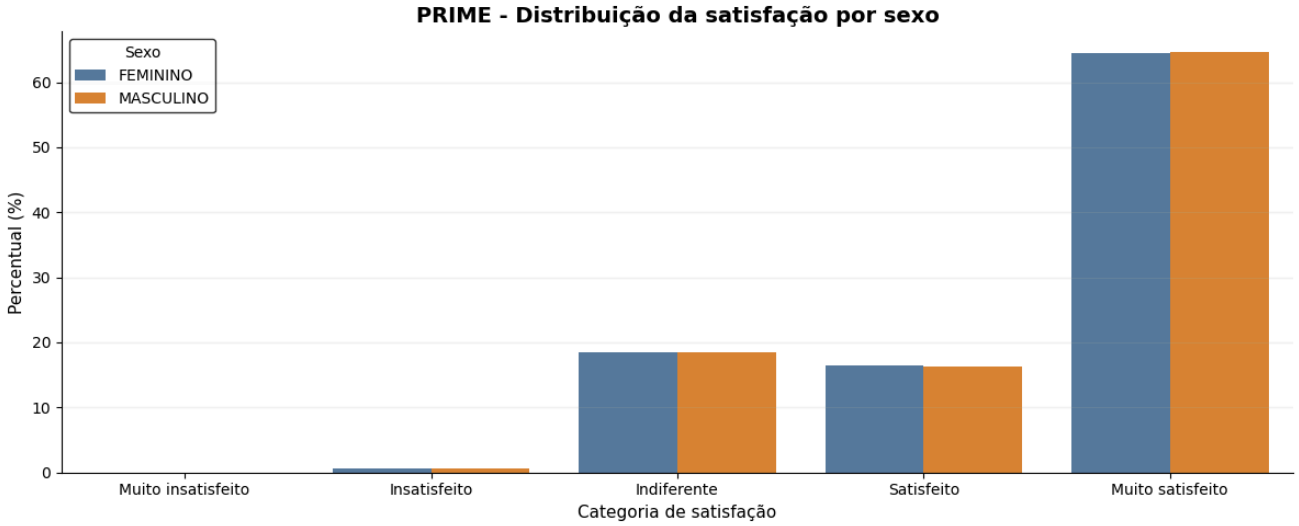
	Sexo	Categoria	N válidos	Freq. absoluta	Freq. (%)	IC 95% inferior	IC 95% superior
20	FEMININO	Muito insatisfeito	32877	0	0.00	0.00	0.00
21	FEMININO	Insatisfeito	32877	219	0.67	0.58	0.75
22	FEMININO	Indiferente	32877	6227	18.94	18.51	19.37
23	FEMININO	Satisfeito	32877	5287	16.08	15.67	16.48
24	FEMININO	Muito satisfeito	32877	21144	64.31	63.81	64.87
25	MASCULINO	Muito insatisfeito	220396	0	0.00	0.00	0.00
26	MASCULINO	Insatisfeito	220396	1321	0.60	0.57	0.63
27	MASCULINO	Indiferente	220396	40817	18.52	18.35	18.69
28	MASCULINO	Satisfeito	220396	35651	16.18	16.02	16.33
29	MASCULINO	Muito satisfeito	220396	142607	64.70	64.51	64.91

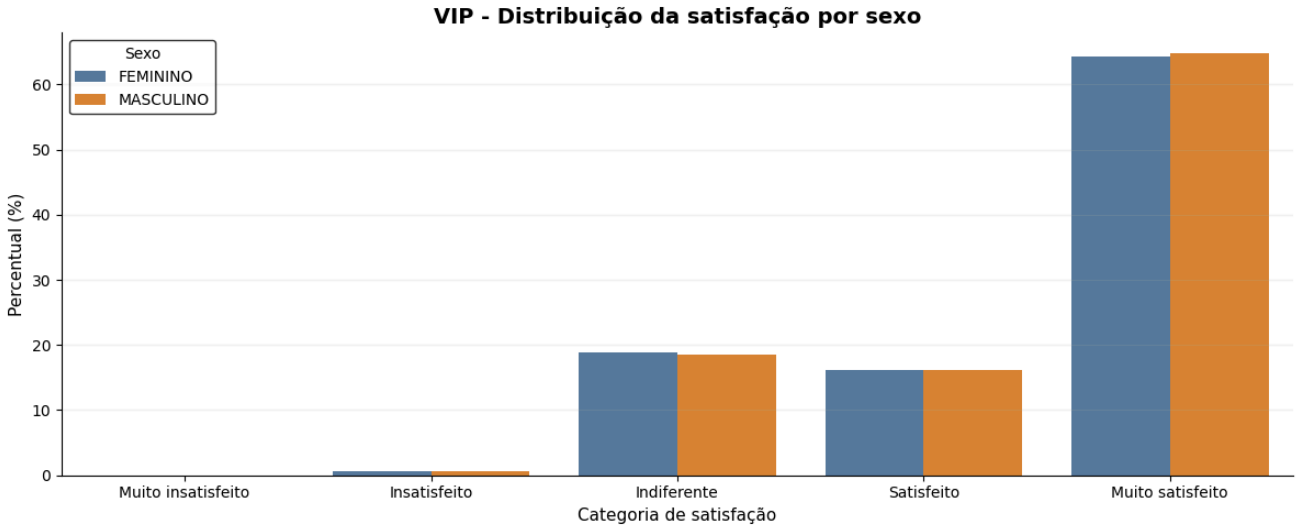

ESSENTIAL - Distribuição da satisfação
Percentual (%)
0
10
20
30
40
50
60
70
0.00%
0.60%
18.62%
16.14%
64.64%
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação

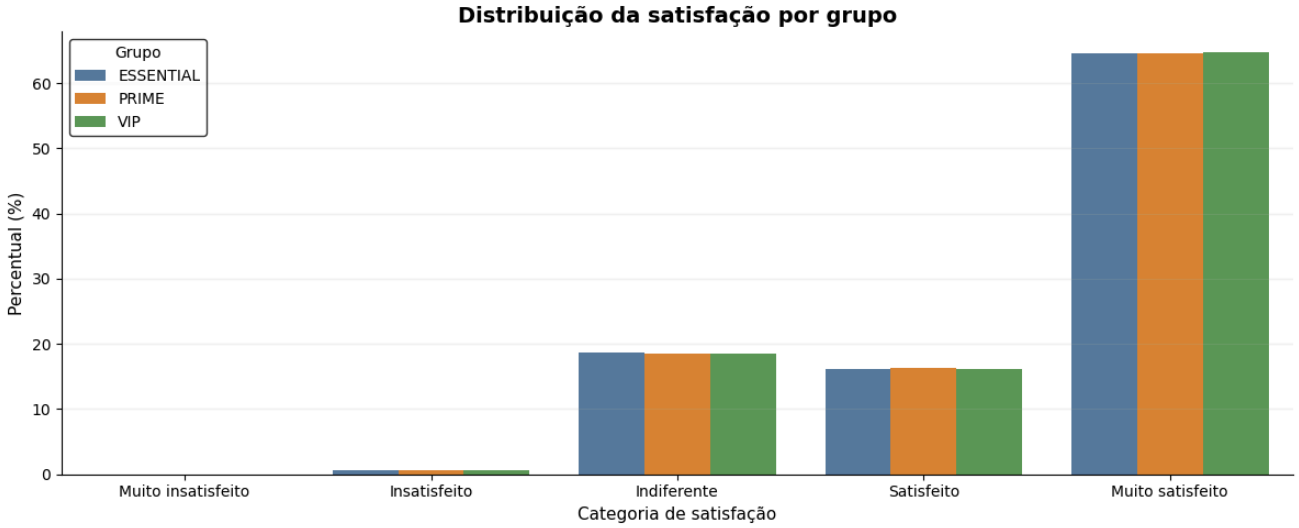

PRIME - Distribuição da satisfação
Percentual (%)
0
10
20
30
40
50
60
70
0.00%
0.60%
18.52%
16.33%
64.55%
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação

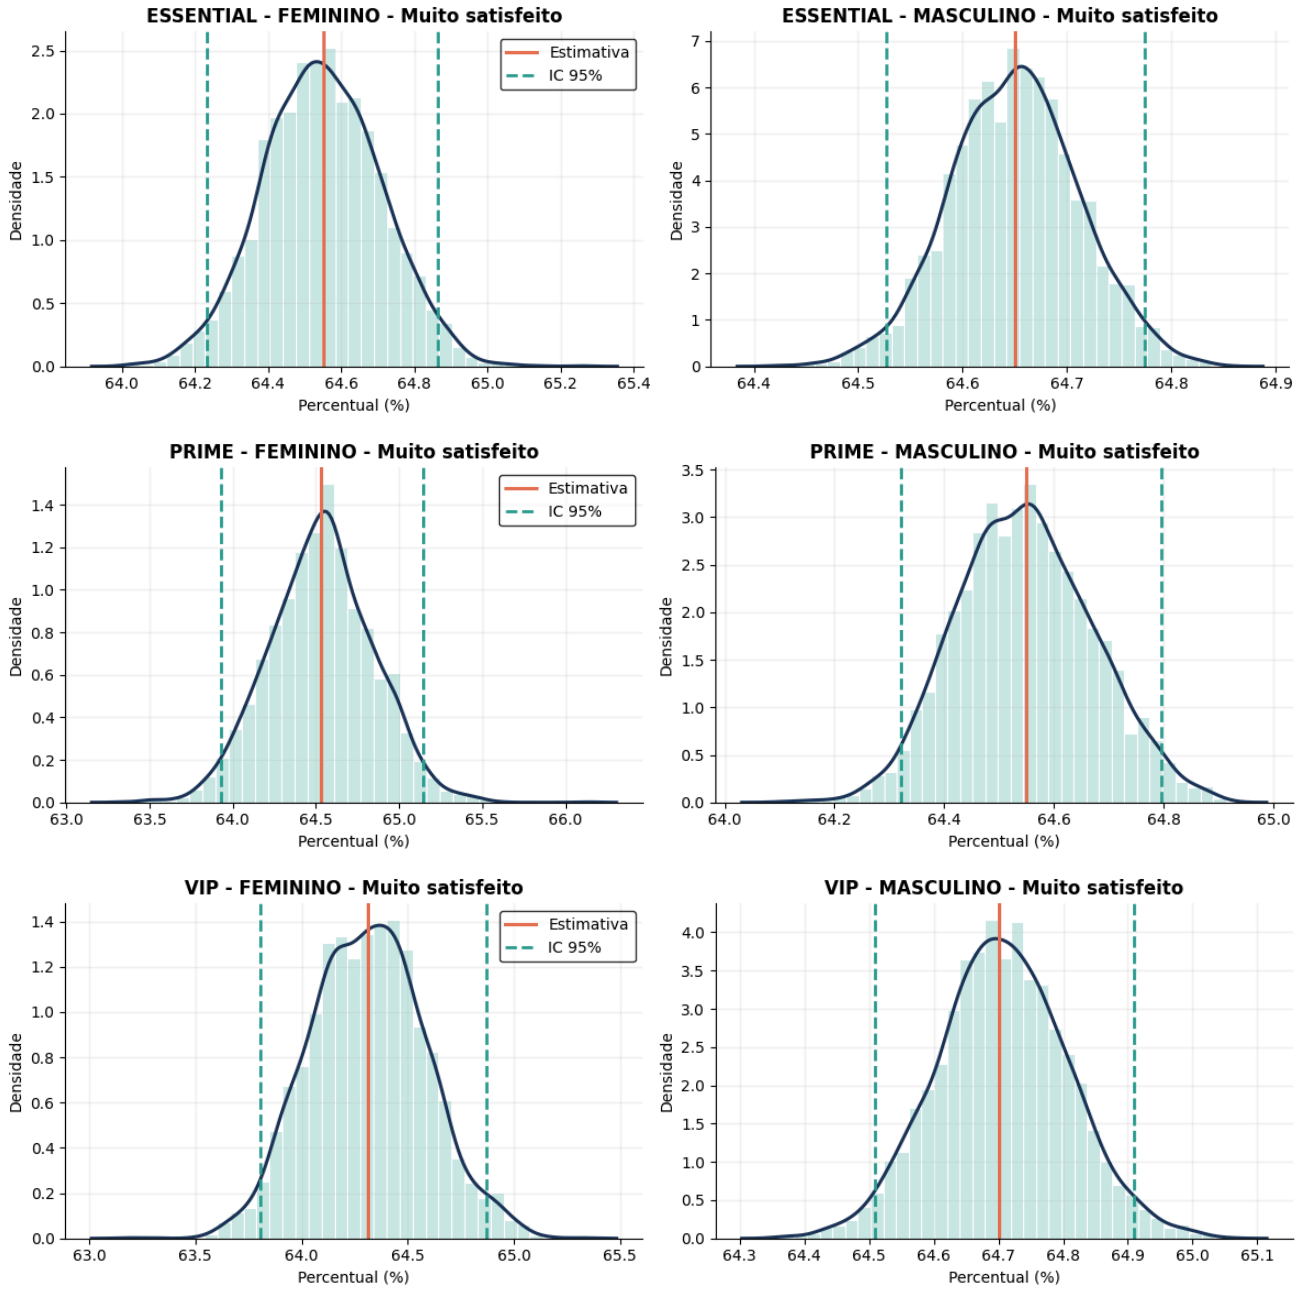

VIP - Distribuição da satisfação
Percentual (%)
0
10
20
30
40
50
60
70
0.00%
0.61%
18.57%
16.16%
64.65%
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação


ESSENTIAL - Distribuição da satisfação por sexo
Sexo
FEMININO
MASCULINO
Percentual (%)
0
10
20
30
40
50
60
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação


PRIME - Distribuição da satisfação por sexo
Sexo
FEMININO
MASCULINO
Percentual (%)
0
10
20
30
40
50
60
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação


VIP - Distribuição da satisfação por sexo
Sexo
FEMININO
MASCULINO
Percentual (%)
0
10
20
30
40
50
60
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação





Os resultados da A3.1 mostram que a distribuição da satisfação é muito parecida entre ESSENTIAL, PRIME e VIP. Em todos os grupos, a categoria dominante foi Muito satisfeito, com 64,64% em

ESSENTIAL, 64,55% em PRIME e 64,65% em VIP. Indiferente (18,62%, 18,52% e 18,57%) e Satisfeito (16,14%, 16,33% e 16,16%) vêm em seguida, com valores próximos entre os segmentos. Insatisfeito ficou em cerca de 0,6% em todos os grupos, e Muito insatisfeito não teve nenhuma ocorrência.

Dentro de cada grupo, a análise por sexo manteve o mesmo padrão. O percentual de Muito satisfeito foi de 64,55% em FEMININO e 64,65% em MASCULINO em ESSENTIAL, de 64,53% e 64,55% em PRIME e de 64,31% e 64,70% em VIP. A maior diferença entre sexos foi de 0,39 ponto percentual, em VIP, e o mesmo comportamento aparece nas demais categorias.

Os intervalos de confiança por bootstrap foram estreitos na leitura geral dos grupos, com amplitudes de até 0,43 ponto percentual na categoria Muito satisfeito. Na segmentação por sexo, os intervalos de FEMININO são mais largos que os de MASCULINO, o que é esperado pelo menor número de registros, mas continuam estreitos.

Conclui-se que a percepção dos clientes é predominantemente positiva, homogênea entre os três grupos e estável por sexo. O predomínio de Muito satisfeito e a presença quase nula de avaliações negativas indicam uma experiência consistentemente favorável em todos os segmentos.

Atividade A3.2: Análise Bootstrap do resultado da Pesquisa de Satisfação

Nesta etapa, a análise da satisfação dos clientes é aprofundada por meio da aplicação da técnica de bootstrap, buscando avaliar a precisão estatística dos percentuais identificados em cada categoria de satisfação.

O procedimento é realizado separadamente nos grupos `ESSENTIAL`, `PRIME` e `VIP`, considerando duas perspectivas de análise: a distribuição geral dos níveis de satisfação em cada grupo e a distribuição desses níveis de acordo com o sexo dos clientes dentro de cada segmento. Para ambas as abordagens, são analisadas as cinco categorias de satisfação: `Muito insatisfeito`, `Insatisfeito`, `Indiferente`, `Satisfeito` e `Muito satisfeito`.

Com isso, a etapa possibilita verificar a consistência das estimativas obtidas, comparar a precisão dos resultados entre os diferentes grupos e identificar possíveis diferenças nos níveis de satisfação de acordo com o sexo dos clientes em cada segmento.

```
Análise bootstrap da satisfação por grupos concluída.
Grupos analisados: 3
Categorias analisadas: 5
Também foi calculada a precisão bootstrap por sexo dentro de cada grupo.
```

	Grupo	Categoria	N válidos	Freq. (%)	Erro padrão bootstrap	IC 95% inferior	IC 95% superior	Amplitude IC
0	ESSENTIAL	Muito insatisfeito	683501	0.00	0.00	0.00	0.00	0.00
1	ESSENTIAL	Insatisfeito	683501	0.60	0.01	0.58	0.62	0.04
2	ESSENTIAL	Indiferente	683501	18.62	0.05	18.53	18.71	0.18
3	ESSENTIAL	Satisfeito	683501	16.14	0.04	16.05	16.23	0.17
4	ESSENTIAL	Muito satisfeito	683501	64.64	0.06	64.52	64.75	0.23
5	PRIME	Muito insatisfeito	183226	0.00	0.00	0.00	0.00	0.00
6	PRIME	Insatisfeito	183226	0.60	0.02	0.57	0.64	0.07
7	PRIME	Indiferente	183226	18.52	0.09	18.34	18.69	0.35
8	PRIME	Satisfeito	183226	16.33	0.09	16.16	16.50	0.34
9	PRIME	Muito satisfeito	183226	64.55	0.11	64.33	64.76	0.43
10	VIP	Muito insatisfeito	253273	0.00	0.00	0.00	0.00	0.00
11	VIP	Insatisfeito	253273	0.61	0.02	0.58	0.64	0.06
12	VIP	Indiferente	253273	18.57	0.08	18.42	18.72	0.30
13	VIP	Satisfeito	253273	16.16	0.07	16.03	16.31	0.28
14	VIP	Muito satisfeito	253273	64.65	0.09	64.47	64.83	0.36

```
Grupo: ESSENTIAL
```

	Categoria	Freq. (%)	Erro padrão bootstrap	IC 95% inferior	IC 95% superior	Amplitude IC
0	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
1	Insatisfeito	0.60	0.01	0.58	0.62	0.04
2	Indiferente	18.62	0.05	18.53	18.71	0.18
3	Satisfeito	16.14	0.04	16.05	16.23	0.17
4	Muito satisfeito	64.64	0.06	64.52	64.75	0.23

```
Grupo: PRIME
```

	Categoria	Freq. (%)	Erro padrão bootstrap	IC 95% inferior	IC 95% superior	Amplitude IC
5	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
6	Insatisfeito	0.60	0.02	0.57	0.64	0.07
7	Indiferente	18.52	0.09	18.34	18.69	0.35
8	Satisfeito	16.33	0.09	16.16	16.50	0.34
9	Muito satisfeito	64.55	0.11	64.33	64.76	0.43

```
Grupo: VIP
```

	Categoria	Freq. (%)	Erro padrão bootstrap	IC 95% inferior	IC 95% superior	Amplitude IC
10	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
11	Insatisfeito	0.61	0.02	0.58	0.64	0.06
12	Indiferente	18.57	0.08	18.42	18.72	0.30
13	Satisfeito	16.16	0.07	16.03	16.31	0.28
14	Muito satisfeito	64.65	0.09	64.47	64.83	0.36

```
Grupo: ESSENTIAL - bootstrap por sexo
```

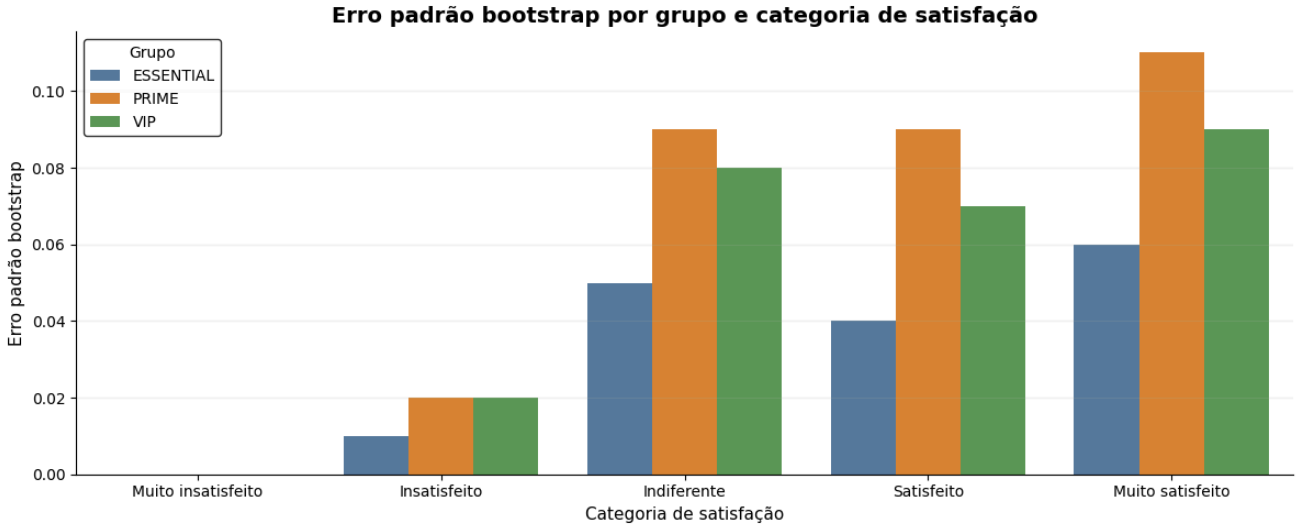
	Sexo	Categoria	Freq. (%)	Erro padrão bootstrap	IC 95% inferior	IC 95% superior	Amplitude IC
0	FEMININO	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
1	FEMININO	Insatisfeito	0.60	0.03	0.55	0.66	0.10
2	FEMININO	Indiferente	18.82	0.13	18.56	19.08	0.53
3	FEMININO	Satisfeito	16.03	0.12	15.78	16.27	0.49
4	FEMININO	Muito satisfeito	64.55	0.16	64.23	64.86	0.63
5	MASCULINO	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
6	MASCULINO	Insatisfeito	0.60	0.01	0.58	0.62	0.04
7	MASCULINO	Indiferente	18.59	0.05	18.49	18.69	0.20
8	MASCULINO	Satisfeito	16.16	0.05	16.07	16.25	0.18
9	MASCULINO	Muito satisfeito	64.65	0.06	64.53	64.77	0.25

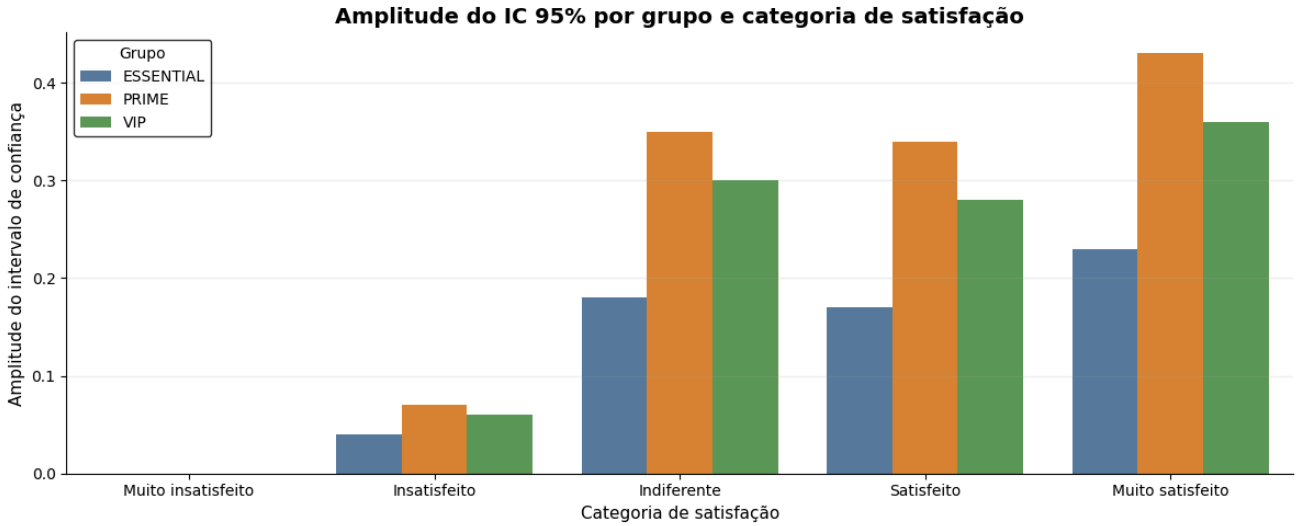
```
Grupo: PRIME - bootstrap por sexo
```

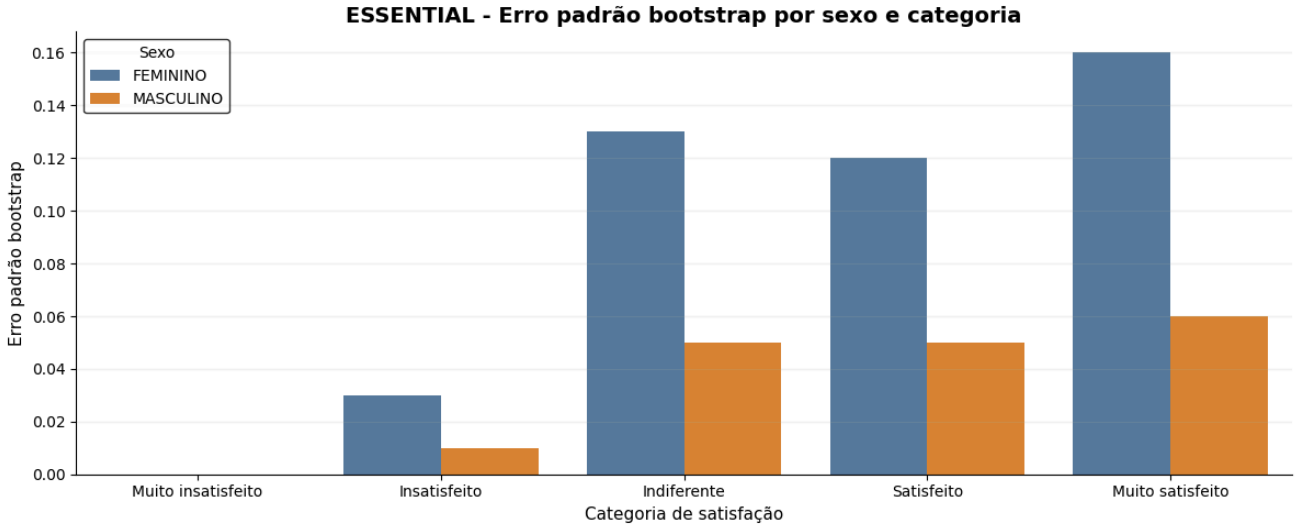
	Sexo	Categoria	Freq. (%)	Erro padrão bootstrap	IC 95% inferior	IC 95% superior	Amplitude IC
10	FEMININO	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
11	FEMININO	Insatisfeito	0.56	0.05	0.47	0.66	0.19
12	FEMININO	Indiferente	18.48	0.25	18.00	18.97	0.97
13	FEMININO	Satisfeito	16.43	0.24	15.95	16.90	0.95
14	FEMININO	Muito satisfeito	64.53	0.31	63.93	65.15	1.22
15	MASCULINO	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
16	MASCULINO	Insatisfeito	0.61	0.02	0.57	0.64	0.07
17	MASCULINO	Indiferente	18.53	0.10	18.34	18.72	0.39
18	MASCULINO	Satisfeito	16.32	0.09	16.13	16.50	0.37
19	MASCULINO	Muito satisfeito	64.55	0.12	64.32	64.79	0.47

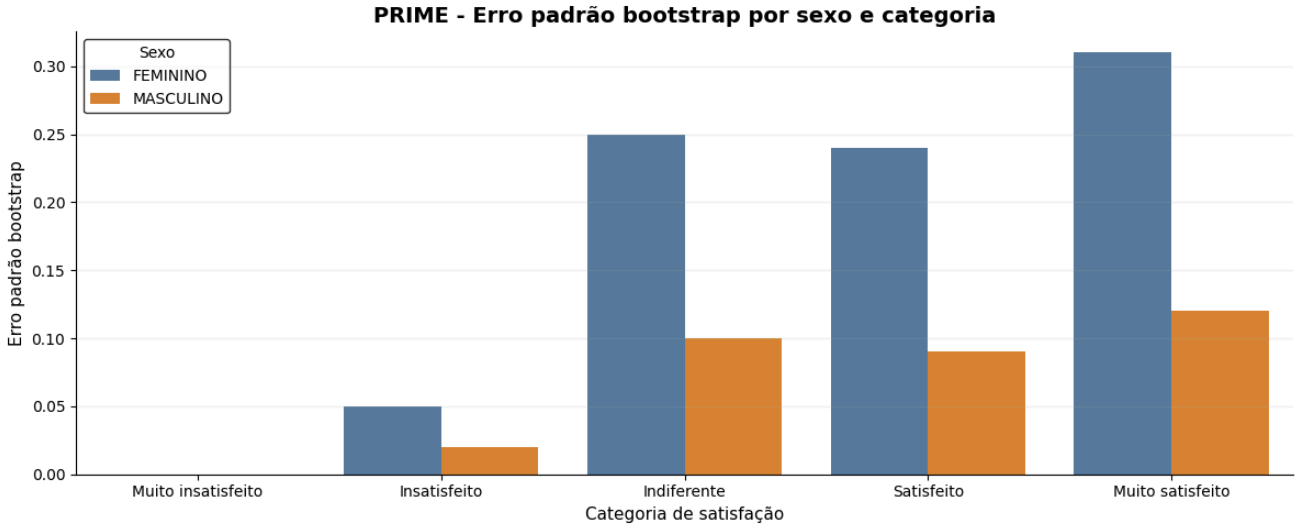
`Grupo: VIP - bootstrap por sexo`

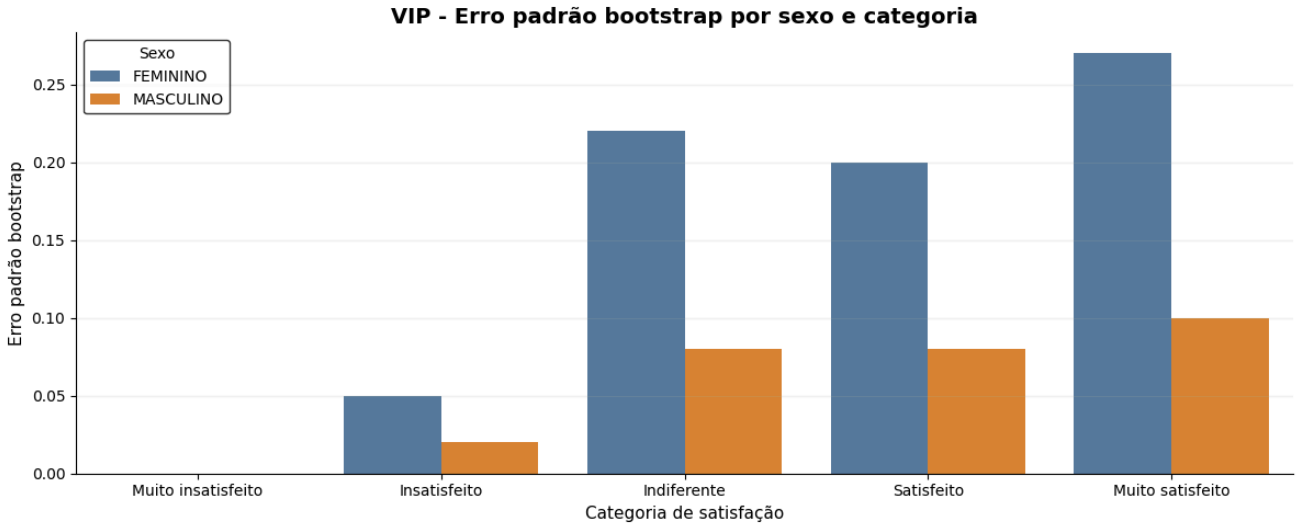
	Sexo	Categoria	Freq. (%)	Erro padrão bootstrap	IC 95% inferior	IC 95% superior	Amplitude IC
20	FEMININO	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
21	FEMININO	Insatisfeito	0.67	0.05	0.58	0.75	0.18
22	FEMININO	Indiferente	18.94	0.22	18.51	19.37	0.86
23	FEMININO	Satisfeito	16.08	0.20	15.67	16.48	0.81
24	FEMININO	Muito satisfeito	64.31	0.27	63.81	64.87	1.06
25	MASCULINO	Muito insatisfeito	0.00	0.00	0.00	0.00	0.00
26	MASCULINO	Insatisfeito	0.60	0.02	0.57	0.63	0.07
27	MASCULINO	Indiferente	18.52	0.08	18.35	18.69	0.33
28	MASCULINO	Satisfeito	16.18	0.08	16.02	16.33	0.31
29	MASCULINO	Muito satisfeito	64.70	0.10	64.51	64.91	0.40

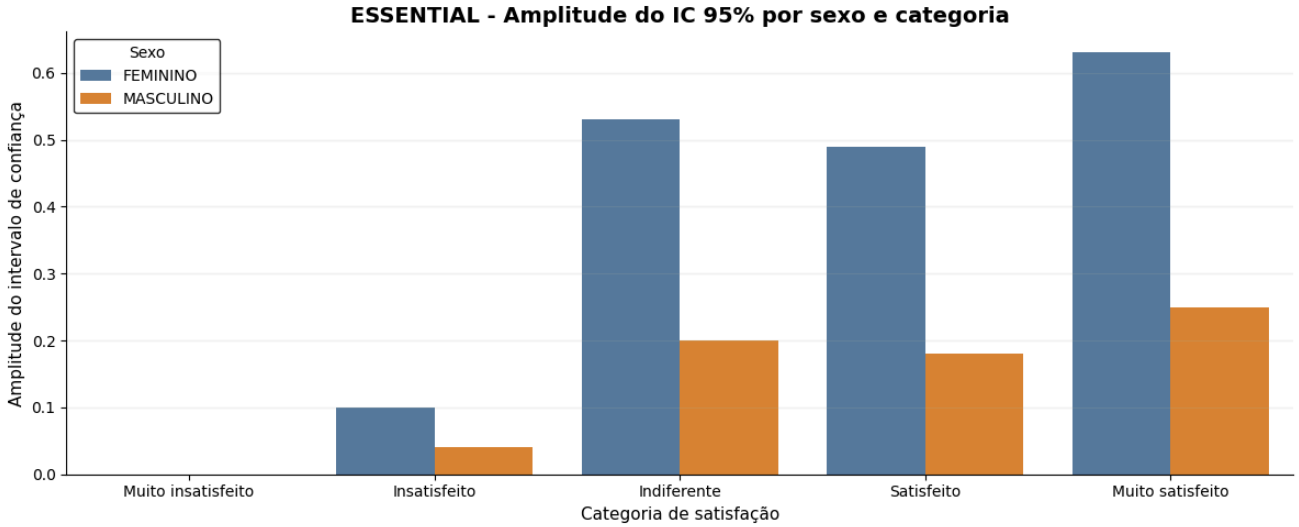

Erro padrão bootstrap por grupo e categoria de satisfação
Grupo
ESSENTIAL
PRIME
VIP
Erro padrão bootstrap
0.00
0.02
0.04
0.06
0.08
0.10
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação

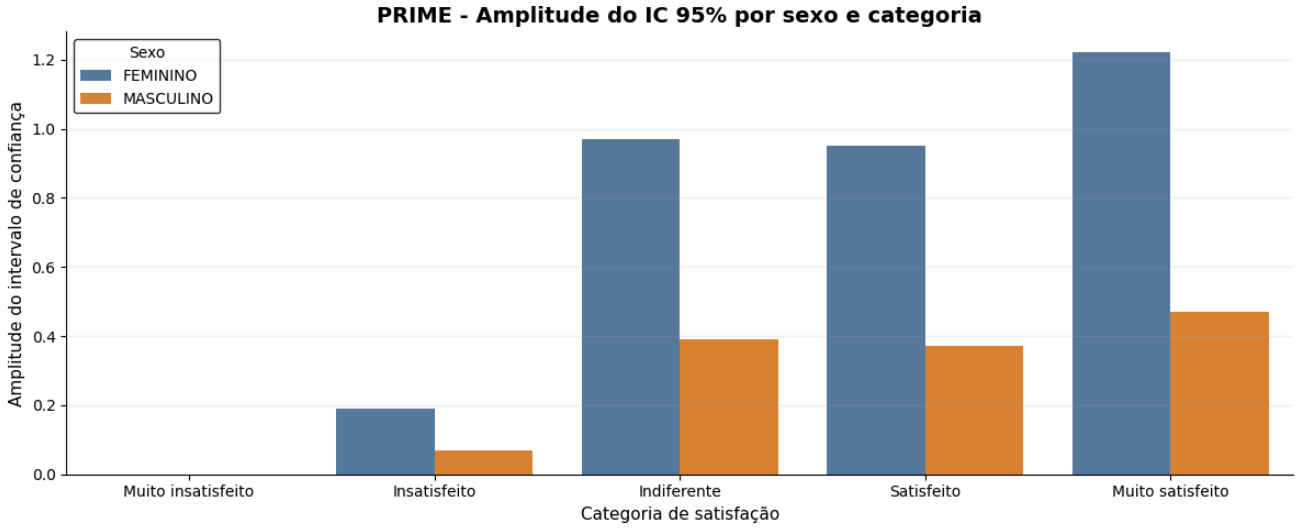

Amplitude do IC 95% por grupo e categoria de satisfação
Grupo
ESSENTIAL
PRIME
VIP
Amplitude do intervalo de confiança
0.0
0.1
0.2
0.3
0.4
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação

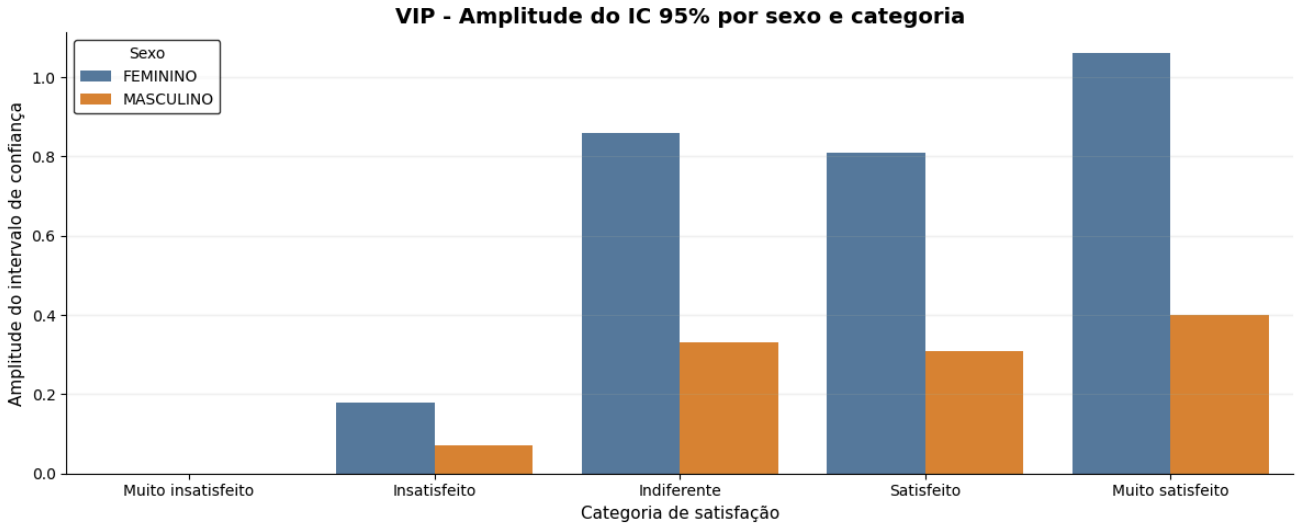

ESSENTIAL - Erro padrão bootstrap por sexo e categoria
Sexo
FEMININO
MASCULINO
Erro padrão bootstrap
0.00
0.02
0.04
0.06
0.08
0.10
0.12
0.14
0.16
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação

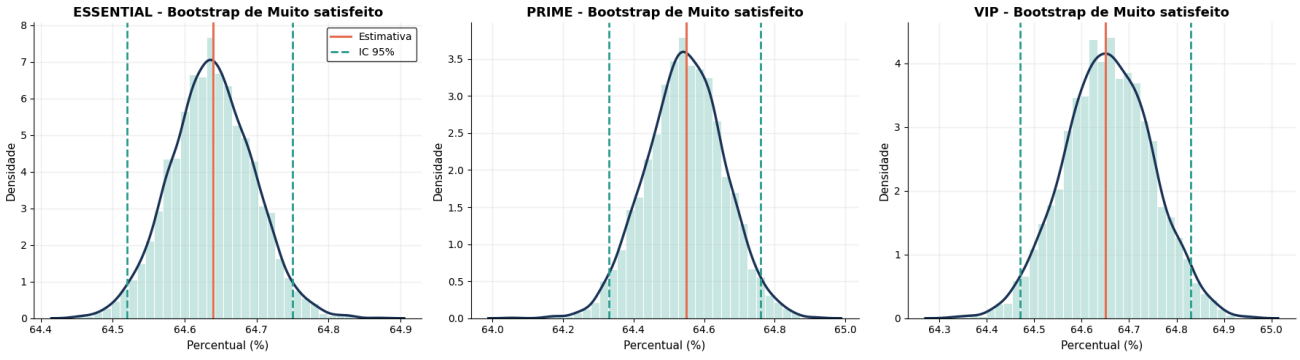

PRIME - Erro padrão bootstrap por sexo e categoria
Sexo
FEMININO
MASCULINO
Erro padrão bootstrap
0.00
0.05
0.10
0.15
0.20
0.25
0.30
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação

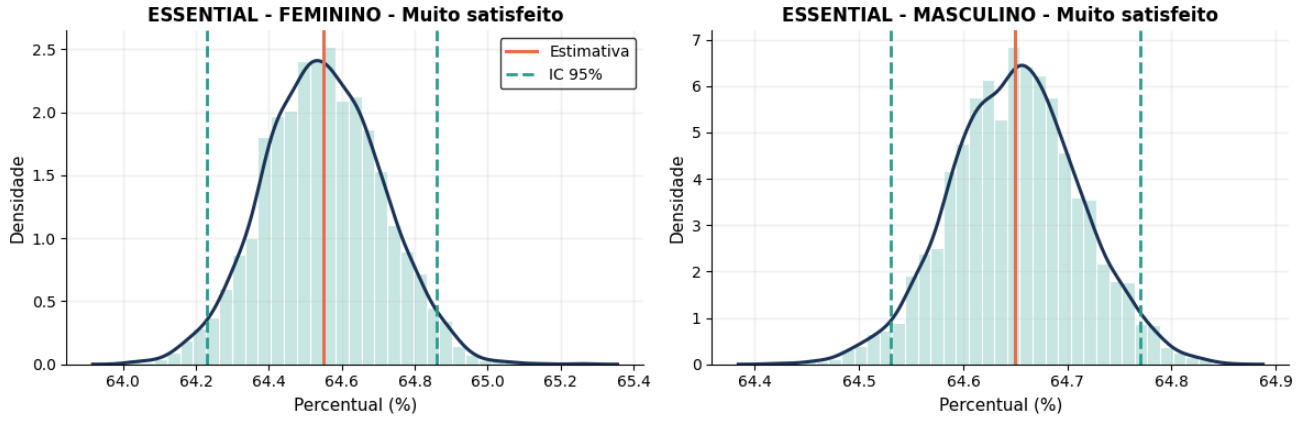

VIP - Erro padrão bootstrap por sexo e categoria
Sexo
FEMININO
MASCULINO
Erro padrão bootstrap
0.00
0.05
0.10
0.15
0.20
0.25
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação

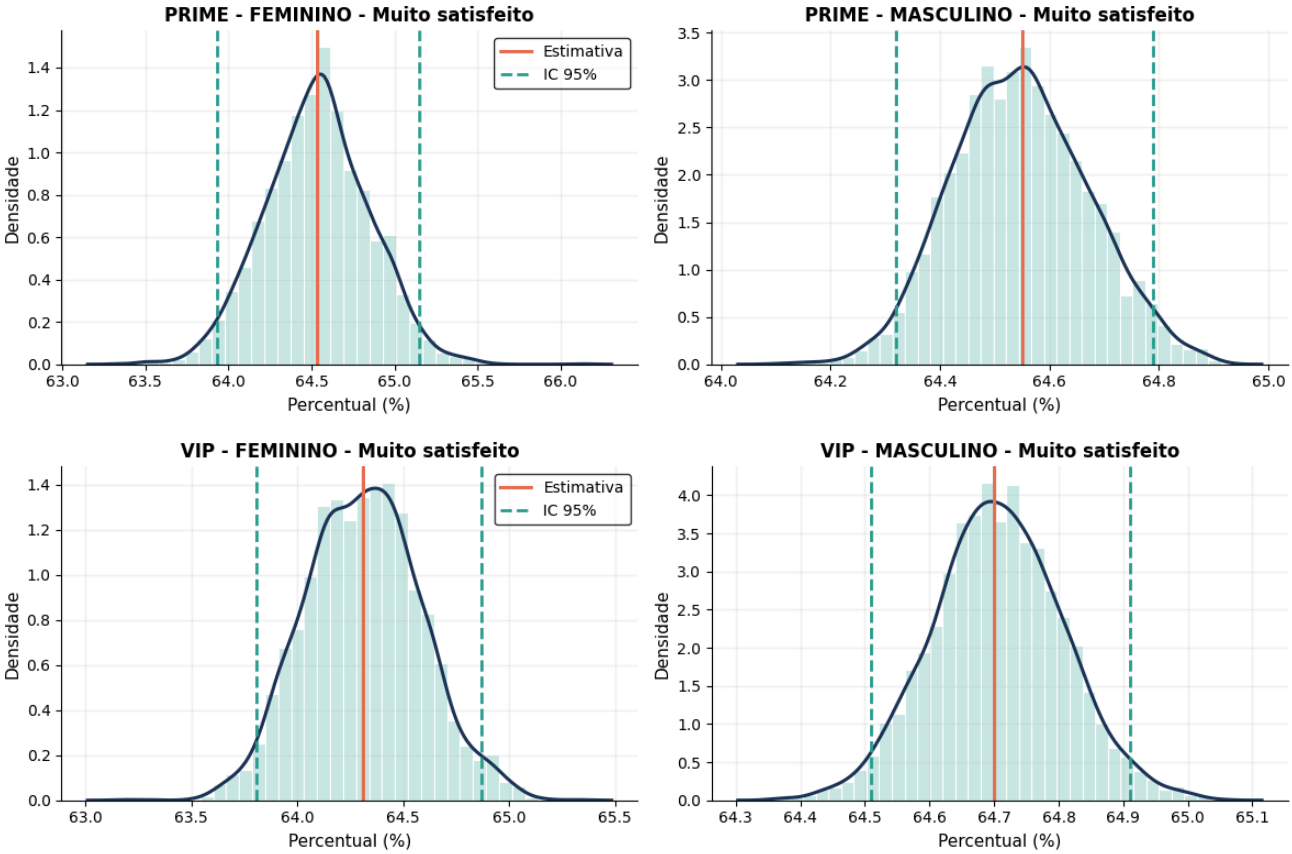

ESSENTIAL - Amplitude do IC 95% por sexo e categoria
Sexo
FEMININO
MASCULINO
Amplitude do intervalo de confiança
0.0
0.1
0.2
0.3
0.4
0.5
0.6
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação


PRIME - Amplitude do IC 95% por sexo e categoria
Sexo
FEMININO
MASCULINO
Amplitude do intervalo de confiança
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação


VIP - Amplitude do IC 95% por sexo e categoria
Sexo
FEMININO
MASCULINO
Amplitude do intervalo de confiança
Muito insatisfeito
Insatisfeito
Indiferente
Satisfeito
Muito satisfeito
Categoria de satisfação


ESSENTIAL - Bootstrap de Muito satisfeito
PRIME - Bootstrap de Muito satisfeito
VIP - Bootstrap de Muito satisfeito
Estimativa
IC 95%
Densidade
Percentual (%)


ESSENTIAL - FEMININO - Muito satisfeito
ESSENTIAL - MASCULINO - Muito satisfeito
Estimativa
IC 95%
Densidade
Percentual (%)



A análise bootstrap mostrou que as estimativas percentuais das cinco categorias de satisfação são estáveis nos grupos ESSENTIAL, PRIME e VIP. Na leitura geral de cada grupo, o erro padrão bootstrap máximo foi de 0,11 ponto percentual, na categoria Muito satisfeito de PRIME, e a maior amplitude de intervalo de confiança foi de 0,43 ponto percentual, também nessa categoria.

As categorias mais frequentes tiveram erros padrão um pouco maiores em termos absolutos, mas dentro de intervalos estreitos: em Muito satisfeito, de 0,06 em ESSENTIAL, 0,11 em PRIME e 0,09 em VIP. Já Insatisfeito, com participação residual, teve erro padrão de apenas 0,01 a 0,02 e amplitude entre 0,04 e 0,07, e Muito insatisfeito ficou em zero em todas as medidas.

Na segmentação por sexo, os resultados continuaram precisos, com diferença previsível entre os dois grupos. Em Muito satisfeito, o erro padrão ficou entre 0,06 e 0,12 em MASCULINO e entre 0,16 e 0,31 em FEMININO, e a maior amplitude (1,22 ponto percentual) ocorreu em FEMININO de PRIME, o subgrupo com menos registros.

Assim, o bootstrap reforça a robustez da leitura estratificada da satisfação, tanto entre os grupos quanto dentro deles, sem sinais de instabilidade relevante nas estimativas.

Atividade A3.3: Resultado Final da Pesquisa de Satisfação

Nesta etapa, são reunidos os resultados obtidos nas Atividades A3.1 e A3.2, consolidando a distribuição percentual das cinco categorias de satisfação, os intervalos de confiança estimados por bootstrap e os principais indicadores utilizados para a interpretação dos resultados nos grupos `ESSENTIAL`, `PRIME` e `VIP`.

O objetivo é apresentar uma visão consolidada da pesquisa de satisfação considerando a estrutura estratificada da base, a partir de duas perspectivas complementares: a análise geral de cada grupo e

a análise segmentada por sexo dentro de cada grupo. Dessa maneira, a etapa permite comparar os diferentes segmentos, identificar os níveis de satisfação predominantes, verificar a consistência estatística das estimativas e sintetizar o perfil geral de percepção dos clientes da UWine.

```
Resultado final da pesquisa de satisfação consolidado.
Grupos analisados: 3
Também foi consolidada a leitura por sexo dentro de cada grupo.
```

	Grupo	Muito insatisfeito (%)	Insatisfeito (%)	Indiferente (%)	Satisfeito (%)	Muito satisfeito (%)	Positivos (%)	Neutros (%)	Negati
0	ESSENTIAL	0.0	0.60	18.62	16.14	64.64	80.78	18.62	
1	PRIME	0.0	0.60	18.52	16.33	64.55	80.88	18.52	
2	VIP	0.0	0.61	18.57	16.16	64.65	80.82	18.57	

```
Grupo: ESSENTIAL - resultado final por sexo
```

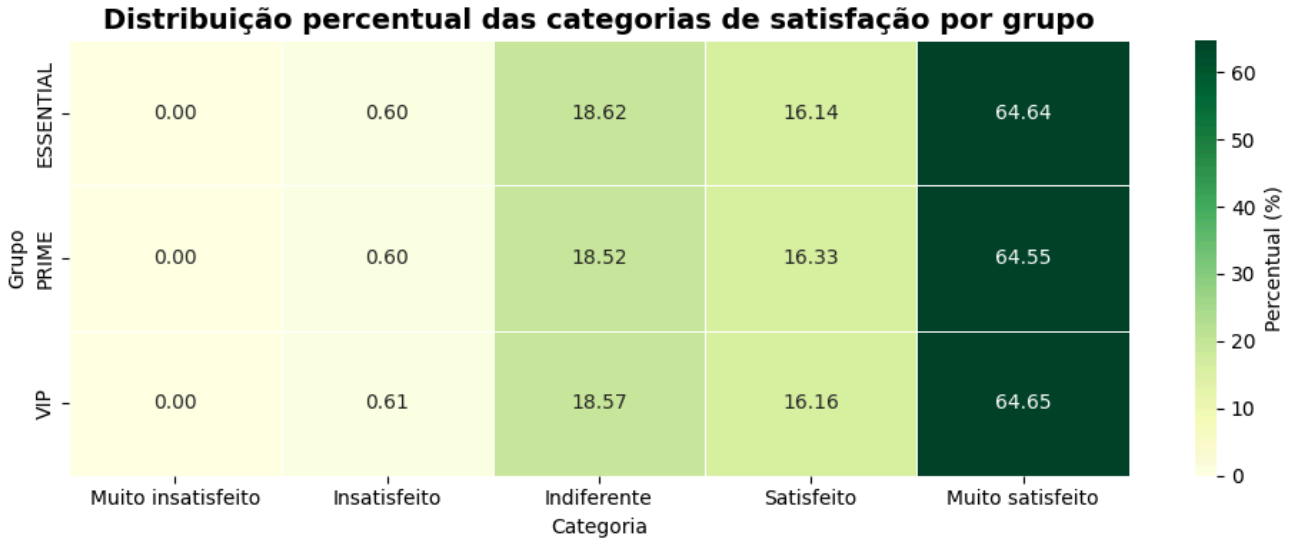
	Grupo	Sexo	Muito insatisfeito (%)	Insatisfeito (%)	Indiferente (%)	Satisfeito (%)	Muito satisfeito (%)	Positivos (%)	Ne
0	ESSENTIAL	FEMININO	0.0	0.6	18.82	16.03	64.55	80.58	
1	ESSENTIAL	MASCULINO	0.0	0.6	18.59	16.16	64.65	80.81	

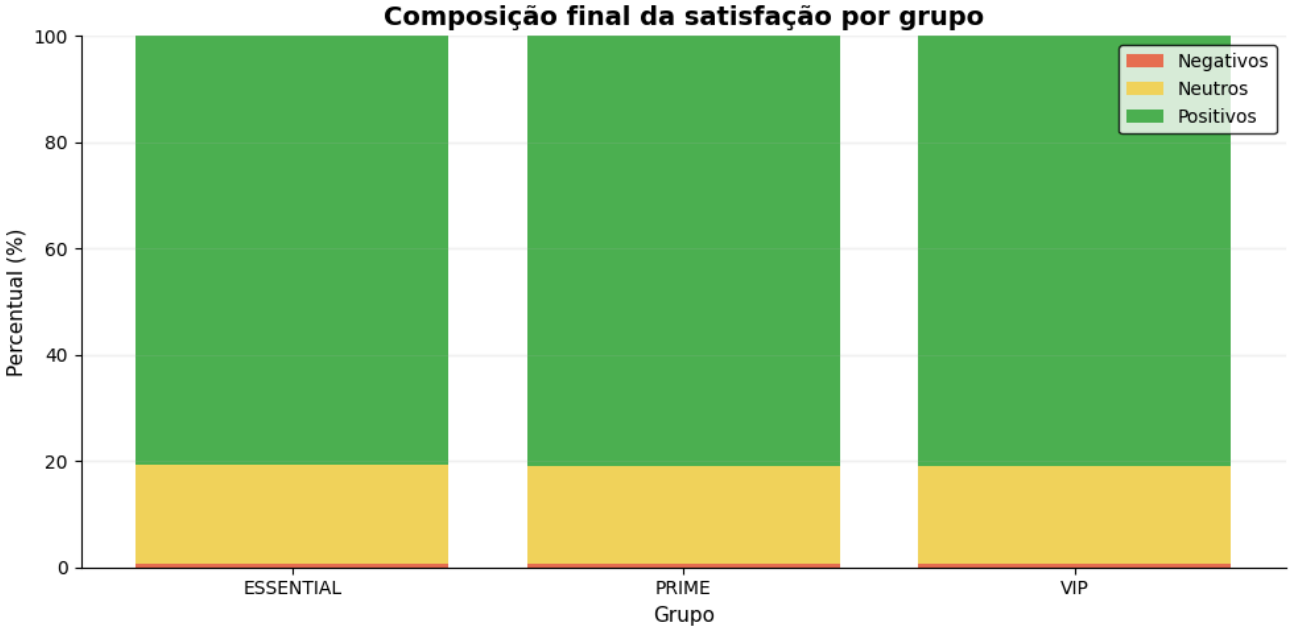
```
Grupo: PRIME - resultado final por sexo
```

	Grupo	Sexo	Muito insatisfeito (%)	Insatisfeito (%)	Indiferente (%)	Satisfeito (%)	Muito satisfeito (%)	Positivos (%)	Neutro (%
2	PRIME	FEMININO	0.0	0.56	18.48	16.43	64.53	80.95	18.4
3	PRIME	MASCULINO	0.0	0.61	18.53	16.32	64.55	80.87	18.5

```
Grupo: VIP - resultado final por sexo
```

	Grupo	Sexo	Muito insatisfeito (%)	Insatisfeito (%)	Indiferente (%)	Satisfeito (%)	Muito satisfeito (%)	Positivos (%)	Neutro (%
4	VIP	FEMININO	0.0	0.67	18.94	16.08	64.31	80.39	18.9
5	VIP	MASCULINO	0.0	0.60	18.52	16.18	64.70	80.88	18.5

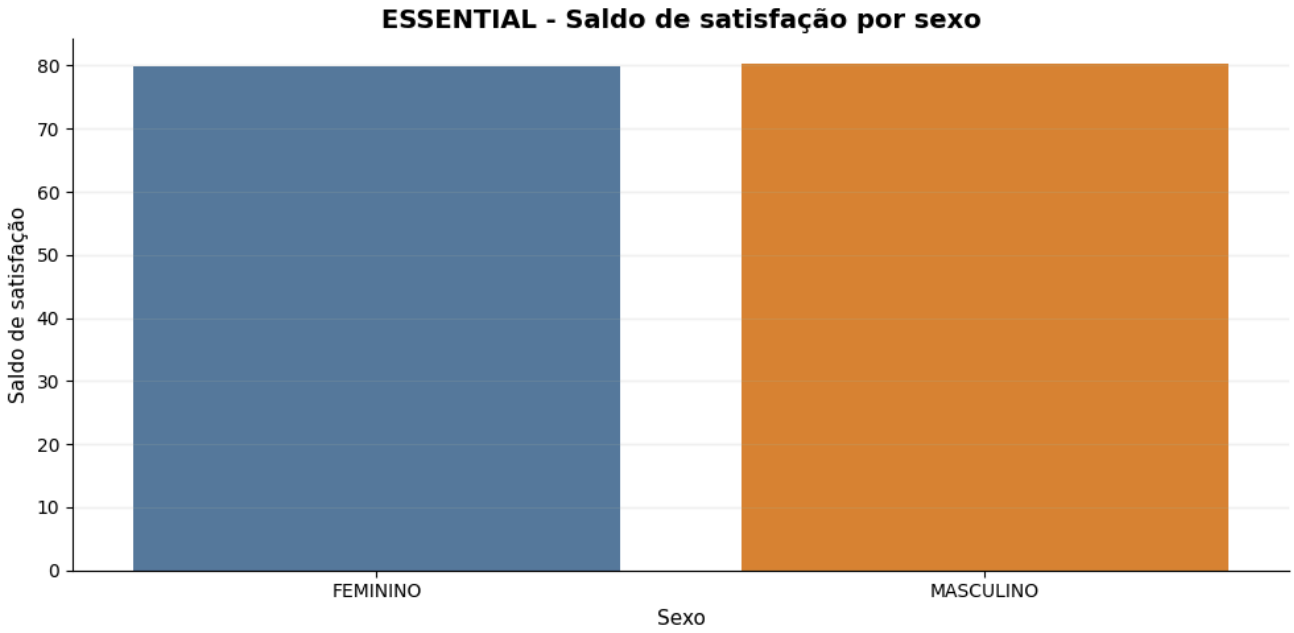





```
/tmp/ipykernel_2450/2303619261.py:6: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. As
sign the `x` variable to `hue` and set `legend=False` for the same effect.

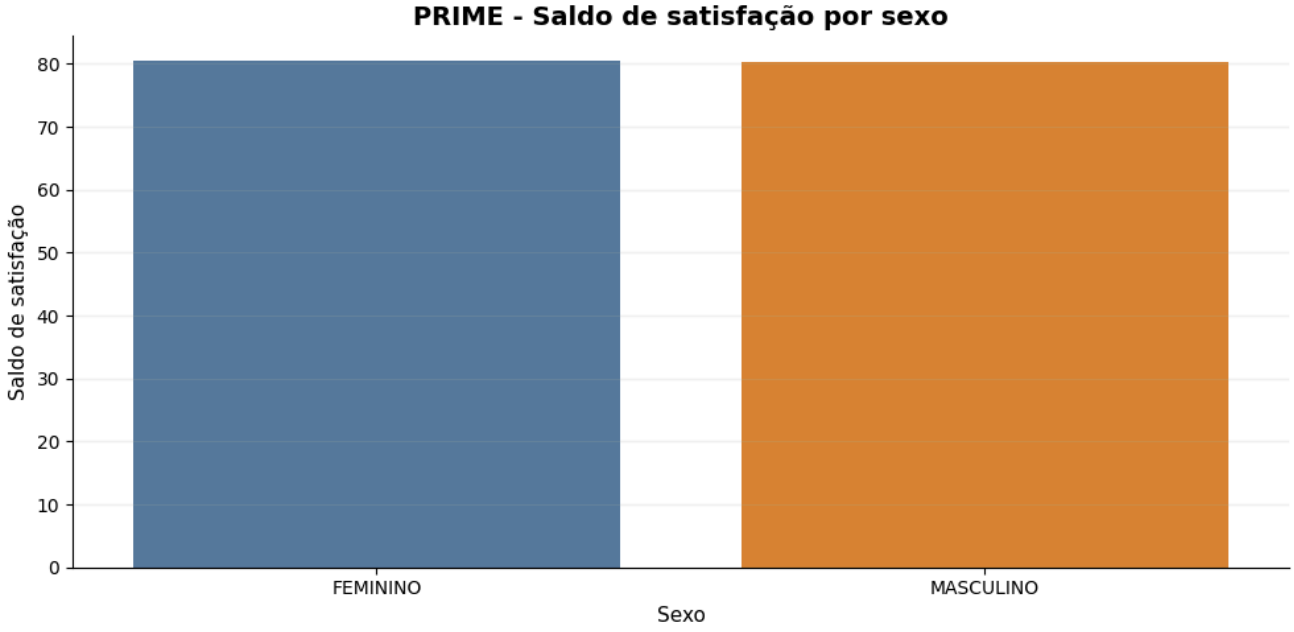
  sns.barplot(
```




```
/tmp/ipykernel_2450/2303619261.py:6: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. As
sign the `x` variable to `hue` and set `legend=False` for the same effect.

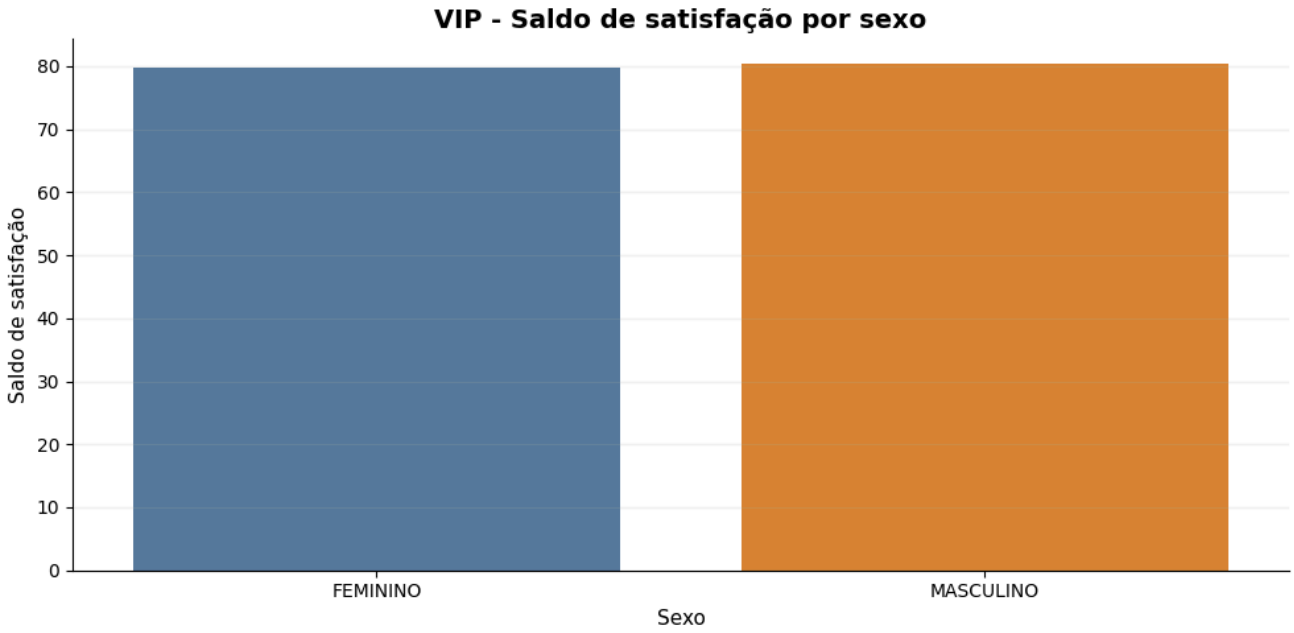
  sns.barplot(
```




```
/tmp/ipykernel_2450/2303619261.py:6: FutureWarning:

Passing `palette` without assigning `hue` is deprecated and will be removed in v0.14.0. As
sign the `x` variable to `hue` and set `legend=False` for the same effect.

  sns.barplot(
```



	Grupo	Positivos (%)	Negativos (%)	Saldo satisfação	Categoria dominante
1	PRIME	80.88	0.60	80.28	Muito satisfeito
2	VIP	80.82	0.61	80.21	Muito satisfeito
0	ESSENTIAL	80.78	0.60	80.18	Muito satisfeito

	Grupo	Sexo	Positivos (%)	Negativos (%)	Saldo satisfação	Categoria dominante
1	ESSENTIAL	MASCULINO	80.81	0.60	80.21	Muito satisfeito
0	ESSENTIAL	FEMININO	80.58	0.60	79.98	Muito satisfeito
2	PRIME	FEMININO	80.95	0.56	80.39	Muito satisfeito
3	PRIME	MASCULINO	80.87	0.61	80.26	Muito satisfeito
5	VIP	MASCULINO	80.88	0.60	80.28	Muito satisfeito
4	VIP	FEMININO	80.39	0.67	79.73	Muito satisfeito

Na consolidação final, as respostas positivas (Satisfeito e Muito satisfeito) somaram 80,78% em ESSENTIAL, 80,88% em PRIME e 80,82% em VIP, enquanto as respostas negativas ficaram em 0,60%, 0,60% e 0,61%, respectivamente. As respostas neutras (Indiferente) representaram cerca de 18,5% a 18,6%. O saldo de satisfação foi, portanto, amplamente favorável e praticamente igual entre os segmentos: 80,18 em ESSENTIAL, 80,28 em PRIME e 80,21 em VIP.

A leitura por sexo confirmou esse padrão. Em todos os grupos e em ambos os sexos, Muito satisfeito foi a categoria dominante, e os percentuais de respostas positivas variaram apenas de 80,39% a 80,95%. O menor saldo foi o de FEMININO em VIP (79,73) e o maior, o de FEMININO em PRIME (80,39), diferença inferior a 0,7 ponto.

A análise bootstrap confirmou a precisão dessas estimativas. O erro padrão médio foi de 0,03 em ESSENTIAL, 0,06 em PRIME e 0,05 em VIP, com amplitudes médias de intervalo de confiança de 0,12, 0,24 e 0,20 ponto percentual. Na segmentação por sexo, os intervalos de FEMININO foram mais largos (amplitude média de 0,35 a 0,67) que os de MASCULINO (0,13 a 0,26), mas ainda estreitos.

Conclui-se que a pesquisa de satisfação revela uma percepção amplamente positiva, homogênea entre ESSENTIAL, PRIME e VIP e estatisticamente estável também entre homens e mulheres dentro de cada grupo.

RELATÓRIO FINAL - PARTE 1

Análise Estatística da Base de Clientes — UWine

1. Introdução

O relatório reúne os resultados da Parte 1 do projeto UWine: estratificação amostral, testes de hipóteses, estatística descritiva e pesquisa de satisfação. A pergunta central é: **qual é o tamanho ideal da amostra para representar a população de clientes?** Como os grupos ESSENTIAL, PRIME e VIP se comportam de forma diferente, a análise foi feita por grupo, e não apenas de forma global.

2. Atividade A1 — Estratificação Amostral

2.1 Tamanho ideal da amostra

O tamanho ideal foi definido pela estabilização do erro-padrão da média de `TOTAL (R$)`, escolhendo o menor n cujo erro-padrão fica menor ou igual ao erro-padrão médio. Na base inteira, o resultado foi de 51.400 observações. Por grupo, foi de:

- ESSENTIAL: 50.900 observações
- PRIME: 47.500 observações
- VIP: 51.500 observações

2.2 Qualidade dos dados

Não houve valores negativos nas variáveis monetárias, e os extremos altos foram mantidos, pois podem representar clientes de maior valor. Já `NOTA DE SATISFAÇÃO (%)` se concentrou em 68,68 (92,575% da base, 100% em ESSENTIAL e 99,96% em VIP), e por isso a satisfação foi analisada pela variável `OPINIÃO DO CLIENTE`.

2.3 Testes de hipóteses e validação

Cada grupo gerou 20 rodadas válidas de reamostragem, com taxas de aceite de 39,22% em ESSENTIAL, 57,14% em PRIME e 29,85% em VIP. Os testes mostraram que:

- O Shapiro-Wilk rejeitou a normalidade de `TOTAL (R$)` nos três grupos.
- O Qui-Quadrado indicou que a permanência dentro do intervalo de confiança depende da partição (p entre 0,0001 e 0,0089), com TRAIN mais estável.
- O Levene não rejeitou a homogeneidade de variâncias entre as partições (p entre 0,0552 e 0,5173).
- O Friedman, com o pós-teste de Holm, não encontrou diferença de médias entre TRAIN, VALIDATION e TEST (p entre 0,3499 e 0,8607).
- O bootstrap da diferença entre média amostral e média populacional teve intervalo de confiança incluindo zero em todas as rodadas aceitas.

Assim, apesar da não normalidade, as amostras aceitas são estáveis e compatíveis com a população de cada grupo.

3. Atividade A2 — Estatística Descritiva

3.1 Variáveis quantitativas

ESSENTIAL tem os menores níveis (médias de 3.651,78 em `RENDA BRUTO (R$)` e 403,87 em `TOTAL (R$)`) e forte assimetria positiva (5,86 e 5,02). PRIME tem os maiores (19.912,56 e 2.192,33), com `TOTAL (R$)` mais regular (assimetria de 0,19) e renda com assimetria negativa (-1,60). VIP fica no meio (8.242,14 e 907,18) e tem mais extremos em renda (12,05%). A base é, portanto, heterogênea entre os grupos.

3.2 Variáveis qualitativas

Os três grupos têm perfis muito parecidos: SUDESTE em cerca de 67% dos registros, MASCULINO em cerca de 87%, CASADO em cerca de 55% e DEPENDENTES igual a 1 em cerca de 53%. `OPINIÃO DO CLIENTE` é a mais diversa, com 25 categorias e nenhuma acima de 15,6%.

4. Resultado da Pesquisa de Satisfação

A opinião foi classificada em cinco níveis, e o padrão é muito parecido entre os grupos:

- Muito satisfeito: 64,64% (ESSENTIAL), 64,55% (PRIME) e 64,65% (VIP)
- Indiferente: cerca de 18,6%
- Satisfeito: cerca de 16,2%
- Insatisfeito: cerca de 0,6%
- Muito insatisfeito: nenhuma ocorrência

As respostas positivas somam entre 80,78% e 80,88%, e o saldo de satisfação fica entre 80,18 e 80,28. Por sexo, o padrão se repete, com Muito satisfeito dominante em todos os casos. O bootstrap confirmou a precisão dos resultados, com erros padrão médios de até 0,06 ponto percentual por grupo.

5. Conclusão — Resposta à Pergunta Principal

Qual é o tamanho ideal da amostra?

Não há um único tamanho ideal para toda a população quando se respeita a estrutura da base. A resposta é dada por grupo: **50.900 observações em ESSENTIAL, 47.500 em PRIME e 51.500 em VIP**. O valor global, de 51.400, serve como referência. Os pontos que sustentam essa resposta são:

1. Os grupos têm comportamentos estatísticos distintos, o que impede tratar a base como homogênea.
2. A amostragem estratificada gerou 20 rodadas válidas em cada grupo.
3. As partições foram validadas com o intervalo de confiança de cada grupo e não diferem em média nem em variância.
4. O bootstrap mostrou compatibilidade entre médias amostrais e populacionais.
5. A estatística descritiva mostrou diferenças relevantes entre os grupos.
6. A satisfação é estável entre os grupos, o que reforça a coerência da segmentação.

6. Considerações Finais

A Parte 1 mostrou que a base da UWine é heterogênea, com assimetria e caudas longas nas variáveis monetárias, mas que uma abordagem estratificada permite representá-la de forma adequada. Essa estratégia sustenta as próximas etapas do projeto.

```
[NbConvertApp] Converting notebook /content/ERICK_MACHADO_WORKFLOW_PARTE_1.ipynb to html
[NbConvertApp] WARNING | Alternative text is missing on 71 image(s).
[NbConvertApp] Writing 6358376 bytes to /content/ERICK_MACHADO_WORKFLOW_PARTE_1.html
```